Guia das equações da monografia

Grafos de notícias extraídos por LLM na estimação da matriz de covariância

Documento de apoio — novembro de 2026

Sumário

1 Como ler este guia **3**

1.1 As três hipóteses e suas equações . . . 3
1.2 Convenções de unidade . . . 3
1.3 Índices e dimensões . . . 4
1.4 Símbolos reutilizados com sentidos diferentes . . . 4

2 Carteiras **4**

2.1 Média-variância de Markowitz . . . 4
2.2 Carteira de variância mínima global (GMV) . . . 5
2.3 Máxima diversificação . . . 5
2.4 Mínimo *tracking error* . . . 5
2.5 HRP: distância e bissecção . . . 6

3 Estimação da matriz de covariância **6**

3.1 Covariância amostral . . . 6
3.2 Número de condição . . . 7
3.3 Modelo de fatores . . . 7
3.4 *Shrinkage* linear . . . 7
3.5 Intensidade ótima de Ledoit-Wolf (alvo de correlação constante) . . . 7

4 Avaliação de estimadores e inferência **8**

4.1 Erro de correlação . . . 8
4.2 R^2 fora da amostra . . . 8
4.3 Fama-MacBeth com Newey-West . . . 9
4.4 QAP (permutação de nós) . . . 9
4.5 Teste de Wald da igualdade de coeficientes (H1b) . . . 9
4.6 Razão de variâncias e *bootstrap* em blocos . . . 10
4.7 Índice de Sharpe . . . 10
4.8 Correções para múltiplos testes . . . 10

5 O grafo de notícias **10**
5.1 A tupla extraída . . . 10
5.2 Peso de um evento com decaimento . . . 11
5.3 Vínculo direto, por sinal e por grupo . . . 11
5.4 Compressão logarítmica com sinal . . . 12
5.5 Matriz de exposição e IDF . . . 12
5.6 Exposição comum . . . 12
5.7 Controles de atenção . . . 13

6 Previsão de correlação e testes diádicos **13**
6.1 Transformação de Fisher . . . 13
6.2 Regressão preditiva da correlação . . . 13
6.3 Fator de mercado e correlação residual . . . 14
6.4 Regressão dos testes de pares . . . 14
6.5 Arestas positivas e negativas (sinal, em H1b) . . . 15

7 Estimadores da matriz de covariância com notícias **15**
7.1 Alvo de correlação a partir das notícias . . . 15
7.2 Intensidade ótima generalizada . . . 16
7.3 Fator de mercado mais resíduo encolhido . . . 16
7.4 Black-Litterman na covariância . . . 17

8 Métricas de resultado das carteiras **18**

Referências citadas neste guia **18**

1 Como ler este guia

Este documento explica, uma a uma, as equações usadas na monografia: as que aparecem numeradas e as definições escritas em linha no texto (como $\mathrm{sgnlog}(w)$ ou o IDF). Para cada uma, dá:

- a equação, com o número que tem na monografia (por exemplo, (3.1)); as que aparecem em linha no texto vêm com a indicação *Em linha no texto* e a seção onde estão;
- uma tabela com cada variável, seu significado, seu domínio e sua unidade;
- o resultado da equação (o que ela devolve, em que domínio e em que unidade) e como ele é usado na tese, com os valores obtidos quando o texto os relata.

As equações estão agrupadas por assunto, na ordem em que o argumento as usa: carteiras, estimação de Σ, avaliação e inferência, grafo, regressões de correlação, estimadores com notícias e métricas de resultado.

1.1 As três hipóteses e suas equações

O trabalho investiga a fundo três hipóteses (Seção 3.3 da monografia). Cada uma usa um conjunto pequeno de equações deste guia:

	hipótese	equações
H1a	a exposição comum prevê a correlação futura do par	peso do evento (3.1); IDF e exposição comum (3.2); Fisher z; regressão preditiva (3.3) e R^2_{oos}; fator de mercado (3.4); regressão de pares (3.5); Fama-MacBeth e QAP
H1b	o tipo de relação importa; o sinal não indica o co-movimento	vínculos $d_{ij}^{(k)}$, $w_{ij}^{\pm}$, sgnlog; regressão de pares (3.5); Wald; Benjamini-Hochberg
H2	o *prior* de setor e notícias dá carteira melhor que o de setor e que o placebo	GMV (2.2); *shrinkage* (2.4); alvo (3.6) e δ (3.7); fator + resíduo (3.8); Black-Litterman (3.9)–(3.11); razão de variâncias; Bonferroni

1.2 Convenções de unidade

- **Retorno.** Todos os retornos são *retornos simples diários* em fração decimal ($0{,}01 = 1\%$ no dia), calculados com o preço de fechamento ajustado. Embora a fração seja adimensional, convém rastrear o "tamanho" de cada grandeza: escreve-se $[r]$ para a unidade de um retorno diário. Assim, uma variância diária tem unidade $[r]^2$, um desvio-padrão diário, $[r]$, e a inversa de uma covariância, $[r]^{-2}$. Essa contabilidade mostra, por exemplo, por que os pesos da GMV são adimensionais e por que a QLIKE depende da escala dos retornos.
- **Anualização.** Usam-se 252 pregões por ano: volatilidade anual $= \sqrt{252}\times$ desvio-padrão diário; retorno médio anual $= 252\times$ média diária.
- **Tempo.** Há duas réguas de tempo no texto. O grafo usa *dias corridos* (janela $W = 365$ dias, meia-vida $\tau = 90$ dias), porque as notícias têm data de calendário. Os preços usam *pregões* (janela de estimação de 252 pregões, horizonte $h = 21$ pregões, cerca de um mês).
- **Pesos de carteira.** Frações do patrimônio, adimensionais, que somam 1. Um peso negativo é uma posição vendida.
- **Correlações, cossenos, forças de relação,** δ: adimensionais.

1.3 Índices e dimensões

símbolo	significado
p	número de ações do universo numa data: 50, 100 ou 200 nas carteiras (n no texto); 344 a 474 nos testes de pares
N	número de observações (pregões) da janela de estimação; 252 por padrão
i,j,k,l	índices de ações, $1, \ldots, p$
m	índice de entidade fora do universo (Fed, petróleo, China...) na Seção 5
t	data (de rebalanceamento, no grafo; pregão, nas séries de retorno)
e	um evento do grafo (uma tupla extraída e limpa)
$\mathbf{1}$	vetor de uns de dimensão p
$\|\cdot\|_F$	norma de Frobenius, $\|A\|_F^2 = \sum_{i,j} A_{ij}^2$
$\mathrm{diag}(S)$	matriz diagonal com a diagonal de S
$A \succ 0$, $A \succeq 0$	A positiva definida, positiva semidefinida

1.4 Símbolos reutilizados com sentidos diferentes

A monografia segue a notação de cada fonte, e alguns símbolos têm mais de um sentido. O contexto resolve a ambiguidade, mas vale tê-los à vista:

símbolo	sentidos
γ	(i) aversão ao risco, Eq. (2.1); (ii) $\hat{\gamma} = \|T - S\|_F^2$ na fórmula de δ; (iii) coeficiente da exposição comum nas Eqs. (3.3) e (3.5)
ρ	(i) correlação; (ii) $\hat{\rho}$, termo de covariância entre alvo e amostra na fórmula de δ
κ	(i) número de condição; (ii) $\hat{\kappa}$ na fórmula de Ledoit-Wolf
m	(i) retorno do mercado m_t; (ii) índice de entidade; (iii) m_i, eventos da ação i
w	(i) vetor de pesos da carteira; (ii) peso de um evento $w_e(t)$ ou de um vínculo w_{ij}
β	(i) coeficientes de regressão; (ii) beta de mercado (no texto, b_i)
N	número de pregões da janela; na expressão "carteira $1/N$", número de ativos (aqui, p)
n	(i) número de ações do universo das mais citadas (50, 100, 200); (ii) contagens n_{im}, n_t no grafo

2 Carteiras

2.1 Média-variância de Markowitz

$$\max_{w} \; w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w \quad \text{sujeito a} \quad w^\top \mathbf{1} = 1. \tag{2.1}$$

símbolo	significado	domínio	unidade
w	vetor de pesos da carteira	$\mathbb{R}^p$, $\sum_i w_i = 1$	adimensional
μ	vetor de retornos esperados	$\mathbb{R}^p$	$[r]$
Σ	matriz de covariância dos retornos	$p \times p$, simétrica, $\succeq 0$	$[r]^2$
γ	aversão ao risco	$\gamma > 0$	$[r]^{-1}$
$w^\top \mu$	retorno esperado da carteira	$\mathbb{R}$	$[r]$
$w^\top \Sigma w$	variância da carteira	≥ 0	$[r]^2$

Resultado. os pesos ótimos $w^* \in \mathbb{R}^p$ (adimensionais). Com só a restrição de orçamento, a solução tem forma fechada:

$$w^* = w_{\mathrm{GMV}} + \frac{1}{\gamma}\Big(\Sigma^{-1}\mu - \frac{\mathbf{1}^\top \Sigma^{-1}\mu}{\mathbf{1}^\top \Sigma^{-1}\mathbf{1}}\,\Sigma^{-1}\mathbf{1}\Big),$$

isto é, a carteira de variância mínima mais uma posição autofinanciada (soma zero) que aposta nos retornos esperados, tanto maior quanto menor a aversão γ.

Leitura. para que a função objetivo tenha unidade de retorno, γ tem unidade inversa de retorno; por isso o valor numérico de γ ($\gamma = 5$ na tese, desenho D4) só tem sentido junto com a escala em que μ e Σ são medidos. Na tese, μ é a média de Bayes-Stein (Jorion, 1986) da janela.

Onde aparece. Seção 2.1 (teoria) e Seção 3.8 (desenho D4, Markowitz).

2.2 Carteira de variância mínima global (GMV)

$$w_{\mathrm{GMV}} = \frac{\Sigma^{-1}\mathbf{1}}{\mathbf{1}^\top \Sigma^{-1}\mathbf{1}}. \tag{2.2}$$

símbolo	significado	domínio	unidade
Σ^{-1}	matriz de precisão (inversa da covariância)	$p \times p, \succ 0$	$[r]^{-2}$
$\mathbf{1}^\top\Sigma^{-1}\mathbf{1}$	soma de todos os elementos da precisão (escalar)	> 0	$[r]^{-2}$

Resultado. os pesos da carteira de menor variância entre todas com $\sum_i w_i = 1$, em $\mathbb{R}^p$, adimensionais (as unidades $[r]^{-2}$ do numerador e do denominador se cancelam). A variância mínima atingida é $1/(\mathbf{1}^\top\Sigma^{-1}\mathbf{1})$, em $[r]^2$. É a solução de (2.1) no limite $\gamma \to \infty$, ou com μ ignorado. Na Introdução aparece como $w \propto \Sigma^{-1}\mathbf{1}$.

Leitura. na prática, Σ é substituída por uma estimativa $\hat{\Sigma}$; como a GMV inverte a matriz, os menores autovalores de $\hat{\Sigma}$, os mais mal estimados, dominam os pesos. É por isso que a GMV é o "laboratório" para comparar estimadores: o melhor $\hat{\Sigma}$ tende a dar a menor variância realizada (Engle e Colacito, 2006). Nos universos das carteiras ($n = 50$, 100 e 200 ações, com $N = 252$), há sempre mais observações que ações, e a covariância amostral é invertível. A versão restrita (sem venda a descoberto e com teto de 10% por ativo) não tem forma fechada e é resolvida por gradiente projetado (FISTA).

Onde aparece. Seções 1.1, 2.1, 3.8; carteira principal de todos os desenhos.

2.3 Máxima diversificação

Em linha no texto: Seção 2.1.

$$\max_{w}\ \mathrm{DR}(w) = \frac{w^\top\sigma}{\sqrt{w^\top\Sigma w}}$$

símbolo	significado	domínio	unidade
σ	vetor de volatilidades individuais, $\sigma_i = \sqrt{\Sigma_{ii}}$	$\mathbb{R}^p_+$	$[r]$
$w^\top\sigma$	média ponderada das volatilidades	$\mathbb{R}$	$[r]$
$\sqrt{w^\top\Sigma w}$	volatilidade da carteira	≥ 0	$[r]$

Resultado. a razão de diversificação $\mathrm{DR} \geq 1$ (para pesos não negativos), adimensional. Vale 1 se todos os ativos forem perfeitamente correlacionados; cresce quanto mais a combinação reduz o risco em relação à soma dos riscos individuais.

Leitura. é um problema de razão; com restrições, foi reescrito como programa convexo pela mudança de variáveis homogênea (Cornuéjols e Tütüncü, 2007) e resolvido por pontos interiores. Desenho D6.

2.4 Mínimo *tracking error*

Em linha no texto: Seções 2.1 e 3.8.

$$\min_{w}\ \mathrm{Var}\big(w^\top r_t - r_t^{\mathrm{SPY}}\big) = w^\top\Sigma w - 2\,w^\top\sigma_{\cdot b} + \sigma_b^2$$

símbolo	significado	domínio	unidade
r_t^{SPY}	retorno do índice de referência (ETF SPY)	$\mathbb{R}$	$[r]$
$\sigma_{\cdot b}$	vetor de covariâncias entre cada ativo e o índice	$\mathbb{R}^p$	$[r]^2$
σ_b^2	variância do índice	>0	$[r]^2$

Resultado. os pesos que minimizam a variância do retorno ativo (o *tracking error* ao quadrado, em $[r]^2$). A métrica do desenho D8 é a razão entre as variâncias do retorno ativo de duas carteiras (adimensional). O resultado relatado é $+21\%$ de variância ativa com notícias.

2.5 HRP: distância e bissecção

Em linha no texto: Seções 2.3 (Mantegna, 1999) e 3.8.

$$d_{ij} = \sqrt{2(1-\rho_{ij})}$$

símbolo	significado	domínio	unidade
ρ_{ij}	correlação entre os ativos i e j	$[-1,1]$	adimensional
d_{ij}	distância de correlação	$[0,2]$	adimensional

Resultado. uma métrica: $d_{ij}=0$ para ativos perfeitamente correlacionados, $\sqrt{2}$ para descorrelacionados, 2 para perfeitamente anticorrelacionados. É a base da árvore geradora mínima e do agrupamento hierárquico da HRP. Na HRP, cada bissecção divide o capital entre os dois grupos L e R por

$$\alpha = 1 - \frac{V_L}{V_L+V_R}, \qquad V_g = \tilde{w}_g^{\top}\Sigma_g\tilde{w}_g,\ \ \tilde{w}_g \propto 1/\operatorname{diag}(\Sigma_g),$$

em que V_g é a variância (em $[r]^2$) da carteira de inverso da variância dentro do grupo; o grupo de menor variância recebe mais capital. A HRP do desenho D7 usa $d_{ij}=\sqrt{(1-\rho_{ij})/2}\in[0,1]$, a mesma distância dividida por 2, que produz a mesma árvore.

3 Estimação da matriz de covariância

3.1 Covariância amostral

Em linha no texto: Seção 2.2.1.

$$S = \frac{1}{N-1}\sum_{t=1}^{N}(r_t-\bar{r})(r_t-\bar{r})^{\top}$$

símbolo	significado	domínio	unidade
r_t	vetor de retornos dos p ativos no pregão t	$\mathbb{R}^p$	$[r]$
$\bar{r}$	média dos retornos na janela	$\mathbb{R}^p$	$[r]$
N	tamanho da janela	inteiro, 252	pregões
S	covariância amostral	$p\times p$, simétrica, $\succeq 0$	$[r]^2$

Resultado. uma estimativa não viesada de Σ, com $p(p+1)/2$ parâmetros distintos (com $p=500$, mais de 125 mil). Seu posto é no máximo $N-1$: com $N<p$, S é singular. O elemento s_{ij} é a covariância diária entre i e j; s_{ii}, a variância diária de i; a correlação amostral é $\hat{r}_{ij}=s_{ij}/\sqrt{s_{ii}s_{jj}}\in[-1,1]$.

3.2 Número de condição

Em linha no texto: Seções 2.2.1 e 3.10.

$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}}$$

Resultado. um número real $\kappa \geq 1$ (adimensional), $+\infty$ se a matriz é singular. Mede quanto a inversão amplifica o erro: um erro relativo ε em $\hat{\Sigma}$ pode virar um erro relativo da ordem de $\kappa\varepsilon$ em $\hat{\Sigma}^{-1}$ e, portanto, nos pesos da GMV. Na tese é calculado sobre a correlação estimada, mês a mês, como diagnóstico (não como critério de sucesso).

3.3 Modelo de fatores

$$\Sigma = B\,F\,B^{\top} + D \tag{2.3}$$

símbolo	significado	domínio	unidade
B	exposições (cargas) dos ativos aos fatores	$p \times k$	$[r]$/[fator]
F	covariância dos fatores	$k \times k, \succeq 0$	[fator]^2
D	variâncias idiossincráticas	$p \times p$ diagonal, $D_{ii} \geq 0$	$[r]^2$
k	número de fatores	$k \ll p$	—

Resultado. uma matriz $p \times p$ em $[r]^2$, positiva semidefinida, com ordem de $pk + k^2 + p$ parâmetros em vez de p^2. Se os fatores são retornos de carteiras (mercado, setores), têm unidade $[r]$ e as cargas são adimensionais (betas). Caso usado na tese: um fator, o mercado, com a covariância residual não diagonal (Eq. 3.8); o alvo de fator único de Ledoit e Wolf é o mesmo modelo com D diagonal.

3.4 *Shrinkage* linear

$$\hat{\Sigma} = \delta\,T + (1-\delta)\,S, \qquad 0 \leq \delta \leq 1 \tag{1.1 e 2.4}$$

símbolo	significado	domínio	unidade
S	covariância amostral	$p \times p, \succeq 0$	$[r]^2$
T	matriz-alvo estruturada	$p \times p, \succeq 0$	$[r]^2$
δ	intensidade do *shrinkage*	[0,1]	adimensional

Resultado. uma combinação convexa de duas matrizes positivas semidefinidas, logo também positiva semidefinida, em $[r]^2$. Com $\delta > 0$ e $T \succ 0$, $\hat{\Sigma}$ é positiva definida e invertível mesmo quando S é singular. $\delta = 0$ devolve a amostra; $\delta = 1$, o alvo. Nos experimentos, os alvos dividem com S as variâncias ($T_{ii} = s_{ii}$) e diferem nas correlações; então δ só move as covariâncias fora da diagonal.

Leitura. δ é escolhido para minimizar $\mathbb{E}\|\hat{\Sigma} - \Sigma\|_F^2$, que soma o viés do alvo e a variância da amostra (Eq. 2.5). Na leitura bayesiana, T é a média de um *prior* e δ a confiança nele. No desenho D1, a intensidade média ficou em torno de 0,2.

3.5 Intensidade ótima de Ledoit-Wolf (alvo de correlação constante)

$$\delta^* = \max\left\{0,\ \min\left\{\frac{\hat{\kappa}}{N}, 1\right\}\right\}, \qquad \hat{\kappa} = \frac{\hat{\pi} - \hat{\rho}}{\hat{\gamma}} \tag{2.5}$$

símbolo	significado	domínio	unidade
$\hat{\pi}$	soma das variâncias assintóticas de $\sqrt{N}s_{ij}$ (ruído da amostra)	≥ 0	$[r]^4$
$\hat{\rho}$	soma das covariâncias assintóticas entre os elementos do alvo e de S	$\mathbb{R}$	$[r]^4$
$\hat{\gamma}$	distância ao quadrado entre alvo e amostra, $\|T-S\|_F^2$ (viés do alvo)	≥ 0	$[r]^4$
$\hat{\kappa}$	razão ruído/viés	$\mathbb{R}$	pregões ^{0} (adim.)
N	tamanho da janela	inteiro	pregões

Resultado. $\delta^* \in [0{,}1]$, adimensional (as unidades $[r]^4$ se cancelam). Cresce com o ruído da amostra ($\hat{\pi}$), cai com a distância ao alvo ($\hat{\gamma}$) e com o tamanho da janela (N): quanto mais longa a história, mais se confia em S. Os cortes em 0 e 1 garantem a combinação convexa.

Leitura. as definições completas dos estimadores estão na forma generalizada (Eq. 3.7, Seção 7.2), da qual esta é o caso de alvo de correlação constante, $r_{ij}^T = \bar{r}$.

4 Avaliação de estimadores e inferência

4.1 Erro de correlação

Em linha no texto: Seção 3.10.

$$L_\rho = \frac{2}{p(p-1)} \sum_{i<j} \left(\hat{\rho}_{ij} - \rho_{ij}^{\text{real}}\right)^2$$

Resultado. $L_\rho \in [0{,}4]$, adimensional: erro quadrático médio entre as correlações estimadas e as realizadas no mês seguinte. A diferença entre dois estimadores é testada na série mensal de L_ρ, com erro-padrão de Newey-West (teste do tipo Diebold-Mariano). No D1, o alvo com setor e notícias teve o menor L_ρ de todos os estimadores (0,09% abaixo da correlação constante), mas não a menor variância da GMV.

4.2 R^2 fora da amostra

Em linha no texto: Seção 3.5.1; Campbell e Thompson, 2008.

$$R^2_{oos} = 1 - \frac{\sum_t \sum_{(i,j)} \left(y_{ij,t} - \hat{y}_{ij,t}\right)^2}{\sum_t \sum_{(i,j)} \left(y_{ij,t} - \bar{y}_t\right)^2}$$

símbolo	significado	domínio	unidade
$y_{ij,t}$	correlação futura do par em escala z, $z(\rho_{ij}^{\text{fut}})$	$\mathbb{R}$	adimensional
$\hat{y}_{ij,t}$	previsão com coeficientes estimados só nos meses anteriores (janela expansiva)	$\mathbb{R}$	adimensional
$\bar{y}_t$	média transversal de y no mês t	$\mathbb{R}$	adimensional

Resultado. um número ≤ 1, adimensional, frequentemente relatado em pontos de R^2. Positivo quando a previsão erra menos que a média do mês; pode ser negativo. Como y e os regressores são centrados no mês, o R^2_{oos} mede só a capacidade de *ordenar* os pares dentro de cada mês, e não o nível médio da correlação.

Leitura. o "ganho" das tabelas do Capítulo 6 é a diferença de R^2_{oos} entre duas especificações. Exemplo: notícias sobre persistência e setor, $+0{,}0033$ ($t = 4{,}3$) na correlação total, cerca de três décimos de ponto de R^2.

4.3 Fama-MacBeth com Newey-West

Em linha no texto: Seção 3.5.3.

$$\hat{\beta}_t = \arg\min_{\beta} \sum_{(i,j)} \big(y_{ij,t} - x_{ij,t}^{\top}\beta\big)^2, \qquad \bar{\beta} = \frac{1}{M}\sum_{t=1}^{M} \hat{\beta}_t, \qquad t_{\bar{\beta}} = \frac{\bar{\beta}}{\sqrt{\widehat{\mathrm{LRV}}/M}}$$

$$\widehat{\mathrm{LRV}} = \hat{\gamma}_0 + 2\sum_{L=1}^{\bar{L}} \Big(1 - \frac{L}{\bar{L}+1}\Big)\hat{\gamma}_L, \qquad \bar{L} = 3 + h/21$$

símbolo	significado	domínio	unidade
$\hat{\beta}_t$	coeficientes da regressão transversal do mês t	$\mathbb{R}^K$	unid. de y por d.p. de x
M	número de meses	156 (2011–2023)	meses
$\hat{\gamma}_L$	autocovariância de ordem L da série $\hat{\beta}_t$	$\mathbb{R}$	(unid. de β)^2
$\bar{L}$	defasagens de Newey-West	4 (h=21), 6 (h=63), 9 (h=126)	meses

Resultado. $\bar{\beta}$ é o efeito médio; como os regressores são padronizados no mês, cada coeficiente mede a variação de $z(\rho)$ (adimensional) por um desvio-padrão do regressor. $t_{\bar{\beta}}$ é adimensional e comparado com a normal. Rodar uma regressão por mês elimina a dependência entre pares do mesmo mês; o Newey-West corrige a autocorrelação entre meses, que existe porque os períodos futuros se sobrepõem quando $h > 21$.

Leitura. exemplo: aresta direta com sinal, $\bar{\beta} = -0{,}0016$ ($t = -9{,}1$); exposição comum, $+0{,}0038$ ($t = +11{,}1$).

4.4 QAP (permutação de nós)

Em linha no texto: Seção 3.5.3.

$$p_{\mathrm{QAP}} = \frac{1 + \#\{b :\ T^{(b)} \geq T^{\mathrm{obs}}\}}{1 + B}$$

Resultado. um p-valor em $[1/(1+B), 1]$. Cada réplica b permuta juntas as linhas e colunas de todas as matrizes de notícia do mês (os rótulos das ações), preservando a estrutura de dependência entre os pares, e refaz o Fama-MacBeth; T é a estatística do teste (o coeficiente médio, em H1a e no sinal; a estatística de Wald, em H1b). Com $B = 1.000$ permutações, o piso é $1/1001 \approx 0{,}001$. O p de cada teste é o maior entre o de Fama-MacBeth e o do QAP. Em H1a, o maior coeficiente médio sob permutação é 0,0002, contra 0,0038 observado ($p = 0{,}001$); em H1b, a maior estatística de Wald sob permutação é 30,3, contra 77,9 ($p = 0{,}001$).

4.5 Teste de Wald da igualdade de coeficientes (H1b)

Em linha no texto: Tabela 3.2.

$$W = (R\bar{\beta})^{\top}\big(R\,\hat{V}_{NW}\,R^{\top}\big)^{-1}(R\bar{\beta}) \ \sim\ \chi^2_q$$

Resultado. estatística $W \geq 0$, adimensional. R é a matriz $(q \times K)$ de contrastes que impõe $\beta_1 = \cdots = \beta_6$ (logo $q = 5$), $\hat{V}_{NW}$ a covariância de Newey-West de $\bar{\beta}$. Valor relatado: $W = 77{,}9$, p QAP $= 0{,}001$ ($p = 0{,}003$ com Bonferroni para as três hipóteses): H1b confirmada.

4.6 Razão de variâncias e *bootstrap* em blocos

Em linha no texto: Seção 3.10.

$$\mathrm{RV} = \frac{\hat{\sigma}_A^2}{\hat{\sigma}_B^2}, \qquad p = \Pr^*\Big(\big|\log \mathrm{RV}^* - \log \mathrm{RV}\big| \geq |\log \mathrm{RV}|\Big)$$

símbolo	significado	domínio	unidade
$\hat{\sigma}_A^2$,$\hat{\sigma}_B^2$	variâncias dos retornos diários líquidos das carteiras A (com notícias) e B (referência) nos mesmos pregões	> 0	$[r]^2$
RV^*	a razão recalculada numa reamostragem em blocos circulares de 10 pregões (2.000 réplicas)	> 0	adimensional

Resultado. $\mathrm{RV} > 0$, adimensional. $\mathrm{RV} < 1$: a carteira com notícias tem menos risco. O intervalo de confiança de 95% são os quantis 2,5% e 97,5% de RV^*, e o p é bicaudal. Reamostrar *blocos* de dias, nos dois retornos ao mesmo tempo, preserva a dependência temporal e a correlação entre as carteiras. Exemplos: no D2 ($n = 100$), $\mathrm{RV} = 1{,}001$ ($p = 0{,}89$), empate com o setor; no D9, $\mathrm{RV} = 1{,}143$ ($p = 0{,}015$), isto é, 14% mais variância com notícias.

4.7 Índice de Sharpe

Em linha no texto: Seções 2.7 e 3.10.

$$\mathrm{SR} = \frac{252\,\overline{(r_t - r_f)}}{\sqrt{252}\,\hat{\sigma}(r_t)}$$

Resultado. índice de Sharpe anualizado: retorno anual por unidade de volatilidade anual. Na tese, $r_f = 0$ e os retornos são líquidos de custos. A diferença de Sharpe entre duas carteiras (desenhos D4 e D5) é testada pelo mesmo *bootstrap* em blocos da razão de variâncias.

4.8 Correções para múltiplos testes

Bonferroni sequencial (desenhos D2, D3, D9...): o k-ésimo desenho para a mesma hipótese usa $\alpha_k = 0{,}05/k$ (por isso os critérios $p < 0{,}025$, $0{,}01$ e $0{,}0125$ da Tabela 3.3).

Benjamini-Hochberg (coeficientes de grupo de H1b):

$$p_{(k)}^{\mathrm{BH}} = \min_{l \geq k} \; \min\Big\{1,\, \frac{m}{l}\, p_{(l)}\Big\},$$

que controla a fração esperada de falsos positivos entre as rejeições (FDR), menos conservadora.

Os p-valores são probabilidades em $[0{,}1]$, adimensionais.

5 O grafo de notícias

5.1 A tupla extraída

$$(\text{agent_a, agent_b, relation_type, direction, strength}) \tag{5.1}$$

símbolo	significado	domínio	unidade
agent_a	agente que age	texto (nome)	—
agent_b	agente que recebe o efeito	texto (nome)	—
relation_type	ação, expressão verbal livre; agrupada depois em 16 classes c_e	texto	—
direction	efeito sobre agent_b	{positivo, negativo} $\to \mathrm{sgn}_e \in \{-1, +1\}$	—
strength	força e certeza do efeito	[0,1]	adimensional

Resultado. não é uma equação numérica, mas define o evento: cada tupla limpa vira um evento e datado pela publicação do artigo, t_e, com peso bruto $\mathrm{sgn}_e\, s_e \in [-1{,}1]$ ("$w = \pm$força", Seção 5.6). Faixas do prompt: 0,8–1,0 efeito explícito e material; 0,4–0,7 declarado mas modesto; 0,1–0,3 especulativo. No máximo 8 tuplas por artigo.

5.2 Peso de um evento com decaimento

$$w_e(t) = \mathrm{sgn}_e\, s_e\, 0{,}5^{\,(t-t_e)/\tau} \tag{3.1}$$

símbolo	significado	domínio	unidade
sgn_e	sinal (direção) do evento	$\{-1, +1\}$	adimensional
s_e	força atribuída pelo LLM	[0,1]	adimensional
t	data em que o grafo é consultado	data	dias corridos
t_e	data de publicação do artigo	$t - W \le t_e < t$	dias corridos
$t - t_e$	idade do evento	$(0, W]$	dias corridos
τ	meia-vida	90	dias corridos
W	janela do grafo	365	dias corridos

Resultado. $w_e(t) \in [-1{,}1]$, adimensional. O fator $0{,}5^{(t-t_e)/\tau} \in (0{,}1]$ cai à metade a cada τ dias: com $\tau = 90$, um evento de 90 dias pesa 50%, de 180 dias, 25%, e de 365 dias, cerca de 6%. Equivale a $e^{-\ln 2\,(t-t_e)/\tau}$. A condição estrita $t_e < t$ garante que nada publicado no dia da decisão (talvez depois do fechamento) entre nela.

5.3 Vínculo direto, por sinal e por grupo

Em linha no texto: Seção 3.4.2.

$$w_{ij} = \sum_{e \in \mathcal{E}_{ij}} w_e(t), \qquad w_{ij}^{\pm} = \sum_{e \in \mathcal{E}_{ij}:\, \mathrm{sgn}_e = \pm 1} |w_e(t)|, \qquad d_{ij}^{(k)} = \sum_{e \in \mathcal{E}_{ij}:\, c_e \in k} |w_e(t)|$$

símbolo	significado	domínio	unidade
$\mathcal{E}_{ij}$	eventos da janela entre as ações i e j, nos dois sentidos	conjunto	—
w_{ij}	vínculo direto com sinal (simétrico, $w_{ii} = 0$)	$\mathbb{R}$	adim. (soma de forças)
w_{ij}^{+}, w_{ij}^{-}	somas dos módulos dos eventos positivos e negativos	≥ 0	adimensional
k	grupo de classes de relação (cadeia, parceria, concorrência, controle, legal, impacto, outros)	conjunto de classes	—
$d_{ij}^{(k)}$	intensidade do vínculo no grupo k	≥ 0	adimensional

Resultado. matrizes $p \times p$ simétricas. A unidade é "eventos-equivalentes": um evento recente de força 1 vale 1. Os valores não são limitados, porque pares muito citados acumulam muitos eventos (cauda longa). Note que $w_{ij} = w_{ij}^{+} - w_{ij}^{-}$.

5.4 Compressão logarítmica com sinal

Em linha no texto: Seção 3.4.2.

$$\log(1+d), \qquad \operatorname{sgnlog}(w) = \operatorname{sgn}(w)\log(1+|w|)$$

Resultado. $\log(1+d) \in [0,\infty)$ para $d \geq 0$; $\operatorname{sgnlog}(w) \in \mathbb{R}$, com o mesmo sinal de w, contínua, ímpar e igual a 0 em 0. Comprime a cauda longa: $\operatorname{sgnlog}(1) = 0{,}69$, $\operatorname{sgnlog}(10) = 2{,}4$, $\operatorname{sgnlog}(100) = 4{,}6$. É a forma em que os vínculos entram nas regressões de H1b (tipo e sinal das relações). Adimensional.

5.5 Matriz de exposição e IDF

Em linha no texto: Seção 3.4.3.

$$\tilde{A}_{im} = \sum_{e \in \mathcal{E}_{im}} w_e(t), \qquad \mathrm{idf}_m = \log \frac{n_t}{\mathrm{df}_m}$$

símbolo	significado	domínio	unidade
$\tilde{A}$	matriz ações × entidades fora do universo	$p \times M$	adimensional
$\mathcal{E}_{im}$	eventos entre a ação i e a entidade m (exatamente uma ponta no universo)	conjunto	—
n_t	número de empresas com *ticker* presentes no grafo da janela (não só as do universo)	inteiro, milhares	empresas
df_m	número dessas empresas ligadas à entidade m na janela	$1,\ldots,n_t$	empresas
idf_m	peso da coluna m	$[0, \log n_t]$	adimensional (nats)

Resultado. cada coluna de $\tilde{A}$ é multiplicada por idf_m. Uma entidade ligada a todas as empresas tem $\mathrm{idf} = \log 1 = 0$ e some; uma ligada a quase todas ("S&P 500") pesa pouco; uma ligada a poucas ("petróleo", às petroleiras) tem peso alto. É a mesma ideia do TF-IDF em recuperação de informação. A frequência é contada em todas as empresas do grafo, e não só nas do universo, para que o peso de uma entidade não mude com o universo escolhido. Nas regressões do universo das mais citadas, $\tilde{A}$ usa o módulo dos eventos; nos testes de pares, o sinal.

5.6 Exposição comum

$$g_{ij} = \left(\tilde{A}\tilde{A}^{\top}\right)_{ij} = \cos(\tilde{A}_i, \tilde{A}_j) = \frac{\sum_m \tilde{A}_{im}\tilde{A}_{jm}}{\|\tilde{A}_i\|\,\|\tilde{A}_j\|} \tag{3.2}$$

símbolo	significado	domínio	unidade
$\tilde{A}_i$	linha i de $\tilde{A}$ (perfil de exposição da ação i), ponderada pelo IDF	$\mathbb{R}^M$	adimensional
g_{ij}	exposição comum entre i e j	$[-1,1]$ (sinal) ou $[0,1]$ (módulo)	adimensional
G	matriz das exposições comuns (projeção do grafo bipartido ações–entidades)	$p \times p$, $\succeq 0$	adimensional

Resultado. o cosseno entre os perfis de duas ações. A igualdade $(\tilde{A}\tilde{A}^{\top})_{ij} = \cos$ vale porque as linhas de $\tilde{A}$ são normalizadas para norma 1 antes do produto. $g_{ij} = 1$: as duas ações estão ligadas às mesmas entidades, nas mesmas proporções e com os mesmos sinais; 0: não compartilham nenhuma entidade;

negativo (só na versão com sinal): compartilham entidades com efeitos opostos (o Fed favorece uma e prejudica a outra). Uma ação sem exposição tem linha nula e $g_{ij} = 0$ para $j \neq i$.

Leitura. g_{ij} entra como regressor (Eqs. 3.3 e 3.5), e não diretamente como correlação: em média, vale cerca de 0,001 no universo do S&P 500, onde só 18,9% dos pares têm $g_{ij} \neq 0$, enquanto a correlação dos retornos vale 0,3 a 0,5. A regressão converte a exposição comum na escala da correlação. Resultado-chave: coeficiente $+0{,}0038$ ($t = 11{,}1$) na previsão da correlação residual, o teste de H1a; e R^2 médio de apenas 0,017 na regressão de g_{ij} nos indicadores de setor, isto é, a exposição comum não é o setor disfarçado.

5.7 Controles de atenção

Em linha no texto: Seção 3.4.4.

$$\log(1 + m_i) + \log(1 + m_j), \qquad |\log(1 + m_i) - \log(1 + m_j)|$$

Resultado. dois regressores ≥ 0, adimensionais, em que m_i é o número de eventos da ação i na janela (contagem). O primeiro mede a atenção total do par; o segundo, a assimetria de atenção. Os coeficientes estimados foram nulos (0,0000 e $-0{,}0002$).

6 Previsão de correlação e testes diádicos

6.1 Transformação de Fisher

Em linha no texto: Seção 3.5.1.

$$z(\rho) = \operatorname{atanh}(\rho) = \frac{1}{2} \ln \frac{1 + \rho}{1 - \rho}, \qquad \rho = \tanh(z)$$

Resultado. leva $\rho \in (-1{,}1)$ a $z \in \mathbb{R}$, adimensional. Para correlações amostrais de n observações sob normalidade, $\operatorname{Var}(z) \approx 1/(n-3)$, independente de ρ: a escala estabiliza a variância, de modo que pares com correlação alta e baixa entram na regressão com ruído comparável. Perto de zero, $z \approx \rho$. No código, ρ é truncada em $\pm 0{,}999$ ($|z| \leq 3{,}8$).

6.2 Regressão preditiva da correlação

$$z(\rho_{ij}^{\text{fut}}) = a + b\, z(\rho_{ij}^{\text{hist}}) + \sum_k \beta_k \log\bigl(1 + d_{ij}^{(k)}\bigr) + \gamma\, g_{ij} + \theta^\top x_{ij} + \varepsilon_{ij} \tag{3.3}$$

símbolo	significado	domínio	unidade
ρ_{ij}^{fut}	correlação realizada no período de carteira seguinte (h pregões)	$(-1,1)$	adimensional
ρ_{ij}^{hist}	correlação nos 252 pregões anteriores a t	$(-1,1)$	adimensional
a	intercepto	$\mathbb{R}$	adimensional
b	persistência da correlação	$\mathbb{R}$ (esperado em $(0,1)$)	adimensional
β_k	efeito do grupo de relação k	$\mathbb{R}$	z por unidade de $\log(1+d)$
γ	efeito da exposição comum	$\mathbb{R}$	z por unidade de g
x_{ij}	controles: coocorrência, co-menção, mesmo setor FF49, mesmo SIC2	vetor	contagens, indicadores 0/1
θ	coeficientes dos controles	$\mathbb{R}^{\dim x}$	z por unidade de x
ε_{ij}	erro	$\mathbb{R}$	adimensional

Resultado. a previsão $\hat{z}_{ij}$ (adimensional) e, por $\tanh$, a correlação prevista em $(-1,1)$. Os coeficientes traduzem cada tipo de relação em correlação. A escada E0–E4 adiciona os blocos de regressores um a um; o ganho de E4 sobre E0 (ambos com setor) é o que as notícias acrescentam. $b < 1$ captura a reversão parcial da correlação à média, o resultado de Elton e Gruber (1973).

6.3 Fator de mercado e correlação residual

$$x_{it} = a_i + b_i\, m_t + e_{it} \tag{3.4}$$

símbolo	significado	domínio	unidade
x_{it}	retorno da ação i no pregão t	$\mathbb{R}$	$[r]$
m_t	retorno do mercado: média igual dos retornos do universo no dia	$\mathbb{R}$	$[r]$
a_i	intercepto (alfa diário)	$\mathbb{R}$	$[r]$
b_i	beta de mercado	$\mathbb{R}$ (típico 0,5–1,5)	adimensional
e_{it}	resíduo (parte idiossincrática)	$\mathbb{R}$	$[r]$

Resultado. $\hat{b}_i = \widehat{\mathrm{Cov}}(x_i,m)/\widehat{\mathrm{Var}}(m)$ estimado na janela. A correlação residual realizada é a correlação entre $e_{it} = x_{it} - \hat{a}_i - \hat{b}_i m_t$ e e_{jt} no período seguinte, com os $\hat{b}_i$ da janela e o m_t observado; fica em $(-1,1)$ e é a variável dependente dos testes de pares ($h = 21$ pregões). Ao tirar o mercado, a correlação de dois bancos passa a medir o que eles têm em comum além do mercado.

6.4 Regressão dos testes de pares

$$z(\rho_{e,ij}^{\text{fut}}) = a + b\, z(\rho_{e,ij}^{\text{hist}}) + \gamma\, g_{ij} + \sum_k \beta_k \log\!\big(1 + d_{ij}^{(k)}\big) + \theta^{\top} c_{ij} + \varepsilon_{ij} \tag{3.5}$$

símbolo	significado	domínio	unidade
$\rho^{\mathrm{fut}}_{e,ij}$	correlação residual do par nos $h = 21$ pregões seguintes	$(-1{,}1)$	adimensional
$\rho^{\mathrm{hist}}_{e,ij}$	correlação residual do par na janela de 252 pregões	$(-1{,}1)$	adimensional
g_{ij}	exposição comum, com sinal (Eq. 3.2)	$[-1{,}1]$	adimensional
$d^{(k)}_{ij}$	vínculo direto no grupo k (seis grupos e um residual)	≥ 0	adimensional
c_{ij}	controles: mesmo setor FF49, mesmo SIC2, distância de tamanho, atenção (soma e diferença)	vetor	indicadores e logs
γ, β_k, θ	coeficientes, com os regressores padronizados no mês	$\mathbb{R}$	z por desvio-padrão

Resultado. uma regressão por mês no universo do S&P 500 (155 meses, 12,2 milhões de pares-mês), com a média dos coeficientes e a inferência de Fama-MacBeth e do QAP. H1a é o teste de $\gamma > 0$: $+0{,}0038$, $t = 11{,}1$, isto é, um desvio-padrão a mais de exposição comum corresponde a 0,004 a mais de correlação (em escala z). H1b é o teste de igualdade dos seis β_k. Na análise do sinal, a soma sobre os grupos é trocada por $\beta\,\mathrm{sgnlog}(w_{ij})$ ou pelos dois termos da subseção seguinte.

Leitura. difere da Eq. (3.3) em três pontos: a correlação é a residual ao mercado, o universo não é escolhido pelas notícias, e a inferência é feita mês a mês, e não fora da amostra. As duas se complementam: a (3.3) mede quanto a previsão melhora; a (3.5), qual atributo carrega o efeito.

6.5 Arestas positivas e negativas (sinal, em H1b)

Em linha no texto: Seção 3.5.3, depois da Eq. (3.5).

$$y_{ij} = \cdots + \beta^{+}\log(1 + w^{+}_{ij}) + \beta^{-}\log(1 + w^{-}_{ij}), \qquad H_0 :\ \beta^{+} - \beta^{-} \leq 0$$

Resultado. coeficientes em escala z por desvio-padrão do regressor. Se o sinal do LLM indicasse a direção do co-movimento, β^{+} seria positivo e maior que β^{-}. Resultado: $\beta^{+} = +0{,}0010$, $\beta^{-} = +0{,}0025$, diferença $-0{,}0015$ ($t = -7{,}3$). As duas formas de aresta elevam a correlação, e as negativas, quase todas de concorrência, elevam mais: o sinal descreve o efeito econômico de uma empresa sobre a outra, não a direção do co-movimento.

7 Estimadores da matriz de covariância com notícias

7.1 Alvo de correlação a partir das notícias

$$R^{T}_{ij} = \tanh\big(\bar{z} + \beta^{\top} f_{ij}\big), \qquad R^{T}_{ii} = 1 \tag{3.6}$$

símbolo	significado	domínio	unidade
$\bar{z}$	correlação média da janela em escala z	$\mathbb{R}$	adimensional
f_{ij}	atributos de notícia (e de setor) do par	$\mathbb{R}^K$	como na Eq. (3.3)
β	coeficientes estimados por MQO no painel dos meses anteriores, com y e f centrados no mês	$\mathbb{R}^K$	z por unidade de f
R^T	correlação-alvo	$p \times p$, $R^T_{ij} \in (-1{,}1)$	adimensional

Resultado. uma matriz simétrica com diagonal 1 e elementos em $(-1{,}1)$. O $\tanh$ volta da escala z para a de correlação. Com $\beta = 0$, é a correlação constante $\tanh(\bar{z})$ de Ledoit-Wolf. Como uma matriz assim montada pode não ser positiva semidefinida, é substituída pela correlação válida mais próxima (Higham,

2002). A covariância-alvo é $T = D^{1/2} R^T D^{1/2}$, com $D = \mathrm{diag}(S)$, isto é, $T_{ij} = R^T_{ij}\sqrt{s_{ii}s_{jj}}$ em $[r]^2$: correlações das notícias, variâncias dos preços.

Leitura. a correlação histórica do par fica de fora de f_{ij} de propósito: a fórmula de δ supõe um alvo que não depende da amostra S.

7.2 Intensidade ótima generalizada

$$\begin{aligned}
\hat{\pi} &= \sum_{i,j} \hat{\pi}_{ij}, \qquad \hat{\pi}_{ij} = \frac{1}{N}\sum_{t=1}^{N} \big[(r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j) - s_{ij}\big]^2, \qquad \hat{\gamma} = \|T - S\|_F^2, \\
\hat{\rho} &= \sum_i \hat{\pi}_{ii} + \sum_{i \neq j} \frac{r^T_{ij}}{2}\left(\sqrt{\frac{s_{jj}}{s_{ii}}}\,\hat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}}\,\hat{\vartheta}_{jj,ij}\right), \\
\delta^* &= \max\left\{0,\ \min\left\{\frac{\hat{\pi} - \hat{\rho}}{N\hat{\gamma}}, 1\right\}\right\},
\end{aligned} \tag{3.7}$$

com

$$\hat{\vartheta}_{ii,ij} = \frac{1}{N}\sum_{t=1}^{N} \big[(r_{it} - \bar{r}_i)^2 - s_{ii}\big]\big[(r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j) - s_{ij}\big].$$

símbolo	significado	domínio	unidade
$\hat{\pi}_{ij}$	variância assintótica estimada de $\sqrt{N}s_{ij}$	≥ 0	$[r]^4$
$\hat{\pi}$	ruído total da amostra	≥ 0	$[r]^4$
$\hat{\vartheta}_{ii,ij}$	covariância assintótica entre $\sqrt{N}s_{ii}$ e $\sqrt{N}s_{ij}$	$\mathbb{R}$	$[r]^4$
r^T_{ij}	correlação-alvo do par ($= R^T_{ij}$)	$(-1,1)$	adimensional
$\hat{\rho}$	quanto do ruído da amostra também está no alvo	$\mathbb{R}$	$[r]^4$
$\hat{\gamma}$	viés do alvo (distância à amostra)	≥ 0	$[r]^4$
δ^*	intensidade ótima	$[0,1]$	adimensional

Resultado. $\delta^* \in [0,1]$, adimensional. Por que há $\hat{\rho}$: o alvo usa as variâncias amostrais s_{ii}, então parte do erro de S também está em T; $\hat{\rho}$ desconta esse erro comum (na diagonal, alvo e amostra coincidem, e o termo $\sum_i \hat{\pi}_{ii}$ anula a contribuição dela a $\hat{\pi}$). A única mudança em relação a Ledoit e Wolf (2004) é trocar a correlação constante $\bar{r}$ pela correlação-alvo de cada par, r^T_{ij}. A mesma fórmula serve ao alvo de setor, ao alvo de notícias (D1) e ao *shrinkage* da covariância residual (Eq. 3.8, D2 a D8). Nessas fórmulas, S usa o divisor N. A intensidade só é grande quando o alvo está perto da amostra: por isso os alvos partem da correlação média da janela ($\bar{z}$), que preserva o modo de mercado. No D1, $\delta \approx 0{,}2$.

7.3 Fator de mercado mais resíduo encolhido

$$\hat{\Sigma} = \hat{\sigma}_m^2\, b\, b^\top + \hat{\Sigma}_e \tag{3.8}$$

símbolo	significado	domínio	unidade
$\hat{\sigma}_m^2$	variância do retorno de mercado m_t na janela	> 0	$[r]^2$
b	vetor de betas da Eq. (3.4)	$\mathbb{R}^p$	adimensional
$\hat{\Sigma}_e$	covariância dos resíduos E, encolhida para R_{prior} pela Eq. (3.7)	$p \times p$, $\succeq 0$	$[r]^2$
R_{prior}	correlação residual *a priori*: I, $\bar{r}_e$, setor, setor+notícias, placebo	correlação	adimensional

Resultado. uma covariância $p \times p$ em $[r]^2$, caso particular da Eq. (2.3) com um fator. O primeiro termo (posto 1) é o risco de mercado; o segundo, o risco específico e o que os pares compartilham além do

mercado. Os estimadores do desenho D2 diferem *só* em R_{prior}; a comparação "setor+notícias contra setor" isola o valor das notícias. Na versão com notícias, $R_{\text{prior},ij} = \tanh(\bar{z}_e + \beta^\top [\text{setor,notícias}])$, com β ajustado à correlação residual realizada.

7.4 Black-Litterman na covariância

Incerteza do *prior* (Wishart)

$$V_{(ij),(kl)} = \frac{\sigma_{0,ik}\,\sigma_{0,jl} + \sigma_{0,il}\,\sigma_{0,jk}}{N} \tag{3.9}$$

símbolo	significado	domínio	unidade
Σ_0	covariância residual do prior (modelo com setor)	$p \times p$, $\succ 0$	$[r]^2$
$\sigma_{0,ik}$	elemento (i,k) de Σ_0	$\mathbb{R}$	$[r]^2$
N	número de pregões da janela	252	pregões
V	covariância entre os elementos de $\operatorname{vec}\Sigma_0$	$p^2 \times p^2$, $\succeq 0$	$[r]^4$

Resultado. $V_{(ij),(kl)} = \operatorname{Cov}(s_{ij}, s_{kl})$ para uma covariância amostral de N observações normais com covariância Σ_0. Em particular, $\operatorname{Var}(s_{ij}) = (\sigma_{ii}\sigma_{jj} + \sigma_{ij}^2)/N$. O fator $1/N$ é o análogo da convenção de He e Litterman (1999) de tomar a incerteza do *prior* como o inverso do tamanho da amostra. Por V ter elementos fora da diagonal, uma visão sobre o par (i,j) também move (i,l) e (j,l). Com $p = 100$, V teria 10^8 elementos e nunca é formada: só se usam produtos Vx.

Visões

Em linha no texto: Seção 3.6.3.

$$q_{ij} = \tanh(\hat{z}_{ij})\sqrt{s_i s_j}, \qquad P \operatorname{vec}\Sigma_e = \left(\Sigma_{e,ij}\right)_{(i,j)\in\text{visões}}$$

Resultado. q_{ij} em $[r]^2$: a covariância residual que o modelo de setor+notícias prevê para o par. $\hat{z}_{ij}$ é a previsão em escala z, $s_i = (\Sigma_0)_{ii}$ a variância residual. P é uma matriz de seleção (zeros e uns), de dimensão (número de visões)$\times p^2$, adimensional.

Confiança das visões

$$\omega_c = \overline{\hat{e}^2}\big|_c - \overline{1/(d_m - 3)}, \qquad \omega_c \geq \frac{1}{N-3} \tag{3.10}$$

símbolo	significado	domínio	unidade
c	classe de evidência: 0 (só exposição comum ou co-menção), 1–4 (quartis de coocorrência)	$\{0,\ldots,4\}$	—
$\overline{\hat{e}^2}\big\|_c$	erro quadrático médio da visão em escala z na classe c, nos meses de treino	≥ 0	adimensional (z^2)
d_m	pregões do mês m (com que a correlação realizada é medida)	≈ 21	pregões
$1/(d_m - 3)$	variância do ruído amostral de z com d_m observações	> 0	adimensional
ω_c	variância do erro verdadeiro da visão	$\geq 1/(N-3) \approx 0{,}004$	adimensional

Resultado. a variância do erro da visão, descontado o ruído de medir uma correlação com só $\sim$21 pregões (que inflaria o erro sem ser culpa da visão). O piso $1/(N-3)$ impede confiança maior que a de uma correlação medida com a janela inteira. Levada à escala da covariância pelo método delta:

$$\Omega_{ij} = (1 - \tanh^2 \hat{z}_{ij})^2\, s_i s_j\, \omega_{c(ij)} \quad [[r]^4],$$

pois $\mathrm{d}\tanh(z)/\mathrm{d}z = 1 - \tanh^2 z$. Ω é diagonal (visões com erros independentes).

Posterior

$$\operatorname{vec}\Sigma_e^{BL} = \operatorname{vec}\Sigma_0 + VP^\top\big(PVP^\top + \Omega\big)^{-1}\big(q - P\operatorname{vec}\Sigma_0\big) \tag{3.11}$$

Resultado. a média posterior da covariância residual, em $[r]^2$. Lê-se como um filtro de Kalman: $q - P\operatorname{vec}\Sigma_0$ é a "surpresa" (o que as notícias dizem menos o que o prior diz, em $[r]^2$); $VP^\top(PVP^\top+\Omega)^{-1}$ é o ganho (adimensional: $[r]^4 \cdot [r]^{-4}$), próximo de 1 quando a visão é precisa (Ω pequeno diante de $PVP^\top$) e próximo de 0 quando é ruidosa. Cada par recebe assim a confiança que a sua evidência justifica, ao contrário de um δ único. O sistema é resolvido por gradiente conjugado, e o resultado é projetado na correlação positiva semidefinida mais próxima. Desenho D9: $+14\%$ de variância ($p = 0{,}015$).

8 Métricas de resultado das carteiras

métrica	definição	domínio e unidade
volatilidade anual	$\sqrt{252}\,\hat\sigma(r_t)$, com r_t o retorno diário líquido de custos	≥ 0; % ao ano
retorno anual	$252\,\bar r$	$\mathbb{R}$; % ao ano
Sharpe	$252\,\overline{(r_t - r_f)}\,/\,(\sqrt{252}\,\hat\sigma)$	$\mathbb{R}$; adimensional
perda máxima	$\min_t\big(V_t/\max_{s\leq t} V_s - 1\big)$, $V_t = \prod_{s\leq t}(1+r_s)$	$[-1{,}0]$; %
giro	$\sum_i \lvert w_i^{\text{alvo}} - w_i^{\text{deriva}}\rvert$ por rebalanceamento; "giro/ano" soma os do ano	$[0{,}2]$ por troca; vezes o patrimônio
custo	$c\times$giro, $c = 10$ pontos-base $= 0{,}001$	≥ 0; fração do patrimônio
razão de variâncias	$\hat\sigma^2_{\text{modelo}}/\hat\sigma^2_{\text{referência}}$	> 0; adimensional, < 1 favorece o modelo

Leitura. w^{deriva} são os pesos que a carteira teria depois de variar com os preços desde o último rebalanceamento: $w_i^{\text{deriva}} = w_i\prod(1+r_i)/\sum_k w_k\prod(1+r_k)$; é contra eles que o giro e o custo são cobrados. No desenho D8, por exemplo, o giro do mínimo *tracking error* sobe de 3,3 para 4,0 vezes o patrimônio por ano quando as notícias entram na matriz.

Referências citadas neste guia

As referências completas estão em `monografia/referencias.bib`. Citadas aqui: Campbell e Thompson (2008); Cornuéjols e Tütüncü (2007); Elton e Gruber (1973); Engle e Colacito (2006); He e Litterman (1999); Higham (2002); Jorion (1986); Ledoit e Wolf (2004, *Honey*); Mantegna (1999).