Grafos de notícias extraídos por LLM e a estimação da matriz de covariância

Guia de escrita: resumo do que foi feito, referências, revisão bibliográfica, metodologia e resultados

Gabriel Vaz Cançado Ferreira
Projeto NewsManager — TCC em Finanças

Estado em 10 de novembro de 2026

Resumo

Este documento reúne, num só lugar, tudo o que o projeto produziu até agora, para servir de roteiro à redação do texto final. Um modelo de linguagem local (`qwen2.5:14b-instruct`) leu 572.762 artigos do corpus FNSPID (cerca de 36% do corpus elegível) e extraiu 1.270.582 relações tipadas, com sinal e força, entre agentes econômicos. As relações foram ligadas a tickers e organizadas num grafo dinâmico com 255.384 nós e 1.064.801 eventos limpos (2011–2023). A pergunta da tese é se esse grafo melhora a estimação da matriz de covariância dos retornos e, por meio dela, as carteiras. O resultado se divide em dois. *Do lado estatístico*, as notícias preveem a correlação futura entre pares de ações além da correlação histórica e do setor (H1; t até 9,7 na correlação residual), o tipo de relação importa, a centralidade prevê o beta de baixa e os autovetores do grafo apontam para as direções de risco futuro. *Do lado econômico*, em nenhum dos nove desenhos de carteira testados, todos com critério fixado antes de rodar, a informação das notícias reduziu de forma significativa a variância realizada nem melhorou o Sharpe; em alguns casos piorou. O documento descreve os dados, a extração, o método, os resultados, os desvios declarados e o que ainda falta.

Sumário

1 Como usar este guia **3**

2 Introdução e pergunta de pesquisa **3**
2.1 Motivação . . . 3
2.2 Pergunta central . . . 3
2.3 Contribuição . . . 4

3 Revisão bibliográfica **4**
3.1 Estimar Σ: o problema do erro de estimação . . . 4
3.2 Redes em finanças . . . 5
3.3 Vínculos econômicos, texto e notícias . . . 5
3.4 Os três trabalhos que ligam texto a Σ (núcleo da revisão) . . . 5
3.5 LLM e grafos de empresas . . . 5
3.6 Lacuna . . . 6
3.7 Avaliação e inferência . . . 6

4 Dados **6**
4.1 Corpus de notícias: FNSPID . . . 6
4.2 Preços . . . 7
4.3 Universos . . . 7

5 Extração de relações com LLM e construção do grafo **8**
5.1 Tarefa e esquema 8
5.2 Escolha do modelo 8
5.3 Execução 8
5.4 Filtro de ruído 8
5.5 Ligação de entidades a tickers 9
5.6 O grafo dinâmico 9

6 Metodologia **10**
6.1 Disciplina contra *data snooping* 10
6.2 Hipóteses originais 10
6.3 Atributos de par a partir do grafo 10
6.4 Regressão preditiva de correlação (a "ponte" semântica–numérica) 10
6.5 Shrinkage para um alvo fixo de notícias 11
6.6 Os desenhos de carteira (H2) 11
6.7 O programa da seção 18 (roteiro de grafos) 12

7 Resultados **13**
7.1 H1: as notícias preveem a correlação 13
7.2 H2, desenho D1: alvo-prior 14
7.3 H2, desenhos D2 e D3: fator + resíduo, sem restrição e long-only 14
7.4 H2, desenhos D4–D8: outros otimizadores 15
7.5 H2, desenho D9: Black-Litterman na covariância 15
7.6 Programa da seção 18: validação da extração 16
7.7 Programa da seção 18: descritivas do grafo 16
7.8 Programa da seção 18: testes diádicos 16
7.9 Programa da seção 18: dev e holdout 17

8 Discussão **18**

9 Limitações e desvios declarados **19**

10 O que falta **19**

11 Estrutura sugerida para o texto final **20**

12 Reprodutibilidade **20**

1 Como usar este guia

- Cada seção corresponde, aproximadamente, a um capítulo da tese. A seção 11 propõe a estrutura final e indica de onde vem cada parte.
- Os números foram copiados dos documentos do repositório, que são a fonte primária: `docs/metodo_covariancia.md` (seções 1–18, com o pré-registro de cada desenho), `docs/secao18_resultados.md`, `README.md` e os logs em `logs/`. Em caso de divergência, valem os arquivos do repositório.
- As notas em *azul* são sugestões de redação; os itens em **vermelho** ainda não foram feitos.
- Nomenclatura: H1–H3 são as hipóteses originais da tese (seção 6.2); G1–G13 são as hipóteses do roteiro `grafo_noticias_covariancia.md`, testadas no programa da seção 18 do método (seção 6.7); M1–M9 e B0–B11 são os modelos e as referências desse programa.
- **Na monografia, o trabalho se concentra em três hipóteses**, investigadas a fundo: H1a (exposição comum), H1b (tipo de relação, que reúne G1–G3) e H2 (carteiras, desenhos D1–D9). O programa de carteiras da seção 18 (D10, M1–M9, B0–B11, placebos P1–P6, holdout) e as hipóteses H3, G4–G13 **não fazem parte do texto**: a revisão de 2026-11-10 (`docs/revisao_monografia.md`) mostrou que o M2 não media o conteúdo das notícias (alvo quase diagonal e singular nas classes de ação). Por decisão do autor, a monografia é um texto conciso (cerca de 60 páginas) que não menciona esses testes nem traz análises de robustez; H1b é relatada com o QAP de 1.000 permutações ($p = 0{,}001$; com Holm sobre a família original de dez testes, $p \leq 0{,}01$). Este guia mantém o registro completo do que foi rodado, com a numeração original.
- O texto da tese está em `monografia/` (`Monografia.tex`, um `.tex` por capítulo). A explicação detalhada de cada equação usada nele, com variáveis, domínios, resultados e unidades de medida, está em `docs/equacoes/equacoes.tex` (PDF ao lado). A notação deste guia segue a da monografia: τ é a meia-vida, $d_{ij}^{(k)}$ o vínculo do grupo k, $\tilde{A}$ a matriz de exposição e g_{ij} a exposição comum.

2 Introdução e pergunta de pesquisa

2.1 Motivação

A carteira de Markowitz (1952) depende da matriz de covariância Σ dos retornos. Com p ativos e N observações, a covariância amostral S tem $p(p+1)/2$ parâmetros: é singular se $N < p$ e mal condicionada se N não for muito maior que p. O otimizador explora justamente os erros de estimação. A literatura respondeu com estrutura (fatores, blocos de setor) e com *shrinkage*, que combina S com um alvo estruturado T. O alvo funciona como um *prior*: é o lugar natural para entrar informação externa aos retornos.

As notícias descrevem vínculos econômicos entre empresas (fornecimento, concorrência, aquisições, processos) e entre empresas e entidades não negociadas (o Fed, o petróleo, a China). Se esses vínculos antecipam co-movimentos, um alvo construído com eles deveria estimar Σ melhor do que alvos puramente estatísticos.

2.2 Pergunta central

> A estrutura relacional extraída das notícias por um LLM contém informação sobre a covariância futura dos retornos que não está (i) na covariância histórica nem (ii) em modelos de fatores e de setor? E essa informação se traduz em carteiras melhores fora da amostra?

2.3 Contribuição

1. **Dados.** Uma base de relações econômicas extraídas por LLM de um corpus público (FNSPID), tipadas, com sinal e força, incluindo entidades não negociadas, ligadas a tickers e organizadas como grafo dinâmico sem *look-ahead*. Até onde a revisão alcançou, não há trabalho que use relações desse tipo para estimar Σ (seção 3.6).
2. **Evidência estatística.** As notícias preveem a correlação futura além da persistência e do setor; a exposição comum a entidades não negociadas é o canal que sobrevive aos controles.
3. **Evidência econômica negativa, robusta e pré-registrada.** Nove desenhos de carteira (alvo-prior, fator + resíduo, long-only com teto, cinco otimizadores, Black-Litterman na covariância, e o programa walk-forward com 33 estimadores) não mostram ganho. A tese explica o mecanismo: o sinal é pequeno, esparso e piora o condicionamento de $\hat{\Sigma}$; com restrições, todos os estimadores com fator empatam.
4. **Método.** Um protocolo de pré-registro incremental (cada desenho é escrito e versionado antes de rodar), placebos de grafo que preservam graus, separação dev/holdout e correção para múltiplos testes, além de testes de vazamento de memória do LLM.

Nota para a escrita: o resultado principal é negativo para H2. Vale defini-lo cedo no texto como achado: "a informação existe, mas não sobrevive à inversão de Σ", com o placebo mostrando que o conteúdo não é ruído.

3 Revisão bibliográfica

3.1 Estimar Σ: o problema do erro de estimação

- Markowitz (1952) fixa o problema; o otimizador maximiza o erro de estimação.
- Kan and Zhou (2007): com muitos ativos, o erro em Σ pesa tanto quanto o erro na média. Por isso a carteira de variância mínima global (GMV), que não usa a média, é o laboratório padrão para comparar estimadores de Σ.
- **Estrutura ajuda.** Elton and Gruber (1973) mostram que impor correlação constante, inclusive por blocos de setor, prevê melhor que a amostral; Chan et al. (1999) chegam a conclusão parecida comparando modelos de risco.
- **Shrinkage linear.** $\hat{\Sigma} = \delta T + (1-\delta)S$ com δ ótimo analítico: identidade escalada (Ledoit and Wolf, 2004b), correlação constante (Ledoit and Wolf, 2004a) e fator único (Ledoit and Wolf, 2003). Pode ser lido como Bayes empírico, com T no papel de *prior*. **É aqui que a tese entra: um prior vindo das notícias.**
- **Shrinkage não linear** (Ledoit and Wolf, 2017, 2020) e **limpeza por matrizes aleatórias** (Laloux et al., 1999; Bun et al., 2017): referências fortes, sem informação externa.
- **Esparsidade e fatores latentes.** Graphical lasso na matriz de precisão (Friedman et al., 2008), que é o objeto que a GMV usa ($w \propto \Sigma^{-1}\mathbf{1}$); POET (Fan et al., 2013), com número de fatores por Bai and Ng (2002) e limiar adaptativo (Cai and Liu, 2011). A variante *weighted glasso* penaliza menos as arestas apoiadas por conhecimento prévio.
- **Correlação dinâmica.** DCC (Engle, 2002); avaliação econômica de previsões de correlação pela variância da carteira (Engle and Colacito, 2006).
- **Restrições como regularização.** Proibir venda a descoberto e impor teto funciona como shrinkage (Jagannathan and Ma, 2003). Isso é central para interpretar os resultados long-only.

- **Instabilidade da inversão.** López de Prado (2016, 2020): o número de condição $\lambda_{\max}/\lambda_{\min}$ mede a fragilidade da GMV; o HRP evita a inversão.

3.2 Redes em finanças

- Redes de correlação filtradas: MST (Mantegna, 1999) e PMFG (Tumminello et al., 2005).
- Ativos periféricos diversificam melhor (Pozzi et al., 2013); os pesos de Markowitz são negativamente ligados à centralidade (Peralta and Zareei, 2016).
- HRP (López de Prado, 2016): agrupamento hierárquico pela correlação antes de alocar.
- Lu et al. (2023) estimam a covariância com uma rede externa aos retornos (co-negociação): clusters espectrais definem os blocos da covariância idiossincrática e superam blocos GICS. **É o precedente metodológico mais próximo de "rede externa → estrutura de Σ"**, embora sem texto.
- Ferramentas de grafo usadas: kernels de difusão (Kondor and Lafferty, 2002), espectro de grafos assinados (Kunegis et al., 2010), Louvain (Blondel et al., 2008), aleatorização com graus fixos (*curveball*) (Strona et al., 2014).

3.3 Vínculos econômicos, texto e notícias

- **Vínculos reais propagam informação**: clientes e fornecedores (Cohen and Frazzini, 2008); indústrias ligadas na cadeia (Menzly and Ozbas, 2010); similaridade textual de produtos nos 10-K, TNIC (Hoberg and Phillips, 2016); vínculos tecnológicos (Lee et al., 2019).
- **Notícias revelam vínculos**: firmas citadas juntas preveem os retornos umas das outras (Scherbina and Schlusche, 2020); a cobertura conjunta gera transbordamento de atenção e co-movimento (Guo et al., 2017).

3.4 Os três trabalhos que ligam texto a Σ (núcleo da revisão)

1. Tang et al. (2019): a co-ocorrência em notícias prevê a correlação futura mesmo controlando a persistência e, incorporada à covariância, melhora a GMV. É a evidência direta de H1, mas usa só co-menção, sem tipo, sinal ou entidades não negociadas. Na tese, a co-menção do FNSPID é o "controle Tang".
2. Becquin and Esmeir (2023): a similaridade semântica (embeddings de descrições ou de grafo de conhecimento) vira **alvo de shrinkage**, não estimador direto, porque é descalibrada: $\mathrm{Sim} = EE^\top$ lida como correlação, $\mathrm{SimCov} = \mathrm{Sim} \odot \sqrt{\mathrm{diag}\, S\, \mathrm{diag}\, S^\top}$, correção de autovalores e δ à Ledoit-Wolf. Testado em S&P 500, Nasdaq-100 e Nikkei (2007–2023). **É o molde técnico seguido aqui.** Formulam também a hipótese de regime (H3).
3. Lu et al. (2024): encolhem a matriz de correlação com aprendizado por reforço usando as redes TNIC; em GMV, com mais de 400 ações e 20 anos, superam os shrinkages padrão, líquidos de custos.

3.5 LLM e grafos de empresas

A linha "LLM → grafo de empresas → GNN" prevê retornos (Zhou et al., 2025, entre outros). O extrator usado aqui é o Qwen2.5 (Qwen Team, 2024) sobre o FNSPID (Dong et al., 2024).

3.6 Lacuna

Não foi encontrado trabalho que use relações **extraídas por LLM, tipadas, com sinal e com entidades macro não negociadas** para estimar Σ. Em relação a Tang et al. (2019), o grafo acrescenta tipo, sinal e exposição comum a entidades; em relação a Becquin and Esmeir (2023), troca a similaridade estática de descrições por relações datadas e dinâmicas.

[Pendente: a revisão de "LLM e grafos" está fraca: completar a referência Zhou et al. (2025) e buscar trabalhos de 2024–2026 sobre LLM em extração de relações financeiras e sobre vazamento de memória ("look-ahead bias") de LLMs em finanças.]

3.7 Avaliação e inferência

- Referência ingênua 1/N (DeMiguel et al., 2009).
- Testes robustos: Sharpe (Ledoit and Wolf, 2008); variância, com bootstrap studentizado em blocos (Ledoit and Wolf, 2011); bootstrap estacionário (Politis and Romano, 1994) com bloco de Politis and White (2004).
- Perdas robustas para previsões de covariância com proxy ruidosa (Patton, 2011); Diebold-Mariano (Diebold and Mariano, 1995) com correção HLN (Harvey et al., 1997); modelos aninhados (Clark and West, 2007); R^2 fora da amostra (Campbell and Thompson, 2008).
- Dados diádicos: Fama-MacBeth (Fama and MacBeth, 1973) com Newey-West (Newey and West, 1987); QAP (Krackhardt, 1988); clusters diádicos (Aronow et al., 2015; Cameron et al., 2011).
- Múltiplos testes e *snooping*: Holm (Holm, 1979), Benjamini-Hochberg (Benjamini and Hochberg, 1995), Reality Check (White, 2000), SPA (Hansen, 2005), MCS (Hansen et al., 2011), Romano-Wolf (Romano and Wolf, 2005), Sharpe deflacionado (Bailey and López de Prado, 2014).
- Black-Litterman (Black and Litterman, 1992; He and Litterman, 1999), aplicado à covariância (Qian and Gorman, 2001), com a incerteza de Wishart (Anderson, 2003); projeção para a correlação mais próxima (Higham, 2002); Bayes-Stein para a média (Jorion, 1986); máxima diversificação (Choueifaty and Coignard, 2008); reformulação convexa homogênea (Cornuéjols and Tütüncü, 2007).

4 Dados

4.1 Corpus de notícias: FNSPID

- Arquivo `nasdaq_exteral_data.csv` do FNSPID (Dong et al., 2024) no Hugging Face: 21,6 GiB (23.232.979.597 bytes), 12 colunas, uma linha por par (artigo, ticker).
- O CSV nunca foi baixado inteiro: a ingestão lê por *HTTP range* em fragmentos independentes e retomáveis (DuckDB), grava Parquet (camadas bruta → curada) e confere o tamanho e o etag do objeto remoto.
- Propriedades medidas que guiaram o desenho:

  1. artigos com quebras de linha dentro de campos entre aspas: a fronteira dos fragmentos usa uma âncora estrutural (quebra de linha seguida de um número e de um timestamp ISO, campos sem aspas) que não ocorre no texto; validada sem nenhuma linha quebrada;
  2. a inferência de tipos do DuckDB lia os 21,6 GB só para escolher tipos: esquema fixo, tudo `VARCHAR`, conversão explícita na curadoria;

3. duplicação por ticker (o mesmo artigo em cada ticker citado): a camada curada separa `documents` de `mentions`, e cada artigo vai uma vez ao LLM;
4. duas eras: artigos recentes da nasdaq.com com resumos extrativos e editor/autor vazios; antigos em formato de agência;
5. depois de ∼17,7 GB, um terceiro formato (índice vazio), 63% das linhas sem ticker, 76% sem corpo, e 799.037 artigos do portal russo lenta.ru (sem nenhum ticker), excluídos da extração. Isso reduziu as unidades de 2.321.501 para **1.607.982**.

- `doc_id` = URL, ou hash do corpo normalizado quando não há URL; deduplicação ano a ano, pulando `doc_id` já gravado (73 artigos sem URL reapareciam em outro ano).
- Data só ao dia: todo `published_at` é meia-noite. Consequência: o grafo em t usa apenas eventos com data $< t$.

4.2 Preços

- `Stock_price/full_history.zip` do próprio FNSPID (7.693 tickers, 1962–2023), conferido pelo sha256 do LFS. A limpeza grava preços diários, qualidade e calendário (2005 em diante).
- Problemas medidos e tratados:

problema	tamanho	tratamento
coletas emendadas (2015-01-02, 2020-04-02, 2020-07-02, 2020-07-06)	22,7 mil retornos	retorno do dia inválido
lote antigo termina em 2020-07	3.137 tickers (BAC, FB, NFLX, MA. . .)	marcado como truncado
pico de cotação que se reverte	7,8 mil dias	os dois dias inválidos
preço parado com volume 0	437 mil dias	marcado
pregão faltando	81 mil	retorno de vários dias inválido

Tabela 1: Problemas do painel de preços do FNSPID.

A emenda é o erro grave: cada lote foi ajustado por desdobramentos e dividendos só até a própria coleta. Em 2020-07-06 aparecem AAPL −74,9% (desdobramento 4:1), GOOG −94,9%, TSLA −92,4%. As datas de emenda foram identificadas pelo salto do fator $f = \text{adj_close}/\text{close}$, que numa série consistente só muda em data ex-dividendo.

4.3 Universos

- **Top-n por notícias** (seções 8–17): no 1ž pregão de cada mês, as n ações com mais eventos limpos nos 365 dias anteriores, entre as que têm, nos 252 pregões anteriores, $\geq 95\%$ de retornos válidos, nenhum pico, preço $\geq$ US$ 5 e volume financeiro mediano $\geq$ US$ 5 mi. $n \in \{50{,}100{,}200\}$; com a amostra ampliada, $n = 100$ tem 315 tickers distintos e troca de ∼5%/mês. Exceção declarada: tickers truncados pelo fim da coleta antes do fim do mês ficam fora.
- **S&P 500 point-in-time** (seção 18): membros no último registro estritamente antes de t, com retorno válido em $\geq 95\%$ dos 252 pregões; ∼370–460 ações, ∼350 depois de 2020-07.
- **Setores**: CIK pela SEC (ticker atual, ou busca de nomes no EDGAR conferida contra `formerNames`) → SIC → Fama-French 12/49 e SIC de 2 dígitos; cobre 99,7% das ações-mês do universo top-100.

5 Extração de relações com LLM e construção do grafo

5.1 Tarefa e esquema

Cada artigo (truncado em 8.000 caracteres, o que preserva 85,9% dos tokens e trunca só 6,3% dos artigos) é lido por um modelo local (Ollama) que devolve até 8 tuplas

$$(\text{agent_a}, \text{agent_b}, \text{relation_type}, \text{direction} \in \{+,-\}, \text{strength} \in [0,1]) \; + \; \text{published_at}.$$

O prompt (`prompts/extraction.txt`) define agentes econômicos (empresas, índices, bancos centrais, governos e reguladores, moedas, commodities, setores, instituições, pessoas relevantes) e o que *não* é agente (métricas contábeis, grupos genéricos, a própria fonte). A direção é o efeito sobre `agent_b`; a força é calibrada por faixas (0,8–1,0 explícito e material; 0,1–0,3 especulativo); lista vazia é resposta válida. O esquema JSON é imposto por *constrained decoding*, então a saída é sempre JSON válido.

Versionamento. `prompt_version` = hash de prompt + esquema + `max_chars` + modelo. Trocar qualquer um abre um diretório novo; resultados nunca se misturam. A versão final é `a05d0c0dc189`.

5.2 Escolha do modelo

nos mesmos 200 artigos	`deepseek-r1:14b`	`qwen2.5:14b-instruct`
tuplas agente→agente válidas (40 sorteadas)	∼1/4	∼2/3
artigos preenchidos até o teto de 8	30%	5%
métrica como agente	7,2%	2,8%
grupo genérico como agente	10,2%	4,1%
velocidade (RTX 4090)	1,19/s	1,65/s

Tabela 2: Comparação dos extratores. O 7B inventava relações e foi descartado.

O Qwen2.5-14B-Instruct (Qwen Team, 2024) foi escolhido: deixa ∼40% dos artigos vazios (avisos de ex-dividendo, listas de cotação), onde o R1 inventava relações.

5.3 Execução

- GPUs alugadas (Vast.ai, RTX 3090/4090, US$ ∼0,19–0,22/h); 16 requisições simultâneas, KV cache `q8_0`, `num_ctx` derivado do pior caso.
- Gravação incremental sem perda: WAL JSONL com fsync, segmentos Parquet atômicos a cada 200 registros; partição determinística por hash entre VMs.
- **Amostra**: hash determinístico e aninhado do `unit_id`. Primeiro 25% (401.609 unidades, 882.914 relações); depois ampliada para 40% e parada por crédito em 2026-10-15 com **572.762 unidades** (35,6% do corpus elegível), 0 falhas, **1.270.582 relações**. Como a ordem de processamento era a natural do hash, a parte extraída é uma subamostra uniforme.

5.4 Filtro de ruído

O filtro (`newsmanager/extract/noise.py`) *marca* e não apaga. Na amostra de 25%:

Precisão do filtro em amostras de 10–15 por motivo: ∼9/10 ou mais. Num sorteio de 40 relações limpas, ∼70% são relações econômicas claras. Indicadores macro e setores não são ruído.

motivo	relações	exemplo
genérico	7,3%	Allakos → disappoints → investors
comparação	2,1%	Datadog → outperforms → setor
pertencimento	1,5%	Nasdaq 100 → includes → Tesla
fonte	1,1%	Zacks → upgrades → Kaman
laço	0,8%	DuPont → expands → DuPont
métrica	0,8%	Comcast → raises → dividend
organograma	0,2%	Bank of England → appoints → Carney
limpas	**86,2%**	

Tabela 3: Motivos de ruído. Na extração final, 86,1% das relações são limpas.

5.5 Ligação de entidades a tickers

- Um modelo leve (`qwen2.5:7b-instruct`) só *escolhe* entre candidatos fechados (enum no esquema) ou NONE; o universo é a união dos tickers com preço no FNSPID e das marcações `symbols`. O 3B teve a mesma velocidade e classificou tipos pior.
- Depois do LLM: só `company`/`fund` levam ticker; o ticker exige nome compatível ou evidência forte; uma verificação sim/não derruba colisões com tickers estrangeiros (`link-verify`).
- Resultado (versão `l=c49291db2953`, 304.430 nomes, 0 falhas): 773.440 menções com ticker (33,9%). Desvio declarado: 434 tickers novos aceitos por evidência (875 menções) ficaram sem verificação; na rodada anterior ∼25% desse grupo era rejeitado, logo ∼200 menções com ticker errado (0,03%).

5.6 O grafo dinâmico

- **Nós**: um por agente. Regras: o canônico do LLM só vale se compatível com o nome; prefixo de país removido ("US Federal Reserve" = "Federal Reserve"); classes de ação fundidas (GOOG/GOOGL); colisão entre slug e ticker resolvida pelo tipo (`CORN_COMMODITY`); aliases manuais (FOMC → Fed, WTI/Brent → petróleo). O Fed é um nó com 200 grafias e 31.013 menções.
- **Eventos**: `src--classe(w)-->dst`, $w = \pm$strength; 184.035 `relation_type` distintos mapeados por regex para 16 classes: impacto 32,1%, concorrência 9,2%, participação 7,3%, M&A 7,0%, cadeia de suprimentos 6,1%, parceria 4,4%, legal/regulatório 4,1%, posicionamento 3,3%, analista 3,1%, negócios 2,9%, financiamento 2,3%, monetária 2,0%, política comercial 0,9%, governança 0,9%, retorno de capital 0,3%, outros 14,0%.
- **Tamanho final**: **255.384 nós e 1.064.801 eventos limpos** (+44% sobre a amostra de 25%).
- **Snapshot sem look-ahead**: o grafo em t agrega eventos com data em $[t - W, t)$, com peso $w_e(t) = \mathrm{sgn}_e \, s_e \, 0{,}5^{(t-t_e)/\tau}$ (meia-vida τ, em dias corridos; Eq. 3.1 da monografia).
- **Período útil**: 2011–2023 (2006–2009 quase vazios). Arestas diretas entre ações são raras (em 2018, entre os 100 tickers mais citados, 9,7% dos pares), mas 57,9% dos pares compartilham ao menos uma entidade não negociada (Fed, petróleo, China…). **O sinal relevante é a exposição comum, uma estrutura de fatores semântica**, que diferencia o grafo da co-menção.

Nota para a escrita: um diagrama do pipeline (FNSPID → unidades → LLM → tuplas → filtro → link → grafo → $\hat{\Sigma}$ → carteira) e uma figura do grafo em torno do Fed renderiam bem neste capítulo.

6 Metodologia

6.1 Disciplina contra *data snooping*

Este é um ponto forte e deve aparecer no texto. Cada desenho de carteira foi **escrito e commitado antes de rodar** (seções 10, 12, 14, 16 e 18 de `docs/metodo_covariancia.md`), com critério de sucesso, nível de significância e controles fixos. Mudanças posteriores foram declaradas como tal. O nível de significância cai a cada novo desenho da mesma hipótese (Bonferroni: 0,05; 0,025; 0,01 por otimizador; 0,0125; 0,01). O programa da seção 18 tem separação dev/holdout, e o holdout roda uma vez (o código recusa refazer sem `--force`).

6.2 Hipóteses originais

H1 (estatística) Os vínculos das notícias até t preveem a correlação futura entre duas ações além do que a correlação histórica já prevê.

H2 (econômica) Usar esse sinal na estimação de Σ reduz a volatilidade fora da amostra da GMV e melhora carteiras que dependem de Σ, em relação às referências.

H3 (regime) O ganho é maior quando a história de preços é pouco informativa (janela curta, mudança de regime) (Becquin and Esmeir, 2023).

H1 é condição para H2: sem previsão de correlação, um ganho de carteira seria só regularização genérica, o que os placebos separam.

6.3 Atributos de par a partir do grafo

No snapshot em t (janela de 365 dias, meia-vida de 90 dias, sem calibrar):

1. **Vínculo direto por grupo de classe**: $d_{ij}^{(k)} = \sum_{e:\, c_e \in k} |w_e(t)|$ nos dois sentidos; atributo $\log(1 + d_{ij}^{(k)})$; grupos cadeia, rivalidade, controle, impacto, outros.
2. **Exposição comum**: $\tilde{A}_{im}$ = soma dos eventos entre a ação i e a entidade não negociada m, ponderada por IDF $\log(p/\mathrm{df}_m)$ ("S&P 500" pesa pouco, "crude oil" pesa para as petroleiras); $g_{ij} = \cos(\tilde{A}_i, \tilde{A}_j)$ (Eq. 3.2 da monografia). *Nota para a escrita: no código (`newsmanager/grafo/rede.py`), o numerador do IDF é o número de nós com ticker no grafo da janela, não p; a monografia escreve p. Ver a seção 10.*
3. **Co-ocorrência no artigo extraído** e **co-menção do FNSPID** (a variável de Tang et al. 2019).
4. **Controles**: mesmo setor (FF49, SIC2).

6.4 Regressão preditiva de correlação (a "ponte" semântica–numérica)

Com os rebalanceamentos anteriores a t (painel empilhado, janela expansiva):

$$z(\rho_{ij}^{\mathrm{fut}}) = a + b\, z(\rho_{ij}^{\mathrm{hist}}) + \sum_k \beta_k \log(1 + d_{ij}^{(k)}) + \gamma\, g_{ij} + \theta^\top x_{ij} + \varepsilon_{ij},$$

com $z = \mathrm{atanh}$, ρ^{hist} em 252 pregões e ρ^{fut} no mês seguinte. Os β_k e γ traduzem cada tipo de relação em correlação. O modelo com $\beta = \gamma = 0$ é a referência de persistência. Inferência: Fama-MacBeth com Newey-West e R^2 fora da amostra da cross-section.

6.5 Shrinkage para um alvo fixo de notícias

Correlação-alvo $R_T = \tanh(\hat{z})$ (projetada para PSD, Higham 2002), covariância-alvo $T = D^{1/2} R_T D^{1/2}$ com $D = \mathrm{diag}(S)$, e $\hat{\Sigma} = \delta T + (1-\delta)S$. O δ ótimo generaliza Ledoit and Wolf (2004a) trocando a correlação constante $\bar{r}$ por r_{ij}^T fixo:

$$\hat{\pi} = \textstyle\sum_{ij} \widehat{\mathrm{AsyVar}}(\sqrt{N} s_{ij}), \qquad \hat{\gamma} = \|T - S\|_F^2,$$
$$\hat{\rho} = \textstyle\sum_i \hat{\pi}_{ii} + \sum_{i \neq j} \frac{r_{ij}^T}{2} \Big(\sqrt{s_{jj}/s_{ii}}\, \hat{\vartheta}_{ii,ij} + \sqrt{s_{ii}/s_{jj}}\, \hat{\vartheta}_{jj,ij} \Big),$$
$$\delta^* = \max\big(0, \min(1, (\hat{\pi} - \hat{\rho})/(N\hat{\gamma}))\big).$$

Unidades: $\hat{\pi}$, $\hat{\rho}$ e $\hat{\gamma}$ estão em (retorno diário)^4 e se cancelam; $\delta^* \in [0,1]$ é adimensional. Definições de $\hat{\pi}_{ij}$ e $\hat{\vartheta}_{ii,ij}$ em `docs/equacoes/equacoes.tex`.

6.6 Os desenhos de carteira (H2)

Configuração comum (salvo indicação): 2013-01 a 2023-12 (2011–2012 só treinam os alvos), janela in-sample de 252 pregões, rebalanceamento mensal, custo de 10 bps sobre o giro, notícias de 365 dias com meia-vida de 90, coeficientes treinados só em meses cujo período de carteira já terminou (`min_train` = 24). Teste: razão de variâncias dos retornos diários líquidos, com p bicaudal por bootstrap circular em blocos de 10 dias (2.000 reamostragens, seed 7).

	desenho	como a notícia entra
D1	alvo-prior (seção 9)	$R_{ij} = \tanh(\bar{z} + \beta^\top f_{ij})$, sem z_{hist}; $\beta = 0$ é o LW correlação constante
D2	fator + resíduo (seção 10)	$\hat{\Sigma} = \sigma_m^2 bb^\top + \hat{\Sigma}_e$, com $\hat{\Sigma}_e$ encolhida para $R_{\text{prior}} = \tanh(\bar{z}_e + \beta^\top[\text{setor,notícias}])$ na correlação residual
D3	long-only, teto 10% (seção 12)	o estimador de D2 na variância mínima restrita
D4–D8	outros otimizadores (seção 14)	Markowitz ($\gamma = 5$, μ Bayes-Stein), máximo Sharpe, máxima diversificação, HRP, TE mínimo contra o SPY
D9	Black-Litterman na covariância (seção 16)	visões por par $q_{ij} = \tanh(\hat{z}_{ij})\sqrt{s_i s_j}$, confiança Ω por classe de evidência, prior de Wishart
D10	programa walk-forward (seção 18)	33 estimadores, dev/holdout, placebos de grafo (seção 6.7)

Tabela 4: Desenhos testados para H2. Em todos, a referência a bater é o estimador com setor e sem notícias, e há um placebo com as notícias permutadas entre ações.

D2: fator de mercado + correlação residual. Mercado m_t = média igual dos retornos do universo; $x_{it} = a_i + b_i m_t + e_{it}$ por MQO na janela; y do painel = z da correlação *residual* realizada no mês. É o desenho de Lu et al. (2023) com a rede de notícias no lugar da co-negociação. Estimadores: resíduo diagonal, correlação constante, setor (referência), notícias, setor + notícias (principal) e placebo. Critérios: (1) H1 residual com $t > 2$; (2) razão setor + notícias / setor < 1 com $p < 0{,}05$ e abaixo do placebo em $n = 100$; (3) razão < 1 em $n = 50$ e 200 e com a amostra ampliada.

D9: Black-Litterman na covariância. Prior Σ_0 = resíduo do D2 com setor; incerteza de Wishart $V_{(ij),(kl)} = (\sigma_{0,ik}\sigma_{0,jl} + \sigma_{0,il}\sigma_{0,jk})/T$ (análogo de $\tau = 1/T$ de He and Litterman 1999). Confiança Ω por classe de evidência (só exposição; quartis de co-ocorrência), estimada no painel

descontando o ruído amostral $1/(d_m - 3)$:

$$\operatorname{vec}\Sigma_e^{BL} = \operatorname{vec}\Sigma_0 + VP^\top(PVP^\top + \Omega)^{-1}(q - P\operatorname{vec}\Sigma_0),$$

resolvido por gradiente conjugado sem formar V. Carteira principal: GMV sem restrição. Nível $p < 0{,}0125$.

6.7 O programa da seção 18 (roteiro de grafos)

Construção comum

- Universo S&P 500 point-in-time; datas t = 1ž pregão do mês, 2011–2023.
- Grafo em $[t - 365\text{d}, t)$, peso $\text{sign} \cdot \text{strength} \cdot 0{,}5^{\text{idade}/\tau}$.
- Aresta direta w_{ij} (com sinal), w^+, w^-, $d^{(k)}$ por grupo de classe.
- Exposição $\tilde{A}_{im}$ da ação i ao nó $m \notin U_t$, com sinal, IDF e linhas normalizadas; projeção bipartida $g_{ij} = (\tilde{A}\tilde{A}^\top)_{ij}$, PSD por construção ($C^G$).
- Normalizações: bruta, IDF, grau, PMI, z contra o modelo de configuração.

Modelos

código	estimador
B0–B6	1/N; amostral; LW identidade, correlação constante, fator único; **B5: blocos setoriais FF12 (referência principal)**; LW não linear
B7, B8, B9	fatores observáveis (mercado, 12 indústrias, tamanho, momentum); POET; fator + glasso residual
B10, B11, R0	EWMA ($\lambda = 0{,}97$); HRP amostral; fator + resíduo setor (elo com D2)
M2	$\delta T^G + (1-\delta)S$, $T^G = \Delta C^G \Delta$, δ analítico; τ e normalização escolhidos no dev (**modelo principal**)
M2-abs/bin/res, M2+W	variantes: $\lvert\tilde{A}\rvert$, indicador, no resíduo; com kernel de difusão no Laplaciano assinado
M1	fatores Fed ($-\Delta$DGS2), petróleo, China, dólar, ouro + mercado; cargas ridge centradas na exposição das notícias
M3	POET com suporte do grafo
M4	glasso ponderado, $\lambda_{ij} = \lambda_0 e^{-\gamma\lvert\tilde{w}_{ij}\rvert}$
M5	fatores espectrais: q autovetores do Laplaciano normalizado de $C^G - I$
M6	multiplex: 14 camadas por classe e tipo de agente, pesos por MQO não negativo
M8	comunidades (Louvain) para blocos e HRP

Tabela 5: Estimadores do programa da seção 18. M7 (DCC-X) e M9 (centralidade como fator) ficaram fora ou viraram o teste G9.

Hipóteses G1–G13 e testes

- **Diádicas (painel de pares, $y = z$ da correlação residual futura, $h = 21$)**: Fama-MacBeth com NW ($L = 3 + h/21$) e QAP com 200 permutações; p = maior dos dois. Controles: z_{hist}, mesmo FF49, mesmo SIC2, distância de tamanho, atenção. G1 (aresta com sinal), G2 ($\beta^+ > \beta^-$), G3 (Wald de igualdade de 6 grupos de classe), G6 (cobertura e tamanho, descritiva), G8 (direção temporal), G9 (centralidade → beta de baixa futuro).
- **G4**: exposição ao Fed × surpresa (ΔDGS2) em 104 reuniões do FOMC; exploratória.
- **Carteira (walk-forward)**: dev 2013–2018 (72 meses, escolhas automáticas), holdout 2019–2023 (60 meses, uma vez). G5 (M2 contra B5 na GMV, $p < 0{,}01$), G7 (regimes, descritiva), G10 (M2 contra 200 placebos P2 *curveball* e contra co-menção P6), G11 (M4 contra B9 em log-verossimilhança), G12 (alinhamento dos autovetores do grafo com os da covariância futura), G13 (HRP por comunidades contra HRP amostral).

- **Placebos**: P1 posições sorteadas; P2 rewiring com graus preservados; P3 permutação dentro do setor; P4 sinais aleatórios; P5 grafo de dois anos antes; P6/P6b só co-menção / co-ocorrência.
- **Múltiplos testes**: família de 10 testes com Holm a 5%; SPA, Reality Check e MCS para "o melhor modelo com grafo"; Sharpe deflacionado com o número de configurações do dev.
- **Robustez**: meia-vida, normalização, kernel, janela (126/504), frequência, universo, retornos log, winsorização, custos, restrições, só agentes sem ticker, sem *market wraps*, bootstrap estacionário.

Validação da extração e vazamento

- Auditoria automática de presença dos agentes no texto da unidade.
- Amostra estratificada de 800 tuplas (16 classes × 2 períodos × 25) para dois anotadores, e 63 artigos inteiros para o recall.
- Teste de vazamento por anonimização: nomes, tickers e datas mascarados em 218 unidades e reextraídos com a mesma `prompt_version`.

7 Resultados

7.1 H1: as notícias preveem a correlação

Configuração: universo top-100, 156 rebalanceamentos (2011–2023), 772.200 pares-data; avaliação fora da amostra com janela expansiva em 132 meses (2013–2023). Cobertura dos pares: exposição comum 64,3%; co-menção 34,7%; co-ocorrência 23,7%; vínculo direto 1–4% por grupo.

modelo	R^2_{oos}	ganho sobre M0	t (NW)	meses melhores
M0 persistência	0,1858	—	—	—
M1 + co-menção FNSPID (Tang)	0,1873	+0,0015	2,5	67%
M2 + co-ocorrência extraída	0,1900	+0,0042	5,7	74%
M3 + relações tipadas + exposição	0,1891	+0,0033	5,4	76%
M4 tudo	**0,1911**	**+0,0053**	4,8	75%

Tabela 6: H1 na correlação total (amostra de 25%). Ganho positivo nos três subperíodos.

comparação fora da amostra	ganho	t (NW)	meses melhores
setor sobre persistência	+0,0030	4,5	67%
notícias sobre persistência	+0,0053	4,8	75%
co-menção sobre persistência + setor	+0,0008	1,8	63%
notícias sobre persistência + setor	**+0,0031**	**4,0**	74%
notícias sobre persistência + setor + co-menção	+0,0023	5,2	73%

Tabela 7: H1 com controle de setor (amostra de 25%).

- **H1 confirmada.** O ganho é pequeno em nível (+0,5 ponto de R^2 sobre 18,6%), mas estável; y é uma correlação de 21 dias, dominada por ruído.
- O grafo do LLM domina a co-menção marcada (quase 3× o ganho), e a co-menção quase some depois do setor ($t = 1{,}8$); as notícias, não.

- A **exposição comum** é o sinal semântico que sobrevive (t = 7,4 no Fama-MacBeth completo; $t = 6{,}3$ ao lado do setor). As relações diretas tipadas quase não acrescentam; a cadeia chega a ficar negativa ($t = -3{,}2$) com controle de co-ocorrência.
- **Correlação residual** (pré-requisito do D2): ganho +0,0026, $t = 9{,}7$, melhor em 86% dos meses.
- **Amostra ampliada (36%)**: total +0,0033 ($t = 4{,}3$); residual +0,0027 ($t = 8{,}8$; 84%). O sinal se mantém com 44% mais eventos.

7.2 H2, desenho D1: alvo-prior

Um primeiro caminho, com a correlação histórica dentro do alvo, foi descartado por construção (o alvo dependia da própria amostra e $\delta \approx 1$). Com alvos-prior (δ médio $\approx 0{,}2$):

estimador	sem restrição	p	long-only	p
LW fator único	**0,918**	0,000	0,999	0,91
LW não linear	0,949	0,005	1,006	0,79
LW identidade	0,959	0,035	1,017	0,36
alvo setor	1,008	0,26	1,006	0,002
alvo notícias	1,042	0,000	1,006	0,20
alvo setor + notícias	1,035	0,002	1,006	0,16
placebo	1,032	0,015	1,002	0,39
amostral	1,254	0,000	1,029	0,09

Tabela 8: Razão de variâncias da GMV contra LW correlação constante ($n = 100$).

O alvo de notícias tem o *menor* erro de correlação par a par (−0,09% contra LW correlação constante; placebo +0,33%, $t = 3{,}7$ de diferença), mas não reduz a variância. O fator único é o pior em erro de correlação e o melhor em variância: **a GMV premia a estrutura de fatores, não a precisão par a par**. Isso motivou o D2, declarado como revisão motivada pelo resultado.

7.3 H2, desenhos D2 e D3: fator + resíduo, sem restrição e long-only

	notícias / setor		placebo / setor		$\lambda_{\max}/\lambda_{\min}$	
n	razão	p	razão	p	setor	+ notícias
amostra de 25%						
50	0,997	0,57	1,028	0,08	102	109
100	1,001	0,92	1,028	0,009	183	210
200	1,018	0,10	1,058	0,000	375	533
amostra de 36%						
50	1,003	0,77	1,011	0,30	104	110
100	1,001	0,89	1,022	0,006	183	217
200	1,025	0,046	1,021	0,27	374	544

Tabela 9: D2: GMV sem restrição. Volatilidades em $n = 100$: setor 12,88%, + notícias 12,89%, LW fator único 12,90%, LW não linear 13,12%, 1/N 20,1%.

- **Critério 1 atendido; critérios 2 e 3 não.** As notícias não reduzem a variância além do setor; com mais dados, em $n = 200$ pioram ($p = 0{,}046$).
- O grafo verdadeiro bate o placebo (variância 2,8–5,8% menor com a amostra de 25%): o conteúdo não é ruído.

- **Mecanismo**: as notícias aumentam o número de condição (+6% a +45%); a GMV inverte $\hat{\Sigma}$ e o ganho se perde na inversão (López de Prado, 2016).
- Achado lateral: fator de mercado + resíduo encolhido para o setor empata com o LW fator único e bate o LW não linear.

run ($n = 100$, amostra de 36%)	vol.	Sharpe	razão contra setor	p
fator + resíduo setor	13,43%	0,778	—	—
setor + notícias	13,42%	0,789	0,998	0,46
placebo	13,39%	0,783	0,994	0,12
LW fator único	13,39%	0,788	0,993	0,15
1/N	19,94%	0,663	2,205	0,000

Tabela 10: D3: variância mínima long-only com teto de 10%. Exigia $p < 0{,}025$ e notícias abaixo do placebo.

Confirmação: razões de 0,996 ($n = 50$, $p = 0{,}06$) e 0,996 ($n = 200$, $p = 0{,}09$); tetos de 5% e 20%: 0,995 e 0,998. Diferenças de 0,2–0,5% da variância, abaixo do ruído. O resultado exploratório com a amostra de 25% (0,994, $p = 0{,}017$) **não se replicou**. Com teto, todos os estimadores com fator empatam (Jagannathan and Ma, 2003).

7.4 H2, desenhos D4–D8: outros otimizadores

otimizador	estatística	notícias/setor	p	placebo/setor	p
Markowitz ($\gamma = 5$)	Δ Sharpe	−0,015	0,16	+0,004	0,62
máximo Sharpe	Δ Sharpe	−0,010	0,43	+0,004	0,76
máxima diversificação	razão de var.	0,992	0,46	0,921	0,17
HRP	razão de var.	1,007	0,14	1,002	0,59
TE mínimo	razão de var. ativa	**1,214**	**0,000**	1,008	0,63

Tabela 11: D4–D8 ($n = 100$). Nível exigido: $p < 0{,}01$ e melhor que o placebo.

- Nenhum dos cinco atende o critério; a direção não se repete em $n = 50$ e $n = 200$.
- No **TE mínimo** as notícias *pioram* de forma crescente com n: +10% ($n = 50$), +21% ($n = 100$), +43% ($n = 200$), $p < 0{,}001$; o placebo não piora. Replicar um índice exige acertar a covariância conjunta; as correlações residuais das notícias acertam a média dos pares, mas distorcem o hedge (giro de 3,3 para 4,0 por ano).
- **O otimizador importa muito mais que o estimador**: a volatilidade vai de 13% (variância mínima) a 25% (Markowitz); para um otimizador fixo, trocar o estimador muda menos de 1 ponto. Nenhum otimizador com retorno esperado bateu o SPY em Sharpe líquido (0,82).

7.5 H2, desenho D9: Black-Litterman na covariância

O BL **aumenta** a variância em 14%, mesmo com o número de condição caindo (183 → 137). As confianças crescem com a evidência (ω de 0,013 a 0,058 em z), mas o erro de cada visão é da mesma ordem do sinal; as milhares de visões movem covariâncias que a GMV explora. O placebo piora mais (1,30): a informação existe, mas não vira carteira melhor.

Testes exploratórios do mesmo período, sem critério: estabilidade diária de $\hat{\Sigma}$ (notícias/setor = 1,12 no κ mediano, placebo 1,10) e fatores de sentimento por agente (R^2 mediano de 4,2%, nível de ruído).

$\hat{\Sigma}$ (GMV sem restrição, $n = 100$)	vol.	Sharpe	razão contra setor	p
fator + resíduo setor	12,83%	0,632	—	—
setor + BL notícias	13,71%	0,609	1,143	0,015
BL placebo	14,62%	0,556	1,300	0,012
BL Ω homogêneo	13,61%	0,596	1,126	0,021
setor + notícias (δ único)	12,83%	0,641	1,001	0,87
LW fator único	12,85%	0,634	1,003	0,52

Tabela 12: D9. Confirmação: $n = 50$ razão 1,10; $n = 200$ razão 1,20 ($p = 0{,}001$).

7.6 Programa da seção 18: validação da extração

- **Auditoria de presença** (740.467 das 1.063.603 tuplas com texto disponível, 70%): os dois agentes aparecem no texto em 72,8% literalmente e 98,2% por tokens distintivos (de 92,1% em retorno de capital a 99,4% em parceria). A diferença vem da normalização de nomes pelo LLM (“Apple Inc.” contra “Apple”).
- **Vazamento por anonimização** (218 unidades; 872 tuplas originais, 795 reextraídas): quando o mesmo par reaparece (294 pares; 33,7% das tuplas originais), o sinal é o mesmo em **91,2%**, o tipo exato em 55,4%, e a força média é 0,730 contra 0,728 (diferença absoluta média 0,045). As divergências não se alinham com o retorno futuro de 21 pregões (Spearman $\rho = -0{,}13$, $p = 0{,}26$, $n = 82$); a original não está mais alinhada com o futuro ($\rho = -0{,}02$) que a anonimizada ($\rho = +0{,}08$). **Sem evidência de vazamento.** Limites: só um terço das tuplas reaparece com o mesmo par, e o teste de alinhamento tem pouco poder.
- [**Pendente:** anotação manual das 800 tuplas (dois anotadores) e do recall em 63 artigos: precisão de entidade e de relação, acurácia de tipo e sinal, Spearman da força, κ de Cohen e recall.]

7.7 Programa da seção 18: descritivas do grafo

- **Portão**: R^2 médio da projeção g sobre o setor = 0,017 em 156 meses ($< 0{,}5$): o grafo não é setor reescrito.
- Metade das arestas entre ações liga empresas do mesmo FF12 (47–54%), contra ∼10% dos pares.
- Arestas negativas: 41–53% por ano. Jaccard ano a ano: 0,12–0,17. Cobertura cresce com o tamanho (73–86% no menor quintil, ∼97% no maior). Grau mediano 1 (p90 = 6).

7.8 Programa da seção 18: testes diádicos

Painel S&P 500, 155 meses, ∼350–460 ações por mês, $h = 21$.

regressor (G1)	coef.	t
sgnlog(w)	**−0,0016**	**−9,1**
g (projeção bipartida)	+0,0038	+11,1
z_{hist}	+0,105	+16,7
mesmo FF49	+0,013	+14,4
mesmo SIC2	+0,011	+15,3
distância de tamanho	−0,0018	−4,2

Tabela 13: G1: Fama-MacBeth na correlação residual futura.

- **G1 rejeitada**: o coeficiente da aresta com sinal é negativo nos três subperíodos e nos horizontes de 63 e 126 dias. Diagnóstico (exploratório): positivas ($t = +6{,}7$) e negativas ($t = +11{,}8$) *ambas* aumentam a correlação; as negativas são principalmente concorrência entre rivais do mesmo ramo, que andam juntos. **O sinal extraído pelo LLM descreve o efeito econômico, não a direção do co-movimento.** A existência e a intensidade do vínculo preveem correlação ($|w|$: $t = +12$; g: $t = +11$).
- **G2 rejeitada**: $\beta^+ - \beta^- = -0{,}0015$ ($t = -7{,}3$), o contrário do esperado.
- **G3 confirmada**: Wald = 77,9 (p QAP = 0,005). Concorrência +0,0022 ($t = 9{,}9$), parceria +0,0004 (4,7), controle +0,0007 (4,1), cadeia +0,0006 (3,1), impacto +0,0003 (1,9), legal ≈ 0. As expectativas registradas (cadeia > 0, parceria pequena, legal ≤ 0) se confirmam.
- **G6** (descritiva): interação com cobertura $t = 4{,}7$; o termo com sinal fica mais negativo nas grandes empresas.
- **G8 rejeitada**: mudanças no grafo não antecedem mudanças na correlação ($t = -2{,}2$ à frente, sinal contrário; reverso nulo).
- **G9 confirmada**: centralidade prevê o beta de baixa futuro ($t = 2{,}9$, $p = 0{,}002$), mas depende da normalização (some com as normas grau e z).
- **G4** (FOMC, exploratória): exposição ao Fed × surpresa +0,0029 ($t = 1{,}8$), na direção esperada, não significante.
- Robustez (meia-vida 30/180/365, normalizações): vereditos de G1, G2, G3 e G8 não mudam.

7.9 Programa da seção 18: dev e holdout

Escolhas congeladas no dev (2013–2018). M2: $\tau = 180$, norma z (20 tentativas); POET $C = 0{,}5$; M5 $q = 10$; M1 $\kappa = 1$, $c = 0{,}1$ (o prior de notícias muda a QLIKE em só 10^{-5}); M2+W $\alpha = 0{,}25$, $\beta = 2$; M4/B9 $\lambda_0 = 0{,}2$, $\gamma = 2$ (borda da grade). No dev, o POET teve variância GMV ∼23% menor que o melhor M2.

hipótese	p	p Holm	veredito
G1	1,0	1,0	rejeitada
G2	1,0	1,0	rejeitada
G3	0,005	**0,045**	**confirmada**
G5	1,0	1,0	rejeitada (M2 pior que B5)
G8	0,985	1,0	rejeitada
G9	0,002	**0,021**	**confirmada**
G10	1,0	1,0	rejeitada
G11	0,83	1,0	rejeitada
G12	0,005	**0,045**	**confirmada**
G13	1,0	1,0	rejeitada

Tabela 14: Família primária com Holm. Sobrevivem as duas diádicas estruturais e a espectral; nenhuma de carteira.

Holdout (2019–2023, 60 meses, 1.257 pregões, rodado uma vez em 2026-10-28).

- **G5**: razão de variâncias M2/B5 = **1,115** (IC 95% 1,030–1,237; $p = 0{,}023$): o M2 tem 11% mais variância, significativo no sentido *contrário*. DM-HLN em QLIKE favorece o B5 ($p = 0{,}0003$); M2 fora do MCS de QLIKE; Sharpe deflacionado 0,78.

- Pares modelo com notícias / controle sem notícias: M2/B3 1,071; M2/B4 1,208; M2res/R0 1,051; M4/B9 1,010; M1/B7′ 1,016; M8blk/FF12 0,998; M5/PCA 1,52. Nenhum estimador com notícias é significativamente melhor que seu controle.
- O SPA aponta um modelo com notícias melhor que B5 (M4, $p = 0{,}0015$), mas o ganho é do glasso: o B9 sem notícias faz o mesmo (G11).
- **G10**: p empírico contra 200 placebos P2 = 0,81; o P3 (embaralhado dentro do setor) é melhor que o grafo real na maioria das réplicas.
- **G12**: cosseno médio 0,236 entre autovetores do grafo e da covariância dos 63 pregões seguintes, contra p95 de 0,178 nos placebos ($p = 0{,}005$).
- **G13**: HRP por comunidades / HRP amostral = 1,068.
- **G7**: na QLIKE o M2 erra mais em 2020Q1; na variância da GMV, piora em tempos calmos.
- Robustez do G5: em nenhuma variante o M2 bate o B5; a única abaixo de 1 é a long-only (0,972, $p = 0{,}30$).

estimador	vol. anual	Sharpe	MDD	giro/ano	previsão de risco
B0 (1/N)	22,6%	0,67	−40%	1,0	0,95
B5 (blocos setoriais)	15,2%	0,39	−27%	31	0,43
B7 (fatores observáveis)	**14,2%**	0,65	−22%	19	0,41
B9 (glasso)	14,3%	0,62	−25%	14	0,43
M4 (glasso ponderado)	14,4%	0,64	−25%	15	0,43
B6 corrigido (LW não linear)	14,4%	—	—	—	—
B4 (LW fator único)	14,6%	0,48	−26%	30	0,38
R0	14,7%	0,42	−25%	33	0,37
M2res	15,1%	0,49	−27%	36	0,37
M2	16,0%	0,50	−28%	52	0,26
M5	19,7%	0,33	−39%	20	0,84

Tabela 15: GMV no holdout (descritivo). O B6 original (28,6%) tinha um defeito, corrigido em análise posterior rotulada; o M3 (31,2%) sofre de quase singularidade por desenho.

8 Discussão

1. **Informação existe.** H1 confirmada e estável (correlação total e residual, três subperíodos, 25% e 36% do corpus, controle de setor e de co-menção). O grafo bate os placebos em correlação, o tipo de relação importa (G3), a centralidade prevê risco de baixa (G9) e os autovetores do grafo apontam para o risco futuro (G12).
2. **Mas não vira carteira melhor.** Em nove desenhos (D1–D9) e no programa walk-forward com 33 estimadores, nenhum ganho significativo; pioras significativas na GMV com $n = 200$, no TE mínimo, no BL e no M2 do holdout.
3. **Por quê.**
   - O ganho preditivo é pequeno (∼0,3–0,5 ponto de R^2) e concentrado na média dos pares; a GMV depende da estrutura de autovalores, não do erro médio par a par.
   - Sem restrição, a estrutura esparsa extra abre o leque de autovalores e a inversão consome o ganho (López de Prado, 2016).
   - Com restrição, o teto e a proibição de venda já regularizam tanto que todos os estimadores com fator empatam (Jagannathan and Ma, 2003).

- O que o grafo sabe já está, em grande parte, em setor, fatores e correlação histórica (G10: o placebo dentro do setor é tão bom quanto o grafo real).

4. **O sinal do LLM não é o sinal da correlação.** Concorrentes recebem relações negativas e andam juntos. Isso é uma lição para quem usa sentimento extraído por LLM como proxy de co-movimento.
5. **Comparação com a literatura.** Tang et al. (2019), Becquin and Esmeir (2023) e Lu et al. (2024) relatam ganhos de carteira. Diferenças possíveis a discutir: referência a bater (aqui, sempre um alvo com setor e um placebo, não só LW); pré-registro e correção para múltiplos testes; universo e período; dados do FNSPID (subamostra, painel de preços com falhas).
6. **H3 (regime)** não foi testada como hipótese própria nos desenhos D1–D9; o G7 (descritivo) indica que o M2 erra mais na previsão em 2020Q1. [**Pendente:** decidir se H3 entra como resultado (descritivo) ou como limitação.]

9 Limitações e desvios declarados

- **Amostra**: 36% do corpus elegível (corte por orçamento de GPU); cobertura desigual entre anos.
- **Ruído do LLM**: ∼70% das tuplas limpas são relações econômicas claras (sorteio pequeno); precisão e recall formais dependem da anotação manual pendente. Sem `evidence_span` no esquema.
- **Ligação**: tickers pequenos usados como nome (AVGO, DHI, RIG, ∼250 menções) e empresas renomeadas ficam sem ticker; sinônimos não fundidos todos; 434 tickers novos sem verificação.
- **Preços**: painel do FNSPID com emendas, truncamento em 2020-07 (BAC, FB, NFLX, MA, CSCO, MCD. . . saem do universo) e sem UNH, VZ, MRNA, SPG, BRK, SNAP; sem retorno de deslistagem; viés de sobrevivência.
- **Tempo**: data sem hora (mitigado com $dt < t$); o holdout não é posterior ao *cutoff* do Qwen2.5 (FNSPID termina em 2023), daí o teste de anonimização.
- **Holdout não virgem para M2**: um notebook exploratório usou 2019–2023 com construções do tipo M2 antes do pré-registro (declarado na seção 18.1 do método); a escolha de hiperparâmetros continuou automática no dev.
- **Substituições do roteiro**: GICS → Fama-French/SIC; FF5 → fatores construídos no universo; sem covariância intradiária nem perda de Stein; surpresa de Kuttner → ΔDGS2; sem grafos externos (Revere, TNIC); DCC fora.
- **Correções pós-resultado** (todas registradas): `dropna` que derrubava 25% dos pregões no `avaliar` (conclusão igual); defeito no B6 nos pregões de emenda (corrigido como análise posterior, sem mudar vereditos); `isNone` sobre NaN no comparador de anonimização (só a linha "limpas" muda); meses vazios nas centralidades alternativas do G9 (não corrigido, viesa para zero).

10 O que falta

1. [**Pendente:** anotação manual: 800 tuplas por dois anotadores e recall em 63 artigos (`data/anotacao/`, ver `LEIA-ME.txt`); o script que calcula as métricas já existe.]

2. [**Pendente:** commitar a seção 2.3 de `docs/secao18_resultados.md`, a correção em `newsmanager/grafo/extracao.py` e os logs da anonimização; atualizar a seção 2.2 desse documento, que ainda dá a reextração anonimizada como pendente.]
3. [**Pendente:** completar referências marcadas com "conferir" no `referencias.bib` (Zhou et al. 2025, prenomes de Tang et al., autoria do FNSPID).]
4. [**Pendente:** figuras: pipeline; distribuição de classes; evolução do grafo por ano; vizinhança do Fed; série de volatilidade das carteiras; mapa dos t dos testes diádicos.]
5. [**Pendente:** alinhar texto e código em três fórmulas (detalhes nas notas de implementação de `docs/equacoes/equacoes.tex`): (i) IDF, numerador p no texto e número de nós com ticker no grafo da janela no código; (ii) normalização pelo grau, $D^{-1/2}|W|D^{-1/2}$ no texto e divisão das colunas de $\tilde{A}$ pela raiz do grau da entidade no código; (iii) distância da HRP, $\sqrt{2(1-\rho)}$ no texto e $\sqrt{(1-\rho)/2}$ no código (mesma árvore, só uma nota). Decidir se o texto descreve o código ou se o código muda (o que exigiria rodar de novo o holdout, que roda uma vez).]
6. Opcional: recalcular os MCS da seção 18 com o B6 corrigido (rotulado como posterior).

11 Estrutura sugerida para o texto final

capítulo	conteúdo e fonte
1. Introdução	seção 2 deste guia; pergunta, contribuição e resumo dos resultados
2. Revisão bibliográfica	seção 3; `metodo_covariancia.md` §2; roteiro §11
3. Metodologia	seção 6; método §4–5, 10, 12, 14, 16, 18
4. Dados	seção 4; `README.md` (partes 1 e 4)
5. Extração e grafo	seção 5; `README.md` (partes 2 e 3); `secao18_resultados.md` §2–3
6. Resultados I: previsão de correlação	H1 (método §8, 11, 13); diádicos G1–G9 (resultados §4–5)
7. Resultados II: carteiras	D1–D9 (método §9, 11, 13, 15, 17); holdout (resultados §6–7)
8. Discussão e conclusão	seções 8–9 deste guia
Apêndices	prompt e esquema; reprodutibilidade (seção 12)
Documento à parte	`docs/equacoes/equacoes.tex`: cada equação com variáveis, domínios, resultados e unidades

Esta é a ordem adotada em `monografia/` (ver `monografia/ORGANOGRAMA.md`): a metodologia vem antes dos dados.

Nota para a escrita: a ordem "previsão primeiro, carteira depois" segue a lógica H1 ⇒ H2 e deixa claro que o resultado negativo de H2 não vem da falta de informação. Apresentar os desenhos D1–D9 em ordem cronológica, com o pré-registro de cada um, mostra a disciplina contra snooping.

12 Reprodutibilidade

- Código: repositório `NewsManager` (Python, DuckDB, Ollama). Pipeline:

```
python -m newsmanager {probe,plan,ingest,curate,validate,serve}
python -m newsmanager.extract {units,run,collect,filter}
python -m newsmanager.extract {link-prep,link-run,link-verify,link-build,graph-build}
python -m newsmanager {prices,universe,sectors,h1,backtest}
```

```
python -m newsmanager.backtester {run,compare,notebook}
python -m newsmanager.grafo <etapa>    # backtests/secao18/fase1.sh, fase2.sh
```

- Versões: extração `v=a05d0c0dc189`; link `l=c49291db2953`; escolhas do dev com sha256 `ee9e01ad...ef91b82`.
- Texto: `monografia/Monografia.tex`; guia das equações: `docs/equacoes/equacoes.tex` (ambos compilam com `tectonic-Xcompile`).
- Dados derivados no Google Drive (`gdrive:NewsManager`); estado da amostra de 25% em `data/archive/*_25pct/`.
- Testes: ingestão real (`tests/test_e2e_subset.py`), extração com Ollama simulado, grafo, preços, backtester (contra uma simulação dia a dia independente) e grafo da seção 18.

Referências

T. W. Anderson. *An Introduction to Multivariate Statistical Analysis*. Wiley, 3 edition, 2003.

Peter M. Aronow, Cyrus Samii, and Valentina A. Assenova. Cluster-robust variance estimation for dyadic data. *Political Analysis*, 23(4), 2015.

Jushan Bai and Serena Ng. Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 2002.

David H. Bailey and Marcos López de Prado. The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 2014.

Guillaume Becquin and Saher Esmeir. Semantic similarity covariance matrix shrinkage. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 9977–9992, 2023. URL `https://aclanthology.org/2023.findings-emnlp.668/`.

Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57 (1), 1995.

Fischer Black and Robert Litterman. Global portfolio optimization. *Financial Analysts Journal*, 48(5):28–43, 1992.

Vincent D. Blondel, Jean-Loup Guillaume, Renaud Lambiotte, and Etienne Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, page P10008, 2008.

Joël Bun, Jean-Philippe Bouchaud, and Marc Potters. Cleaning large correlation matrices: tools from random matrix theory. *Physics Reports*, 666, 2017.

Tony Cai and Weidong Liu. Adaptive thresholding for sparse covariance matrix estimation. *Journal of the American Statistical Association*, 106, 2011.

A. Colin Cameron, Jonah B. Gelbach, and Douglas L. Miller. Robust inference with multiway clustering. *Journal of Business & Economic Statistics*, 29(2), 2011.

John Y. Campbell and Samuel B. Thompson. Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 2008.

Louis K. C. Chan, Jason Karceski, and Josef Lakonishok. On portfolio optimization: forecasting covariances and choosing the risk model. *Review of Financial Studies*, 12:937–974, 1999.

Yves Choueifaty and Yves Coignard. Toward maximum diversification. *Journal of Portfolio Management*, 35(1), 2008.

Todd E. Clark and Kenneth D. West. Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 2007.

Lauren Cohen and Andrea Frazzini. Economic links and predictable returns. *Journal of Finance*, 63(4), 2008.

Gérard Cornuéjols and Reha Tütüncü. *Optimization Methods in Finance*. Cambridge University Press, 2007.

Victor DeMiguel, Lorenzo Garlappi, and Raman Uppal. Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy? *Review of Financial Studies*, 22(5), 2009.

Francis X. Diebold and Roberto S. Mariano. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 1995.

Zihan Dong, Xinyu Fan, and Zhiyuan Peng. FNSPID: A comprehensive financial news dataset in time series. *arXiv preprint arXiv:2402.06698*, 2024. Conjunto de dados em https://huggingface.co/datasets/Zihan1004/FNSPID; conferir autoria e versão publicada.

Edwin J. Elton and Martin J. Gruber. Estimating the dependence structure of share prices: implications for portfolio selection. *Journal of Finance*, 28, 1973.

Robert Engle. Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 2002.

Robert Engle and Riccardo Colacito. Testing and valuing dynamic correlations for asset allocation. *Journal of Business & Economic Statistics*, 24(2), 2006.

Eugene F. Fama and James D. MacBeth. Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3), 1973.

Jianqing Fan, Yuan Liao, and Martina Mincheva. Large covariance estimation by thresholding principal orthogonal complements. *Journal of the Royal Statistical Society: Series B*, 75(4), 2013.

Jerome Friedman, Trevor Hastie, and Robert Tibshirani. Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3), 2008.

Li Guo, Lin Peng, Yubo Tao, and Jun Tu. Joint news, attention spillover, and stock returns. arXiv:1703.02715, 2017.

Peter Reinhard Hansen. A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 2005.

Peter Reinhard Hansen, Asger Lunde, and James M. Nason. The model confidence set. *Econometrica*, 79(2), 2011.

David Harvey, Stephen Leybourne, and Paul Newbold. Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 1997.

Guangliang He and Robert Litterman. The intuition behind Black-Litterman model portfolios. Technical report, Goldman Sachs Investment Management Research, 1999.

Nicholas J. Higham. Computing the nearest correlation matrix: a problem from finance. *IMA Journal of Numerical Analysis*, 22, 2002.

Gerard Hoberg and Gordon Phillips. Text-based network industries and endogenous product differentiation. *Journal of Political Economy*, 124(5), 2016.

Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 1979.

Ravi Jagannathan and Tongshu Ma. Risk reduction in large portfolios: why imposing the wrong constraints helps. *Journal of Finance*, 58(4), 2003.

Philippe Jorion. Bayes-Stein estimation for portfolio analysis. *Journal of Financial and Quantitative Analysis*, 21(3), 1986.

Raymond Kan and Guofu Zhou. Optimal portfolio choice with parameter uncertainty. *Journal of Financial and Quantitative Analysis*, 42(3), 2007.

Risi Imre Kondor and John Lafferty. Diffusion kernels on graphs and other discrete input spaces. In *Proceedings of the 19th International Conference on Machine Learning (ICML)*, 2002.

David Krackhardt. Predicting with networks: nonparametric multiple regression analysis of dyadic data. *Social Networks*, 10(4), 1988.

Jérôme Kunegis, Stephan Schmidt, Andreas Lommatzsch, Jürgen Lerner, Ernesto W. De Luca, and Sahin Albayrak. Spectral analysis of signed graphs for clustering, prediction and visualization. In *Proceedings of the SIAM International Conference on Data Mining (SDM)*, 2010.

Laurent Laloux, Pierre Cizeau, Jean-Philippe Bouchaud, and Marc Potters. Noise dressing of financial correlation matrices. *Physical Review Letters*, 83, 1999.

Olivier Ledoit and Michael Wolf. Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10, 2003.

Olivier Ledoit and Michael Wolf. Honey, I shrunk the sample covariance matrix. *Journal of Portfolio Management*, 30(4), 2004a.

Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88, 2004b.

Olivier Ledoit and Michael Wolf. Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15, 2008.

Olivier Ledoit and Michael Wolf. Robust performance hypothesis testing with the variance. *Wilmott*, pages 86–89, September 2011.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *Review of Financial Studies*, 30(12), 2017.

Olivier Ledoit and Michael Wolf. Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 2020.

Charles M. C. Lee, Stephen Teng Sun, Rongfei Wang, and Ran Zhang. Technological links and predictable returns. *Journal of Financial Economics*, 132(3), 2019.

Marcos López de Prado. Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 2016.

Marcos López de Prado. *Machine Learning for Asset Managers*. Cambridge University Press, 2020.

Cheng Lu, Papa Momar Ndiaye, and Majeed Simaan. Improved estimation of the correlation matrix using reinforcement learning and text-based networks. *International Review of Financial Analysis*, 96:103572, 2024.

Yutong Lu, Gesine Reinert, and Mihai Cucuringu. Co-trading networks for modeling dynamic interdependency structures and estimating high-dimensional covariances in US equity markets. arXiv:2302.09382, 2023.

Rosario N. Mantegna. Hierarchical structure in financial markets. *European Physical Journal B*, 11, 1999.

Harry Markowitz. Portfolio selection. *Journal of Finance*, 7(1), 1952.

Lior Menzly and Oguzhan Ozbas. Market segmentation and cross-predictability of returns. *Journal of Finance*, 65(4), 2010.

Whitney K. Newey and Kenneth D. West. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 1987.

Andrew J. Patton. Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 2011.

Gustavo Peralta and Abalfazl Zareei. A network approach to portfolio selection. *Journal of Empirical Finance*, 38, 2016.

Dimitris N. Politis and Joseph P. Romano. The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1994.

Dimitris N. Politis and Halbert White. Automatic block-length selection for the dependent bootstrap. *Econometric Reviews*, 23(1), 2004. Correção em Patton, Politis e White (2009).

Francesco Pozzi, Tiziana Di Matteo, and Tomaso Aste. Spread of risk across financial markets: better to invest in the peripheries. *Scientific Reports*, 3:1665, 2013.

Edward Qian and Stephen Gorman. Conditional distribution in portfolio theory. *Financial Analysts Journal*, 57(2):44–51, 2001.

Qwen Team. Qwen2.5 technical report. arXiv:2412.15115, 2024.

Joseph P. Romano and Michael Wolf. Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 2005.

Anna Scherbina and Bernd Schlusche. Follow the leader: using the stock market to uncover information flows between firms. *Review of Finance*, 24(1), 2020. Versão anterior: Economic linkages inferred from news stories and the predictability of stock returns, AEI Working Paper (2016).

Giovanni Strona, Domenico Nappo, Francesco Boccacci, Simone Fattorini, and Jesus San-Miguel-Ayanz. A fast and unbiased procedure to randomize ecological binary matrices with fixed row and column totals. *Nature Communications*, 5:4114, 2014.

Yan Tang, Yifan Zhou, and Mingyi Hong. News co-occurrences, stock return correlations, and portfolio construction implications. *Journal of Risk and Financial Management*, 12(1):45, 2019. Conferir prenomes dos autores.

Michele Tumminello, Tomaso Aste, Tiziana Di Matteo, and Rosario N. Mantegna. A tool for filtering information in complex systems. *Proceedings of the National Academy of Sciences*, 102(30), 2005.

Halbert White. A reality check for data snooping. *Econometrica*, 68(5), 2000.

Zhou et al. Grafos de empresas extraídos por LLM para previsão de retornos com GNN. In *Proceedings of the FinNLP Workshop*, 2025. Referência incompleta no projeto ("Zhou et al., FinNLP 2025"): localizar título e autores exatos antes de citar.