Universidade Federal de Minas Gerais
Escola de Engenharia
Curso de Graduação em Engenharia Elétrica

Grafos de notícias extraídos por LLM na estimação da matriz de covariância e na seleção de carteiras

Gabriel Vaz Cançado Ferreira

Orientador: Prof. Dr. Cristiano Arbex Valle
Departamento de Ciência da Computação (DCC/UFMG)

Belo Horizonte, Dezembro de 2026

Monografia

Grafos de notícias extraídos por LLM na estimação da matriz de covariância e na seleção de carteiras

Monografia submetida à banca examinadora designada pelo Colegiado Didático do Curso de Graduação em Engenharia Elétrica da Universidade Federal de Minas Gerais, como parte dos requisitos para aprovação na disciplina Trabalho de Conclusão de Curso.

Belo Horizonte, Dezembro de 2026

Resumo

Este trabalho investiga se relações econômicas extraídas de notícias por um modelo de linguagem de grande porte (LLM) melhoram a estimação da matriz de covariância dos retornos de ações e, por meio dela, a construção de carteiras. A partir do corpus público FNSPID, um modelo executado localmente (Qwen2.5-14B-Instruct) leu 572.762 artigos e extraiu 1.270.582 relações tipadas, com sinal e intensidade, entre empresas e entidades econômicas como o Federal Reserve, o petróleo e a China. As entidades foram associadas a *tickers* e organizadas num grafo dinâmico com 255 mil nós e 1,06 milhão de eventos entre 2011 e 2023, consultado apenas com informação anterior a cada data de decisão.

A avaliação ocorreu em dois níveis. No estatístico, previsões fora da amostra e regressões de Fama-MacBeth com testes de permutação verificaram se os vínculos preveem a correlação futura entre pares de ações além da correlação histórica e do setor, por dois canais: a exposição comum das empresas às mesmas entidades não negociadas e o tipo da relação direta entre elas. No econômico, o grafo entrou na matriz de covariância como alvo de *shrinkage*, como estrutura da correlação residual de um modelo de fatores e como visões de Black-Litterman, e as carteiras resultantes foram comparadas fora da amostra, entre 2013 e 2023, com estimadores de referência e com um placebo, em nove desenhos com o critério de sucesso registrado antes da execução e o nível de significância reduzido a cada nova tentativa.

As notícias preveem a correlação futura além do histórico e do setor, com estatística t de 8,8 na correlação residual. O canal mais forte é a exposição comum, que sobrevive aos controles de setor e de atenção da mídia num universo que não foi escolhido pelas notícias; o tipo de relação também importa, mas o sinal atribuído pelo modelo descreve o efeito econômico entre as empresas, e não a direção do co-movimento. O ganho de previsão é pequeno, cerca de três décimos de ponto de R^2. Nenhum dos desenhos de carteira reduziu de forma significativa a volatilidade realizada nem melhorou o índice de Sharpe em relação à referência de setor, e em dois deles as notícias pioraram a carteira. Conclui-se que a informação das notícias é real, mas pequena e esparsa: ela se perde na inversão da matriz ou é absorvida pelas restrições de carteira e pelos modelos de setor e de fatores.

Palavras-chave: matriz de covariância; grafos de conhecimento; modelos de linguagem; notícias financeiras; seleção de carteiras.

Agradecimentos

Aqui vai o texto dos agradecimentos.

Sumário

Resumo i

Agradecimentos iii

Lista de Figuras ix

Lista de Tabelas xi

1 Introdução 1
- 1.1 Contexto e motivação . . . 1
- 1.2 Pergunta de pesquisa e hipóteses . . . 2
- 1.3 Objetivos . . . 3
- 1.4 Contribuições . . . 3
- 1.5 Organização do texto . . . 4

2 Fundamentação Teórica e Revisão Bibliográfica 5
- 2.1 Seleção de carteiras e o papel da matriz de covariância . . . 5
- 2.2 Estimação de matrizes de covariância . . . 6
  - 2.2.1 Covariância amostral e o problema da dimensão . . . 6
  - 2.2.2 Estrutura: correlação constante, setores e fatores . . . 7
  - 2.2.3 Shrinkage linear . . . 7
  - 2.2.4 Outras abordagens . . . 8
- 2.3 Redes e grafos em finanças . . . 8
- 2.4 Vínculos econômicos, texto e notícias . . . 8
- 2.5 Texto e matriz de covariância . . . 9
- 2.6 Modelos de linguagem e informação financeira . . . 9
- 2.7 Avaliação de estimadores e inferência . . . 11
  - 2.7.1 Avaliação de previsões e de carteiras . . . 11
  - 2.7.2 Inferência com dados de pares . . . 11
- 2.8 Lacuna e posicionamento do trabalho . . . 11

3 Metodologia 13
- 3.1 Visão geral . . . 13
- 3.2 Protocolo de pré-registro . . . 14
- 3.3 Hipóteses . . . 15
- 3.4 Atributos de par a partir do grafo . . . 16
  - 3.4.1 O grafo numa data . . . 16

3.4.2 Vínculo direto . . . 16
3.4.3 Exposição comum . . . 17
3.4.4 Controles . . . 17
3.5 Previsão de correlação e testes de pares . . . 18
3.5.1 Regressão preditiva de correlação . . . 18
3.5.2 Correlação residual . . . 19
3.5.3 Testes de pares . . . 19
3.6 Estimadores da matriz de covariância com notícias . . . 19
3.6.1 Alvo de shrinkage com notícias . . . 20
3.6.2 Fator de mercado e correlação residual . . . 20
3.6.3 Black-Litterman na covariância . . . 21
3.7 Estimadores de referência e placebo . . . 22
3.8 Carteiras . . . 22
3.9 Desenho experimental . . . 23
3.9.1 Configuração comum . . . 23
3.9.2 Os desenhos testados para H2 . . . 23
3.10 Métricas e testes estatísticos . . . 23

4 Dados **25**
4.1 O corpus de notícias FNSPID . . . 25
4.1.1 Descrição do conjunto . . . 25
4.1.2 Ingestão e curadoria . . . 25
4.1.3 Unidades de extração e amostra . . . 26
4.2 O painel de preços . . . 26
4.3 Universos de ações . . . 27
4.4 Classificação setorial e índice de referência . . . 28

5 Extração de Relações e Construção do Grafo **29**
5.1 Formulação da tarefa . . . 29
5.2 Modelo e execução . . . 30
5.3 Filtro de ruído . . . 30
5.4 Ligação de entidades a tickers . . . 31
5.5 O grafo dinâmico . . . 31
5.5.1 Nós . . . 31
5.5.2 Eventos e classes de relação . . . 32
5.5.3 O grafo numa data . . . 33
5.6 Validação da extração . . . 33
5.6.1 Presença dos agentes no texto . . . 33
5.6.2 Vazamento de memória do modelo . . . 34
5.6.3 Anotação automática da qualidade . . . 34
5.7 Estatísticas descritivas do grafo . . . 35

6 Resultados I: as Notícias e a Correlação Futura **37**
6.1 Previsão da correlação total . . . 37
6.2 Correlação residual . . . 38
6.3 Os canais da informação: H1a e H1b . . . 39
6.3.1 H1a: exposição comum a entidades não negociadas . . . 39

6.3.2 H1b: tipo de relação 40
6.4 Síntese 41

7 Resultados II: as Notícias e as Carteiras **43**
7.1 Alvo de shrinkage com notícias 43
7.2 Fator de mercado e correlação residual 44
7.3 Variância mínima com restrições 45
7.4 Outros otimizadores 45
7.5 Black-Litterman na covariância 46
7.6 Síntese 47

8 Discussão e Conclusões **49**
8.1 Síntese dos resultados 49
8.2 Por que a informação não vira carteira melhor 50
8.3 O sinal extraído pelo LLM e a correlação 51
8.4 Comparação com a literatura 51
8.5 Limitações 51
8.6 Trabalhos futuros 52

Referências Bibliográficas **53**

A Prompt e Esquema de Extração **57**
A.1 Prompt 57
A.2 Esquema JSON 59

B Reprodutibilidade **61**
B.1 Etapas e comandos 61
B.2 Versões e sementes 61

Lista de Figuras

3.1 Visão geral do processo, das notícias à avaliação das carteiras. Em cinza, as entradas; em azul, a extração e a construção do grafo; em laranja, a estimação e a avaliação. Os preços entram na estimação apenas com a janela anterior a t e, na avaliação, com o período posterior. 14

5.1 Recorte do grafo em 2 de janeiro de 2019: sete empresas e três entidades não negociadas, com os eventos dos 365 dias anteriores. Os números são a soma dos eventos com sinal e decaimento (Equação 3.1), e a espessura da linha acompanha o módulo. Só as ligações mais fortes são mostradas. 33

Lista de Tabelas

2.1 Trabalhos que usam informação externa aos retornos para estimar a covariância. 10

3.1 Hipóteses do trabalho, fundamentação e teste. 16
3.2 Estatísticas e critérios dos testes de pares. 19
3.3 Desenhos testados para H2, na ordem de execução. 24

4.1 Problemas do painel de preços do FNSPID e tratamento. 27

5.1 Nós com mais eventos no grafo. 32
5.2 Classes de relação: participação nos eventos e sinal médio ($+1$ positivo, -1 negativo). 32
5.3 Qualidade da extração segundo a anotação automática (567 tuplas). 34

6.1 Previsão da correlação total fora da amostra (132 meses, 2013–2023, 100 ações). 38
6.2 Regressão de Fama-MacBeth da correlação residual futura (S&P 500, 155 meses). Coeficientes por desvio-padrão do regressor. 39
6.3 H1b: efeito de cada grupo de relação sobre a correlação residual futura. . . 40

7.1 D1: razão de variâncias da GMV contra o *shrinkage* para a correlação constante. 44
7.2 D2: GMV sem restrição com fator de mercado e resíduo encolhido para setor e notícias. 44
7.3 D3: variância mínima sem venda a descoberto e com teto de 10% ($n = 100$). 45
7.4 D4–D8: notícias contra setor em cinco otimizadores ($n = 100$) e direção em $n = 50$ e $n = 200$. 46
7.5 D9: GMV sem restrição com Black-Litterman na covariância residual ($n = 100$). 46
7.6 Resultados de H2 em todos os desenhos testados. 47

B.1 Etapas do processo e comando de cada uma. 62

Capítulo 1

Introdução

A matriz de covariância dos retornos é o insumo central de quase toda decisão de alocação de carteiras: é ela que mede quanto risco cada ativo acrescenta e quanto cada combinação de ativos diversifica. Ela não é observada, porém, e precisa ser estimada a partir de uma história curta de preços. Este trabalho investiga se as notícias financeiras, lidas por um modelo de linguagem de grande porte (LLM, do inglês *large language model*) e convertidas num grafo de relações econômicas entre empresas e outros agentes, contêm informação sobre essa matriz que os preços ainda não revelam, e se essa informação produz carteiras melhores fora da amostra.

1.1 Contexto e motivação

Na formulação de Markowitz (1952), a carteira ótima depende do vetor de retornos esperados e da matriz de covariância Σ dos retornos. Na prática, os dois são substituídos por estimativas, e o otimizador trata os erros dessas estimativas como se fossem informação: ativos cuja variância foi subestimada, ou cujas correlações parecem favoráveis por acaso, recebem peso excessivo. O problema cresce com o número de ativos. Com p ativos e uma janela de N observações, a covariância amostral S tem $p(p+1)/2$ parâmetros distintos; ela é singular quando $N < p$ e mal condicionada sempre que N não é muito maior que p, de modo que sua inversa, que é o que o otimizador usa, amplifica o ruído. Kan and Zhou (2007) mostram que, com muitos ativos, o erro de estimação em Σ custa tanto quanto o erro na média. Por isso a carteira de variância mínima global (GMV, do inglês *global minimum variance*), cujos pesos $w \propto \Sigma^{-1}\mathbf{1}$ dispensam os retornos esperados, tornou-se o laboratório padrão para comparar estimadores de Σ. Ainda assim, a simples divisão igual do capital entre os ativos (a carteira $1/N$) é difícil de superar fora da amostra (DeMiguel et al., 2009).

A resposta da literatura foi impor estrutura à estimativa. Elton and Gruber (1973) mostraram que supor correlação constante, inclusive por blocos de setor, prevê a correlação futura melhor que a matriz amostral. Modelos de fatores reduzem o número de parâmetros ao explicar a covariância por poucas fontes comuns de risco (Chan et al., 1999). O *shrinkage* de Ledoit and Wolf (2003, 2004a,b) combina a matriz amostral com um alvo estruturado,

$$\hat{\Sigma} = \delta\, T + (1-\delta)\, S, \tag{1.1}$$

com a intensidade δ escolhida de forma analítica para minimizar o erro esperado. A expressão (1.1) admite uma leitura bayesiana: o alvo T é um *prior* sobre a estrutura de Σ, e

a qualidade desse prior decide quanto se ganha. Os alvos usuais vêm dos próprios retornos (identidade, correlação constante, fator único) ou de classificações estáticas, como o setor. Há, portanto, espaço para um prior construído com informação externa aos preços.

As notícias são um candidato natural para essa informação. Vínculos econômicos reais propagam informação entre empresas: choques em clientes chegam aos fornecedores (Cohen and Frazzini, 2008), indústrias ligadas na cadeia produtiva se antecipam umas às outras (Menzly and Ozbas, 2010), e empresas com produtos parecidos, medidos pelo texto dos relatórios anuais, formam redes de concorrência (Hoberg and Phillips, 2016). As notícias revelam esses vínculos: empresas citadas juntas preveem os retornos umas das outras (Scherbina and Schlusche, 2020), e a cobertura conjunta gera transbordamento de atenção e co-movimento (Guo et al., 2017). Três trabalhos levam essa ideia à matriz de covariância. Tang et al. (2019) mostram que a coocorrência de duas empresas em notícias prevê a correlação futura entre elas, mesmo controlando a correlação passada, e melhora a GMV. Becquin and Esmeir (2023) usam a similaridade semântica entre empresas como alvo de *shrinkage*. Lu et al. (2024) encolhem a matriz de correlação usando as redes textuais de Hoberg and Phillips (2016). Em todos esses casos, porém, o texto entra de forma pobre: como contagem de co-menções, sem saber se uma empresa fornece, concorre, processa ou adquire a outra, ou como similaridade estática entre descrições.

Os LLMs mudam o que é possível extrair. Um modelo executado localmente pode ler centenas de milhares de artigos e devolver, para cada um, relações estruturadas: quem afeta quem, por meio de que tipo de ação, com que sinal e com que intensidade. Essas relações incluem entidades que não são negociadas, mas que movem preços, como o Federal Reserve, o petróleo ou a China. A exposição comum de duas empresas a essas entidades é, em princípio, uma estrutura de fatores descrita em linguagem natural. Até onde a revisão deste trabalho alcançou (Capítulo 2), não há estudo que use relações extraídas por LLM, tipadas, com sinal e com entidades não negociadas, para estimar a matriz de covariância.

1.2 Pergunta de pesquisa e hipóteses

A pergunta que orienta o trabalho é a seguinte:

> *A estrutura de relações extraída das notícias por um LLM contém informação sobre a covariância futura dos retornos que não está na covariância histórica nem em modelos de fatores e de setor? E essa informação se traduz em carteiras melhores fora da amostra?*

A pergunta tem uma parte estatística e uma parte econômica, e a ordem entre elas importa. Daí as duas hipóteses gerais do trabalho:

H1 (estatística). Os vínculos registrados nas notícias até uma data t preveem a correlação futura entre duas ações além do que a correlação histórica e o setor já preveem.

H2 (econômica). Incorporar esse sinal à estimação de Σ reduz a volatilidade realizada da GMV e melhora carteiras que dependem de Σ, em relação a estimadores de referência sem notícias.

H1 é condição necessária para H2. Se as notícias não previssem a correlação, um eventual ganho de carteira seria apenas o efeito genérico de regularizar a matriz, e não do conteúdo das relações. Para separar uma coisa da outra, todo estimador com notícias é comparado também a um placebo, em que os vínculos são embaralhados entre as empresas preservando sua esparsidade e sua distribuição. H1 é desdobrada em duas hipóteses específicas, uma para cada canal pelo qual a teoria de finanças diz que o grafo carregaria informação sobre o co-movimento: a exposição comum das empresas às mesmas entidades não negociadas (H1a) e o tipo das relações diretas entre elas (H1b). Com H2, são três hipóteses, apresentadas com sua fundamentação na Seção 3.3. O trabalho prefere investigar a fundo essas três a testar um número maior de ideias com menos rigor.

1.3 Objetivos

O objetivo geral é avaliar se um grafo de relações econômicas extraído de notícias por um LLM melhora a estimação da matriz de covariância dos retornos de ações e o desempenho fora da amostra das carteiras que dependem dela. Os objetivos específicos são:

1. construir, a partir do corpus público FNSPID (Dong et al., 2024), uma base de relações tipadas, com sinal e intensidade, extraídas por um LLM executado localmente, e associar os agentes dessas relações aos códigos de negociação (*tickers*) das empresas;

2. organizar as relações num grafo dinâmico que possa ser consultado em qualquer data sem usar informação posterior a ela;

3. medir se atributos desse grafo preveem a correlação futura entre pares de ações além da correlação histórica, do setor e da simples co-menção (H1);

4. incorporar o grafo à estimação de Σ por três vias, como alvo de *shrinkage*, como estrutura da correlação residual de um modelo de fatores e como visões de Black-Litterman, e comparar as carteiras resultantes com estimadores de referência e com um placebo (H2);

5. conduzir as avaliações sob um protocolo de pré-registro, com o critério de sucesso fixado antes de cada execução, nível de significância reduzido a cada nova tentativa e confirmação em universos e amostras diferentes.

1.4 Contribuições

O trabalho traz cinco contribuições.

1. **Uma base de relações econômicas extraídas por LLM.** O modelo Qwen2.5-14B-Instruct (Qwen Team, 2024) leu 572.762 artigos, cerca de 36% do corpus elegível, e extraiu 1.270.582 relações. Depois de filtradas e associadas a *tickers*, elas formam um grafo com 255.384 nós e 1.064.801 eventos entre 2011 e 2023, consultado sempre com informação anterior à data de decisão.

2. **Evidência de que as notícias preveem a correlação.** Os atributos do grafo preveem a correlação futura entre pares de ações além da correlação histórica, do setor e da començão, com estatística t de 8,8 na correlação residual ao fator de mercado. O canal que sobrevive aos controles é a exposição comum a entidades não negociadas, num universo que não foi escolhido pelas notícias, e o tipo de relação importa. O efeito é estatisticamente forte, mas pequeno: cerca de três décimos de ponto de R^2.

3. **Evidência negativa, robusta e pré-registrada para as carteiras.** Em nove desenhos de carteira, oito deles com critério de sucesso fixado antes da execução, nenhum estimador com notícias reduziu de forma significativa a volatilidade realizada ou melhorou o índice de Sharpe em relação à sua referência sem notícias, em universos de 50, 100 e 200 ações. Em dois desenhos, as notícias pioraram a carteira. O trabalho identifica o mecanismo: o sinal é pequeno e esparso, piora o condicionamento da matriz que o otimizador inverte e, quando há restrições de peso, é absorvido pela regularização que elas já impõem.

4. **Um achado sobre o significado do sinal extraído.** O sinal que o LLM atribui a uma relação descreve o efeito econômico de uma empresa sobre a outra, e não a direção do co-movimento entre elas. Concorrentes recebem relações negativas, mas suas ações andam juntas.

5. **Um protocolo de avaliação.** O trabalho combina pré-registro incremental dos desenhos, nível de significância decrescente a cada tentativa, um placebo que preserva a distribuição dos vínculos, inferência por permutação para dados de pares e um teste de vazamento de memória do LLM por anonimização dos textos. O protocolo pode ser reaproveitado por outros estudos que usem LLMs sobre dados financeiros históricos.

1.5 Organização do texto

O Capítulo 2 revisa a literatura sobre estimação de matrizes de covariância, redes e texto em finanças e os métodos de avaliação usados no trabalho. O Capítulo 3 apresenta a metodologia: as hipóteses, a construção dos atributos do grafo, os estimadores de Σ com e sem notícias, as carteiras e o protocolo de avaliação. O Capítulo 4 descreve os dados de notícias, preços e setores, e o Capítulo 5, a extração das relações pelo LLM, a construção do grafo e sua validação. O Capítulo 6 responde à primeira parte da pergunta, sobre a previsão da correlação, e o Capítulo 7, à segunda, sobre as carteiras. O Capítulo 8 discute os resultados, as limitações e os trabalhos futuros. Os apêndices trazem o prompt de extração e as instruções de reprodução.

Capítulo 2

Fundamentação Teórica e Revisão Bibliográfica

Este capítulo reúne a base teórica e os trabalhos que sustentam a pesquisa. A Seção 2.1 apresenta o problema de seleção de carteiras e o papel que a matriz de covariância desempenha nele. A Seção 2.2 revisa os estimadores dessa matriz, do mais simples ao mais estruturado. As Seções 2.3 e 2.4 tratam das redes em finanças e da evidência de que vínculos econômicos, revelados por texto e por notícias, propagam informação entre empresas. A Seção 2.5 detalha os três trabalhos que ligam texto à matriz de covariância, que são os antecedentes diretos desta pesquisa, e a Seção 2.6 discute o uso de modelos de linguagem para extrair essa informação. A Seção 2.7 apresenta os métodos de avaliação e inferência empregados, e a Seção 2.8 situa o trabalho em relação à literatura.

2.1 Seleção de carteiras e o papel da matriz de covariância

Considere p ativos com vetor de retornos esperados μ e matriz de covariância Σ. Na teoria de média-variância de Markowitz (1952), uma carteira de pesos w tem retorno esperado $w^\top \mu$ e variância $w^\top \Sigma w$, e o investidor escolhe, entre as carteiras com o mesmo retorno esperado, a de menor variância. Na forma com aversão ao risco γ,

$$\max_{w} \; w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w \quad \text{sujeito a} \quad w^\top \mathbf{1} = 1. \tag{2.1}$$

O caso extremo, em que o investidor ignora os retornos esperados, é a carteira de variância mínima global (GMV):

$$w_{\mathrm{GMV}} = \frac{\Sigma^{-1}\mathbf{1}}{\mathbf{1}^\top \Sigma^{-1}\mathbf{1}}. \tag{2.2}$$

A teoria supõe μ e Σ conhecidos. Na prática, ambos são estimados com uma história curta, e o otimizador explora os erros de estimação como se fossem oportunidades: um ativo com variância subestimada, ou com correlações que parecem baixas por acaso, recebe peso excessivo. Kan and Zhou (2007) quantificam a perda de utilidade fora da amostra causada pela incerteza nos parâmetros e mostram que, com muitos ativos, o erro na estimação de Σ tem impacto comparável ao erro na média. Os retornos esperados são notoriamente mais difíceis de estimar, e por isso o estimador de Bayes-Stein, que encolhe as médias amostrais para a média da carteira de variância mínima, é uma correção usual (Jorion, 1986). A

GMV da Equação (2.2) depende apenas de Σ e se tornou, por isso, o laboratório padrão para comparar estimadores da matriz de covariância: a carteira construída com o estimador mais próximo da verdadeira Σ tende a ter a menor variância realizada. Engle and Colacito (2006) formalizam esse critério econômico e mostram que comparar a variância realizada de carteiras ótimas é um modo válido de ordenar previsões de covariância e de correlação.

O tamanho do problema fica claro na comparação de DeMiguel et al. (2009). Nenhum dos catorze modelos de otimização que avaliaram superou de forma consistente, fora da amostra, a carteira ingênua que divide o capital igualmente entre os p ativos (a carteira $1/N$), em Sharpe, equivalente-certeza ou giro. Para que a otimização compensasse o erro de estimação, seriam necessárias janelas de estimação muito mais longas do que as disponíveis na prática. A carteira $1/N$ passou, desde então, a ser a referência mínima de qualquer estudo empírico.

As restrições de peso também interagem com o erro de estimação. Jagannathan and Ma (2003) mostram que proibir posições vendidas na GMV equivale a encolher a covariância amostral: as restrições ativas reduzem as covariâncias estimadas dos ativos que o otimizador queria vender. Por isso restrições "erradas", que não fazem parte das preferências do investidor, melhoram o desempenho fora da amostra. Esse resultado é central para interpretar comparações de estimadores em carteiras restritas, em que boa parte da regularização já vem das restrições.

Outras carteiras dependem de Σ de modos diferentes. A máxima diversificação de Choueifaty and Coignard (2008) maximiza a razão $w^\top \sigma / \sqrt{w^\top \Sigma w}$, em que σ é o vetor de volatilidades individuais. A paridade de risco iguala as contribuições de cada ativo para o risco total. Problemas de razão, como o máximo Sharpe e a máxima diversificação, podem ser reescritos como programas convexos por uma mudança de variáveis homogênea (Cornuéjols and Tütüncü, 2007). A carteira de mínimo *tracking error* minimiza a variância do retorno ativo em relação a um índice e depende da covariância conjunta entre os ativos e o índice.

2.2 Estimação de matrizes de covariância

2.2.1 Covariância amostral e o problema da dimensão

Dada uma janela de N retornos $r_1, \ldots, r_N \in \mathbb{R}^p$, a covariância amostral $S = \frac{1}{N-1} \sum_t (r_t - \bar{r})(r_t - \bar{r})^\top$ é não viesada, mas tem $p(p+1)/2$ parâmetros distintos. Quando $N < p$, S é singular; quando N é maior que p, mas da mesma ordem, S é mal condicionada. Os autovalores amostrais são mais dispersos que os verdadeiros: os maiores são superestimados e os menores, subestimados (Ledoit and Wolf, 2004b). Como a GMV usa Σ^{-1}, as direções de menor autovalor, justamente as mais mal estimadas, recebem o maior peso. O número de condição $\kappa = \lambda_{\max}/\lambda_{\min}$ mede essa fragilidade: quanto maior, mais a inversão amplifica o ruído (López de Prado, 2016, 2020).

A teoria de matrizes aleatórias torna esse diagnóstico preciso. Laloux et al. (1999) compararam o espectro de matrizes de correlação de ações com a distribuição de Marchenko-Pastur, que descreve os autovalores de uma matriz de correlação de séries independentes. A maior parte dos autovalores empíricos cai dentro da faixa prevista para ruído puro, e apenas poucos, associados ao mercado e a grandes setores, se destacam. Bun et al. (2017) revisam os estimadores que "limpam" o espectro, preservando os autovetores amostrais e corrigindo

os autovalores, entre eles o corte de autovalores (*eigenvalue clipping*) e os estimadores rotacionalmente invariantes.

2.2.2 Estrutura: correlação constante, setores e fatores

A primeira resposta ao erro de estimação foi impor estrutura. Elton and Gruber (1973) mostraram que modelos que supõem correlação constante entre todos os pares, ou constante dentro de grupos de empresas, preveem a correlação futura melhor que a correlação histórica par a par. Os modelos de fatores escrevem

$$\Sigma = B\,F\,B^{\top} + D, \tag{2.3}$$

em que B é a matriz $p \times k$ de exposições aos k fatores, F é a covariância dos fatores e D é diagonal, com as variâncias idiossincráticas. Com $k \ll p$, o número de parâmetros cai de ordem p^2 para ordem pk. Chan et al. (1999) compararam modelos de fatores na previsão de covariâncias e na construção de carteiras de variância mínima e encontraram que poucos fatores capturam a maior parte do ganho possível. O modelo de fator único, com o mercado como fator, é o caso mais simples. Os fatores podem ser observáveis, como mercado, setores, tamanho e momento, ou latentes, extraídos por componentes principais. No segundo caso, o número de fatores pode ser escolhido pelos critérios de informação de Bai and Ng (2002).

2.2.3 Shrinkage linear

Ledoit and Wolf (2003, 2004a,b) propuseram combinar a matriz amostral com um alvo estruturado T,

$$\hat{\Sigma} = \delta\,T + (1-\delta)\,S, \qquad 0 \le \delta \le 1, \tag{2.4}$$

escolhendo δ para minimizar a perda quadrática esperada $\mathbb{E}\|\hat{\Sigma} - \Sigma\|_F^2$. O alvo T tem poucos parâmetros e por isso pouca variância, mas é viesado; S não tem viés, mas tem muita variância. O δ ótimo equilibra as duas fontes de erro. Os três alvos clássicos são a identidade escalada (Ledoit and Wolf, 2004b), a correlação constante (Ledoit and Wolf, 2004a) e o fator único de mercado (Ledoit and Wolf, 2003). Para o alvo de correlação constante, Ledoit and Wolf (2004a) derivam

$$\delta^{*} = \max\!\left\{0,\ \min\!\left\{\frac{\hat{\kappa}}{N},\,1\right\}\right\}, \qquad \hat{\kappa} = \frac{\hat{\pi} - \hat{\rho}}{\hat{\gamma}}, \tag{2.5}$$

em que $\hat{\pi}$ estima a soma das variâncias assintóticas dos elementos de S, $\hat{\rho}$ estima a covariância assintótica entre o alvo e S, e $\hat{\gamma} = \|T - S\|_F^2$ mede a distância entre os dois. Quanto mais ruidosa a amostra e mais próximo o alvo, maior o peso do alvo.

A Equação (2.4) admite uma leitura de Bayes empírico: T é a média de um *prior* sobre Σ e δ é a confiança relativa nele. É essa leitura que abre espaço para alvos construídos com informação externa aos retornos, como os da Seção 2.5. Quando o alvo é uma matriz de correlação construída de fora, ela precisa ser positiva semidefinida; se não for, pode ser substituída pela matriz de correlação mais próxima, calculada por projeções alternadas (Higham, 2002).

2.2.4 Outras abordagens

O *shrinkage* linear move todos os autovalores na mesma proporção. Ledoit and Wolf (2017) propõem encolher cada autovalor de forma diferente, mantendo os autovetores amostrais, e Ledoit and Wolf (2020) obtêm uma fórmula analítica para esse estimador. O *shrinkage* não linear é uma das referências mais fortes da literatura e, como os demais desta seção, não usa nenhuma informação além dos retornos. Outra família impõe esparsidade: o *graphical lasso* (Friedman et al., 2008) penaliza a matriz de precisão Σ^{-1}, e o estimador POET (Fan et al., 2013) combina fatores latentes com um limiar na covariância residual.

Na direção bayesiana, o modelo de Black and Litterman (1992) combina um *prior* de equilíbrio com visões do investidor, cada uma com sua confiança, e He and Litterman (1999) explicam a escolha da incerteza do *prior*. O modelo foi formulado para os retornos esperados, mas Qian and Gorman (2001) mostram como incorporar visões sobre a própria covariância. A incerteza de uma covariância estimada segue a distribuição de Wishart (Anderson, 2003), o que dá uma escala natural para a confiança no *prior*.

2.3 Redes e grafos em finanças

Uma linha de pesquisa trata a matriz de correlação como uma rede e filtra dela a estrutura mais relevante. Mantegna (1999) transformou correlações em distâncias, $d_{ij} = \sqrt{2(1-\rho_{ij})}$, e extraiu a árvore geradora mínima do grafo completo, que agrupa as ações por setor sem que essa informação tenha sido usada. A paridade de risco hierárquica (HRP) de López de Prado (2016) leva a ideia ao otimizador: agrupa os ativos hierarquicamente pela distância de correlação e aloca o capital por bissecção recursiva, com pesos inversamente proporcionais à variância de cada grupo. A HRP nunca inverte Σ e é, por isso, menos sensível ao mau condicionamento.

As redes também podem vir de fora dos retornos. Lu et al. (2023) constroem redes de co-negociação, em que duas ações estão ligadas quando são negociadas em momentos próximos, e usam os grupos dessa rede para definir quais blocos da covariância idiossincrática são estimados. O método supera blocos definidos pela classificação setorial em volatilidade e Sharpe. É o precedente metodológico mais próximo da ideia de usar uma rede externa para estruturar Σ, embora sem texto.

2.4 Vínculos econômicos, texto e notícias

Há evidência ampla de que vínculos econômicos reais propagam informação entre empresas com atraso, o que sugere que esses vínculos também moldam a estrutura de covariância. Cohen and Frazzini (2008) usam as relações declaradas entre empresas e seus principais clientes e mostram que o retorno dos clientes prevê o retorno dos fornecedores no mês seguinte, efeito que atribuem à atenção limitada dos investidores. Menzly and Ozbas (2010) encontram previsibilidade cruzada entre indústrias ligadas nas tabelas de insumo-produto, mais forte onde há menos cobertura de analistas e menos investidores institucionais. Lee et al. (2019) documentam o mesmo fenômeno para empresas com tecnologias próximas, medidas pela sobreposição de patentes.

O texto permite medir vínculos que nenhuma classificação oficial registra. Hoberg and

Phillips (2016) calculam a similaridade entre as descrições de produtos nos relatórios anuais (formulário 10-K) e definem indústrias por texto (TNIC), que mudam ao longo do tempo e capturam a concorrência melhor que os códigos SIC e NAICS. As notícias são outra fonte. Scherbina and Schlusche (2020) identificam vínculos entre empresas pelas co-menções em notícias e mostram que os retornos das empresas líderes preveem os das seguidoras, mesmo sem relação de cliente e fornecedor. Guo et al. (2017) mostram que a cobertura conjunta gera transbordamento de atenção: notícias sobre uma empresa movem a atenção dos investidores para as empresas citadas junto, o que produz co-movimento e previsibilidade.

2.5 Texto e matriz de covariância

Três trabalhos levam a informação textual diretamente à estimação de Σ e são os antecedentes imediatos desta pesquisa.

Tang et al. (2019) medem a coocorrência de pares de empresas em notícias e mostram que ela prevê a correlação futura entre os retornos dos pares mesmo depois de controlar a correlação passada, ou seja, a persistência da correlação. Incorporada à estimação da covariância, a coocorrência melhora a GMV. É a evidência mais direta de que as notícias carregam informação sobre Σ, mas a variável é pobre: conta apenas se duas empresas aparecem juntas, sem distinguir o tipo nem o sinal da relação, e considera só pares de empresas negociadas.

Becquin and Esmeir (2023) usam a similaridade semântica entre empresas, obtida de *embeddings* de descrições textuais e de grafos de conhecimento, para estimar a covariância. O ponto central do trabalho é que a similaridade não deve ser usada como estimador direto, porque é descalibrada: sua escala depende do modelo e da dimensão do *embedding*. Ela serve, em vez disso, como alvo de *shrinkage*. A matriz de similaridade $\mathrm{Sim} = EE^{\top}$, com os *embeddings* normalizados, é lida como uma correlação; é convertida em covariância com as variâncias amostrais, $\mathrm{SimCov} = \mathrm{Sim} \odot \sqrt{\mathrm{diag}(S)\,\mathrm{diag}(S)^{\top}}$; tem os autovalores corrigidos para ser positiva semidefinida; e entra na Equação (2.4) com δ à maneira de Ledoit e Wolf. O método foi testado nos índices S&P 500, Nasdaq-100 e Nikkei entre 2007 e 2023, com três meses de estimação e um de avaliação. Os autores formulam ainda a hipótese de que o ganho de um alvo semântico é maior quando a história de preços é pouco informativa. Esse molde técnico, com o texto como *prior* e as variâncias vindas dos preços, é o seguido neste trabalho.

Lu et al. (2024) usam as redes TNIC de Hoberg and Phillips (2016) para encolher a matriz de correlação, com a intensidade do encolhimento escolhida por aprendizado por reforço. Em carteiras de variância mínima com mais de 400 ações e vinte anos de teste, o método supera os *shrinkages* padrão em volatilidade, Sharpe e risco de cauda, mesmo depois de custos de transação.

A Tabela 2.1 compara esses trabalhos entre si e com a proposta desta pesquisa.

2.6 Modelos de linguagem e informação financeira

A extração de relações a partir de texto foi, por muito tempo, uma tarefa de modelos supervisionados, treinados para um conjunto fixo de tipos de entidade e de relação, com dados anotados à mão. Os modelos de linguagem de grande porte ajustados para seguir instruções mudaram esse quadro: um mesmo modelo pode receber a definição da tarefa em linguagem

Tabela 2.1: Trabalhos que usam informação externa aos retornos para estimar a covariância.

trabalho	fonte	informação usada	tipo e sinal	entidades não negociadas
Tang et al. (2019)	notícias	coocorrência de pares	não	não
Becquin and Esmeir (2023)	descrições, grafo de conhecimento	similaridade de *embeddings*, como alvo de *shrinkage*	não	não
Lu et al. (2024)	relatórios 10-K (TNIC)	similaridade de produtos, encolhimento por aprendizado por reforço	não	não
Lu et al. (2023)	dados de negociação	co-negociação, blocos da covariância residual	não	não
este trabalho	notícias lidas por LLM	relações tipadas e datadas entre agentes	sim	sim

natural e devolver relações estruturadas, com custo baixo o bastante para processar centenas de milhares de documentos. Isso torna possível transformar um arquivo de notícias num grafo de conhecimento, em que os nós são agentes econômicos e as arestas são as ações que os ligam, datadas pela publicação da notícia.

O trabalho mais próximo desta pesquisa na construção do grafo é o de Li and Sanna Passino (2024), que ajustaram o modelo de pesos abertos Mistral 7B (Jiang et al., 2023) para gerar um grafo de conhecimento dinâmico a partir de notícias financeiras. Cada fato extraído é um evento (s,r,o,t): uma entidade de origem, uma relação entre quinze tipos fixos, uma entidade de destino e a data de publicação do artigo. As entidades incluem empresas, governos, reguladores, países, setores e indicadores econômicos. Aplicado a cerca de 400 mil artigos do *Wall Street Journal* entre 1999 e 2023, o método produziu o FinDKG, com 13.645 entidades e cerca de 144 mil fatos, usado para prever arestas futuras e para montar uma carteira temática de inteligência artificial.

O desenho do grafo desta pesquisa segue a mesma lógica: eventos datados entre agentes econômicos, tipos de relação, entidades que vão além das empresas negociadas e o grafo consultado em janelas que avançam no tempo. As diferenças são quatro. O modelo usado aqui não é ajustado: o Qwen2.5-14B-Instruct (Qwen Team, 2024) é guiado por instruções e por decodificação restrita a um esquema JSON. Cada relação tem tipo livre, direção e uma força entre 0 e 1, enquanto no FinDKG o sinal está embutido no tipo e não há intensidade. As entidades são associadas aos *tickers* das empresas, o que permite cruzar o grafo com os preços par a par. E, sobretudo, o FinDKG é usado para informar o retorno esperado, enquanto este trabalho usa o grafo para estimar a matriz de covariância, um problema que o FinDKG não aborda.

2.7 Avaliação de estimadores e inferência

2.7.1 Avaliação de previsões e de carteiras

A covariância verdadeira nunca é observada, e as previsões precisam ser comparadas com uma *proxy* ruidosa, como a covariância realizada no período seguinte (Patton, 2011). O critério econômico de Engle and Colacito (2006), a variância realizada da GMV, é o critério principal deste trabalho, e o R^2 fora da amostra de Campbell and Thompson (2008) mede o ganho de uma previsão sobre uma referência. Retornos diários têm caudas pesadas e dependência temporal, o que invalida os testes clássicos de igualdade de variâncias e de índices de Sharpe. Ledoit and Wolf (2008) propõem testar a diferença entre dois índices de Sharpe com *bootstrap* em blocos, e Ledoit and Wolf (2011) aplicam a mesma ideia à razão entre as variâncias de duas carteiras. Quando a mesma hipótese é testada mais de uma vez, a correção de Bonferroni divide o nível de significância pelo número de tentativas.

2.7.2 Inferência com dados de pares

As regressões em que a unidade é um par de ações exigem cuidado, porque pares que compartilham uma ação não são independentes. A regressão de Fama and MacBeth (1973) estima uma regressão em corte transversal em cada período e usa a série temporal dos coeficientes para a inferência, o que elimina a correlação entre pares do mesmo período; os erros-padrão da série são corrigidos para autocorrelação e heterocedasticidade por Newey and West (1987). O procedimento de atribuição quadrática (QAP) de Krackhardt (1988) testa a associação entre redes permutando juntas as linhas e colunas de uma das matrizes, o que preserva a estrutura de dependência entre os pares.

2.8 Lacuna e posicionamento do trabalho

A literatura revisada estabelece três pontos. Primeiro, a estimação de Σ é limitada pelo erro de estimação, e impor estrutura, por fatores, setores ou *shrinkage*, ajuda (Seção 2.2). Segundo, vínculos econômicos entre empresas, revelados por texto e por notícias, propagam informação e geram co-movimento (Seção 2.4). Terceiro, essa informação pode entrar na estimação de Σ como alvo de *shrinkage* ou como estrutura de blocos (Seção 2.5).

Os trabalhos que ligam texto a Σ, porém, usam o texto de forma limitada: contam co-menções ou medem similaridade estática entre descrições. Nenhum deles distingue o tipo da relação, se uma empresa fornece, concorre, processa ou adquire a outra, nem o seu sinal, e nenhum considera a exposição comum de empresas a entidades que não são negociadas, mas que movem preços, como bancos centrais, *commodities* e países. Até onde esta revisão alcançou, não há estudo que use relações extraídas por LLM, tipadas, com sinal e com entidades não negociadas, para estimar a matriz de covariância.

Do lado da extração, Li and Sanna Passino (2024) mostram que um LLM pode transformar notícias financeiras num grafo de conhecimento dinâmico com tipos de relação e entidades não negociadas, mas usam esse grafo para prever arestas e selecionar ações por tema, e não para estimar o risco conjunto dos ativos.

Este trabalho ocupa essa lacuna. Em relação a Tang et al. (2019), acrescenta o tipo, o sinal e a exposição comum a entidades; em relação a Becquin and Esmeir (2023), troca a

similaridade estática por relações datadas, que formam um grafo dinâmico; em relação a Li and Sanna Passino (2024), leva um grafo do mesmo tipo da previsão de retornos para a estimação da matriz de covariância. E, diferentemente dos três antecedentes, avalia o grafo sob um protocolo pré-registrado, com um placebo que separa o efeito do conteúdo das relações do efeito genérico de regularizar a matriz, e com correção para as tentativas repetidas (Seção 2.7).

Capítulo 3

Metodologia

Este capítulo descreve como a pergunta de pesquisa foi transformada em testes. A lógica é a da Seção 1.2: primeiro se verifica se o grafo de notícias prevê a correlação futura entre ações (H1) e, só então, se essa informação melhora as carteiras quando entra na estimação da matriz de covariância (H2). A Seção 3.1 dá uma visão geral do processo, cujos detalhes de dados e de extração ficam para os Capítulos 4 e 5. As seções seguintes tratam do protocolo que protege os testes contra a seleção de resultados, das hipóteses, dos atributos extraídos do grafo, dos testes de previsão de correlação, dos estimadores de Σ, das referências e do placebo, das carteiras, do desenho experimental e dos testes estatísticos.

3.1 Visão geral

O processo tem cinco etapas:

1. **Extração.** Um LLM lê cada artigo do corpus e devolve tuplas

$$(\text{agente}_a, \text{agente}_b, \text{tipo}, \text{direção}, \text{força}),$$

   datadas pela publicação do artigo (Capítulo 5).

2. **Grafo.** As tuplas são filtradas, os agentes são unificados e associados a *tickers*, e cada tupla vira um evento datado entre dois nós. O grafo numa data t é a agregação dos eventos anteriores a t (Seção 3.4).

3. **Atributos de par.** Do grafo em t saem medidas da ligação entre cada par de ações do universo: vínculo direto, exposição comum a entidades não negociadas e coocorrência.

4. **Estimação de Σ.** Os atributos entram na matriz de covariância como alvo de *shrinkage*, estrutura residual de um modelo de fatores ou visões de Black-Litterman, conforme o estimador (Seção 3.6).

5. **Carteira e avaliação.** Cada $\hat{\Sigma}$ alimenta um otimizador, a carteira é mantida até o rebalanceamento seguinte e os retornos realizados são comparados com os de estimadores de referência e de um placebo (Seções 3.8 a 3.10).

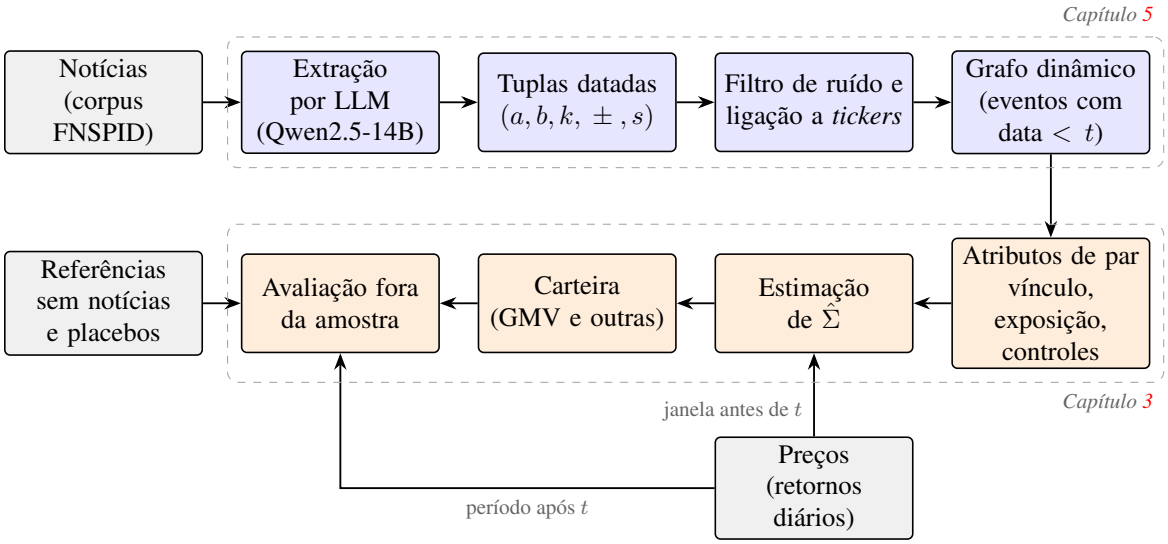


Figura 3.1: Visão geral do processo, das notícias à avaliação das carteiras. Em cinza, as entradas; em azul, a extração e a construção do grafo; em laranja, a estimação e a avaliação. Os preços entram na estimação apenas com a janela anterior a t e, na avaliação, com o período posterior.

A Figura 3.1 resume o fluxo. As etapas em azul são descritas no Capítulo 5; as em laranja, neste capítulo.

Uma regra vale para todas as etapas: nada do que entra numa decisão tomada em t pode depender de informação posterior a t. Como a data de publicação das notícias do corpus não tem hora (Capítulo 4), uma notícia do dia d pode ter saído depois do fechamento; o grafo em t usa, por isso, apenas eventos com data estritamente anterior a t.

3.2 Protocolo de pré-registro

Comparar vários estimadores, carteiras e parâmetros no mesmo período cria o risco de encontrar, por acaso, uma combinação que parece funcionar. Para controlar esse risco, o trabalho adotou um protocolo de pré-registro incremental:

- cada desenho de teste foi escrito e versionado no repositório do projeto *antes* de ser executado com os dados reais, com o modelo, as referências, a estatística, o nível de significância e o critério de sucesso fixados;
- qualquer mudança feita depois da execução foi registrada como tal, com o motivo, e os resultados das versões anteriores foram mantidos;
- quando um desenho falhou e um novo desenho foi proposto para a mesma hipótese, o nível de significância do novo foi reduzido pela correção de Bonferroni ($0{,}05/k$ para o k-ésimo desenho), de modo que tentar de novo não aumenta a chance de um falso positivo;
- os parâmetros de construção do grafo (janela de 365 dias e meia-vida de 90 dias) e a janela de estimação (252 pregões) foram fixados antes do primeiro teste e não foram

calibrados;

- todo resultado de carteira é confrontado com um placebo e confirmado em universos de outros tamanhos, e os primeiros desenhos foram refeitos depois que a amostra de artigos foi ampliada.

Os desvios em relação aos pré-registros são declarados no ponto do texto em que ocorrem, e as análises feitas depois de conhecido um resultado são identificadas como exploratórias.

3.3 Hipóteses

As duas hipóteses gerais foram apresentadas na Seção 1.2. H1 diz que o grafo contém informação sobre a correlação futura; H2, que essa informação melhora as carteiras. Para que H1 possa ser testada, é preciso dizer *por qual canal* o grafo carregaria essa informação. A teoria de finanças oferece dois canais, que dão as duas hipóteses específicas de H1. São, ao todo, três hipóteses, resumidas na Tabela 3.1.

H1a: exposição comum. Nos modelos de fatores, duas ações covariam porque estão expostas às mesmas fontes de risco sistemático (Ross, 1976; Chan et al., 1999). Parte dessas fontes são entidades que não são negociadas como ações, como a política monetária, o preço do petróleo ou a economia chinesa, e as notícias registram quais empresas são afetadas por cada uma. Se duas empresas aparecem ligadas às mesmas entidades, elas devem ter cargas parecidas nos fatores correspondentes e, portanto, correlação maior. A exposição comum g_{ij} da Equação (3.2) mede essa semelhança, e a hipótese é que ela preveja a correlação futura do par além da correlação histórica e do setor. O setor de Elton and Gruber (1973) é o controle natural, porque também é uma forma de exposição comum, só que fixa e grosseira.

H1b: tipo de relação. A literatura de vínculos econômicos mostra que relações diretas entre empresas transmitem choques, e que o canal depende do tipo de relação. Clientes e fornecedores dividem o mesmo fluxo de demanda (Cohen and Frazzini, 2008; Menzly and Ozbas, 2010); concorrentes disputam o mesmo mercado de produtos e respondem aos mesmos choques de demanda e de custo (Hoberg and Phillips, 2016); empresas com tecnologias próximas compartilham choques de inovação (Lee et al., 2019); e participações acionárias e aquisições ligam diretamente os fluxos de caixa. Nem todo vínculo, porém, deveria ter o mesmo efeito: uma disputa judicial ou uma ação regulatória não cria exposição econômica duradoura. A hipótese é que os efeitos dos grupos de relação sobre a correlação residual futura sejam diferentes entre si. Como cada relação extraída também tem um sinal, a análise de H1b examina ainda se o sinal atribuído pelo LLM indica a direção do co-movimento.

H2: as notícias como *prior* da correlação. Na leitura bayesiana do *shrinkage*, o alvo é a média de um *prior* sobre Σ, e um alvo mais próximo da covariância verdadeira dá uma estimativa melhor (Ledoit and Wolf, 2004a). Becquin and Esmeir (2023) mostram que um alvo construído com texto pode ajudar, e Lu et al. (2023), que uma rede externa aos retornos pode estruturar a parte da covariância que o mercado não explica. Se H1 vale, as notícias preveem a correlação de cada par, e essa previsão é um *prior* candidato. A hipótese é que

a carteira de variância mínima construída com o *prior* de setor e notícias tenha variância realizada menor que a construída com o *prior* só de setor, a referência que encarna Elton and Gruber (1973), e que o ganho venha do conteúdo das notícias: a carteira deve superar também um placebo em que os atributos de notícia são embaralhados entre as ações. H2 foi testada numa sequência de nove desenhos (Tabela 3.3), que variam o modo de levar as notícias à matriz e o otimizador.

Tabela 3.1: Hipóteses do trabalho, fundamentação e teste.

	hipótese	fundamentação	teste
H1a	a exposição comum a entidades não negociadas prevê a correlação futura do par além do histórico e do setor	modelos de fatores; Elton and Gruber (1973), Chan et al. (1999)	ganho fora da amostra (escada E0–E4) e coeficiente de g_{ij} nos testes de pares
H1b	os tipos de relação direta têm efeitos diferentes sobre a correlação residual futura	Cohen and Frazzini (2008), Menzly and Ozbas (2010), Hoberg and Phillips (2016)	Wald da igualdade dos coeficientes de grupo
H2	a variância mínima com o *prior* de setor e notícias tem variância realizada menor que com o *prior* de setor e que com o placebo	Ledoit and Wolf (2004a), Becquin and Esmeir (2023), Lu et al. (2023)	razão de variâncias, placebo e confirmação em outros universos

O trabalho se limita a essas três hipóteses de propósito. Cada uma tem um mecanismo econômico descrito na literatura, uma previsão fixada antes do teste e uma estatística própria, e cada uma é examinada a fundo: com controles que separam o canal das explicações mais simples (histórico, setor, atenção da mídia), com inferência adequada à dependência entre pares e, nas carteiras, com placebo e confirmação em universos de tamanhos diferentes. Investigar poucas hipóteses bem fundamentadas com esse cuidado informa mais do que testar muitas ideias com menos rigor, e reduz o risco de que um resultado positivo surja apenas do número de tentativas.

3.4 Atributos de par a partir do grafo

3.4.1 O grafo numa data

Cada relação extraída e filtrada é um evento e entre dois nós, com data t_e, classe de relação c_e, sinal $\mathrm{sgn}_e \in \{-1, +1\}$ e força $s_e \in [0{,}1]$. O grafo na data t agrega os eventos da janela $[t - W, t)$, com $W = 365$ dias corridos, ponderados por um decaimento exponencial de meia-vida τ:

$$w_e(t) = \mathrm{sgn}_e \, s_e \, 0{,}5^{\,(t-t_e)/\tau}. \tag{3.1}$$

A meia-vida é $\tau = 90$ dias em todos os testes, valor fixado sem calibração.

3.4.2 Vínculo direto

Para duas ações i e j do universo, o vínculo direto soma os eventos entre elas, nos dois sentidos. Na forma com sinal, $w_{ij} = \sum_e w_e(t)$; separando por sinal, w_{ij}^{+} e w_{ij}^{-} são as so-

mas, em módulo, dos eventos positivos e negativos; e, por grupo k de classes de relação, $d_{ij}^{(k)} = \sum_{e:\, c_e \in k} |w_e(t)|$. Os grupos reúnem classes com efeito econômico parecido sobre o co-movimento. Nas regressões que alimentam as carteiras, são cinco: cadeia (*supply chain* e parceria), concorrência, controle (participação acionária e fusões e aquisições), impacto e outros. Nos testes de H1b, a cadeia e a parceria são separadas e há um grupo legal e regulatório, o que dá seis grupos mais o residual. Como os vínculos têm cauda longa, entram nas regressões como $\log(1+d)$ ou, com sinal, como $\operatorname{sgnlog}(w) = \operatorname{sgn}(w)\log(1+|w|)$.

3.4.3 Exposição comum

Arestas diretas entre ações são raras, mas muitos pares compartilham alguma entidade que não é negociada, como o Federal Reserve, o petróleo ou a China (Capítulo 5). A exposição comum mede essa ligação indireta. Seja $\tilde{A}$ a matriz ações $\times$ entidades fora do universo, com $\tilde{A}_{im}$ igual à soma dos eventos entre a ação i e a entidade m. Cada coluna é ponderada pelo inverso da frequência da entidade (IDF),

$$\operatorname{idf}_m = \log \frac{n_t}{\operatorname{df}_m},$$

em que n_t é o número de empresas com *ticker* presentes no grafo da janela e df_m é o número delas ligadas a m. Assim, uma entidade ligada a quase todas as empresas, como "S&P 500", pesa pouco, e "petróleo" pesa para as petroleiras. Com as linhas normalizadas para norma unitária, a exposição comum é o cosseno

$$g_{ij} = \left(\tilde{A}\tilde{A}^{\top}\right)_{ij} = \cos(\tilde{A}_i, \tilde{A}_j). \tag{3.2}$$

A matriz $G = [g_{ij}]$ é a projeção do grafo bipartido ações–entidades sobre as ações. Uma ação sem nenhuma entidade na janela tem $g_{ij} = 0$ com todas as outras. Nas regressões do universo das ações mais citadas, $\tilde{A}$ usa o módulo dos eventos, e $g_{ij} \in [0,1]$; nos testes de pares do universo do S&P 500, usa o sinal, e $g_{ij} \in [-1,1]$, negativo quando as duas ações se ligam às mesmas entidades com efeitos opostos.

3.4.4 Controles

Três atributos separam o conteúdo das relações de efeitos mais simples:

- **coocorrência**: número de artigos extraídos em que i e j aparecem em algum evento, com ou sem relação entre si; separa "o LLM encontrou uma relação" de "saíram no mesmo texto";
- **co-menção**: número de artigos do corpus marcados com os dois *tickers*, a variável de Tang et al. (2019);
- **setor**: indicadores de mesmo setor na classificação Fama-French de 49 indústrias e no código SIC de dois dígitos, o controle de Elton and Gruber (1973).

Os testes de pares acrescentam a atenção da mídia, $\log(1+m_i) + \log(1+m_j)$ e $|\log(1+m_i) - \log(1+m_j)|$, em que m_i é o número de eventos da ação i na janela, e a distância de tamanho entre as duas empresas.

3.5 Previsão de correlação e testes de pares

H1 é testada de dois modos complementares. O primeiro mede, fora da amostra, quanto os atributos de notícia melhoram a previsão da correlação de cada par, no universo das ações mais citadas. O segundo estima o efeito de cada atributo com inferência adequada a dados de pares, no universo do S&P 500, que não depende das notícias (Capítulo 4).

3.5.1 Regressão preditiva de correlação

Em cada data de rebalanceamento t, para cada par (i,j) do universo, a variável dependente é a correlação realizada no período de carteira seguinte, ρ_{ij}^{fut}, na escala de Fisher $z(\rho) = \operatorname{atanh}(\rho)$, que estabiliza a variância. A especificação mais completa é

$$z(\rho_{ij}^{\text{fut}}) = a + b\, z(\rho_{ij}^{\text{hist}}) + \sum_{k} \beta_k \log\!\left(1 + d_{ij}^{(k)}\right) + \gamma\, g_{ij} + \theta^{\top} x_{ij} + \varepsilon_{ij}, \tag{3.3}$$

em que ρ_{ij}^{hist} é a correlação nos 252 pregões anteriores a t e x_{ij} reúne coocorrência, co-menção e setor. Os coeficientes β_k e γ traduzem cada tipo de relação em correlação. As especificações testadas formam uma escada:

- E0, persistência: só $z(\rho^{\text{hist}})$;
- E1: E0 com co-menção;
- E2: E0 com coocorrência;
- E3: E0 com vínculos diretos por grupo e exposição comum;
- E4: todos os atributos.

E0, E1 e E4 também são estimadas com os indicadores de setor. A comparação central é entre E0 com setor e E4 com setor: a diferença mede o que as notícias acrescentam ao histórico e ao setor.

O desempenho é medido fora da amostra. Em cada t, os coeficientes são estimados no painel empilhado dos rebalanceamentos anteriores (janela expansiva, com ao menos 24 meses) e aplicados aos pares de t. A variável dependente e os regressores são centrados em cada mês, de modo que a regressão explica a ordenação dos pares dentro do mês, e não o nível médio da correlação. O R^2 fora da amostra (Campbell and Thompson, 2008) é

$$R^2_{oos} = 1 - \frac{\sum_t \sum_{(i,j)} (y_{ij,t} - \hat{y}_{ij,t})^2}{\sum_t \sum_{(i,j)} (y_{ij,t} - \bar{y}_t)^2},$$

com as somas sobre todos os pares e meses de avaliação. O ganho de uma especificação sobre outra é a diferença dos seus R^2_{oos}, testada com erro-padrão de Newey and West (1987) na série mensal das diferenças de erro quadrático.

3.5.2 Correlação residual

A correlação total entre ações é dominada pelo mercado. Para isolar o que é específico de cada par, os testes também usam a correlação residual a um fator de mercado. Seja m_t a média igual dos retornos do universo no dia. Na janela de estimação, cada ação é regredida no mercado,

$$x_{it} = a_i + b_i\, m_t + e_{it}, \tag{3.4}$$

e a correlação residual realizada no período seguinte é calculada com os resíduos fora da amostra, com os b_i da janela e o m_t observado. A escada E0–E4 é estimada para a correlação total e para a residual.

3.5.3 Testes de pares

Os testes de pares usam a correlação residual dos $h = 21$ pregões seguintes como variável dependente e todos os meses de 2011 a 2023. A regressão é

$$z(\rho^{\text{fut}}_{e,ij}) = a + b\, z(\rho^{\text{hist}}_{e,ij}) + \gamma\, g_{ij} + \sum_k \beta_k \log\!\left(1 + d^{(k)}_{ij}\right) + \theta^{\top} c_{ij} + \varepsilon_{ij}, \tag{3.5}$$

em que ρ_e é a correlação residual e c_{ij} reúne os indicadores de mesmo setor (Fama-French 49 e SIC de dois dígitos), a distância de tamanho e os dois termos de atenção. Na análise do sinal, a soma sobre os grupos é trocada por $\beta\,\mathrm{sgnlog}(w_{ij})$ ou por $\beta^{+}\log(1+w^{+}_{ij}) + \beta^{-}\log(1+w^{-}_{ij})$.

Pares que compartilham uma ação não são independentes. Por isso a inferência usa a regressão de Fama and MacBeth (1973): uma regressão em corte transversal em cada mês, com os regressores padronizados no mês, e a média dos coeficientes mensais, com erro-padrão de Newey and West (1987) com $L = 3 + h/21$ defasagens. Cada coeficiente mede, assim, a variação de $z(\rho)$ por um desvio-padrão do regressor. Como segunda inferência, o procedimento QAP (Krackhardt, 1988) permuta juntas as linhas e colunas de todas as matrizes de notícia em cada mês e refaz o Fama-MacBeth; o p é a fração de permutações com estatística ao menos tão extrema quanto a observada, com 1.000 permutações, o que limita o menor p possível a $1/1001 \approx 0{,}001$. O p de cada teste é o maior entre o de Fama-MacBeth e o do QAP. A Tabela 3.2 resume a estatística de cada teste.

Tabela 3.2: Estatísticas e critérios dos testes de pares.

	estatística	sucesso
H1a	coeficiente γ da exposição comum, com a aresta direta e os controles	positivo e significativo
H1b	teste de Wald da igualdade dos seis coeficientes de grupo β_k, com covariância de Newey-West	igualdade rejeitada
H1b, sinal	coeficiente de $\mathrm{sgnlog}(w)$ e diferença $\beta^{+} - \beta^{-}$	positivos e significativos

3.6 Estimadores da matriz de covariância com notícias

Três modos de levar as notícias à matriz de covariância foram testados. Em todos, as variâncias vêm dos preços, e as notícias atuam apenas sobre as correlações.

3.6.1 Alvo de shrinkage com notícias

O primeiro modo segue Becquin and Esmeir (2023): as notícias definem a correlação-alvo. A correlação prevista para o par (i,j) é

$$R^T_{ij} = \tanh\big(\bar{z} + \beta^\top f_{ij}\big), \qquad R^T_{ii} = 1, \tag{3.6}$$

em que $\bar{z}$ é a correlação média da janela em escala z, f_{ij} são os atributos de notícias (e de setor) e β é estimado por mínimos quadrados no painel dos meses anteriores, com y e f centrados no mês. A correlação histórica do par não entra em (3.6): com ela, o alvo dependeria da mesma amostra que S, o que viola a hipótese de alvo fixo da fórmula de δ. Com $\beta = 0$, o alvo é a correlação constante de Ledoit and Wolf (2004a); como $\bar{z}$ é a média da janela, o alvo preserva o nível médio da correlação, isto é, o modo de mercado. Se R^T não for positiva semidefinida, é substituída pela correlação mais próxima (Higham, 2002). A covariância-alvo é $T = D^{1/2} R^T D^{1/2}$, com $D = \operatorname{diag}(S)$, e o estimador é a Equação (2.4).

O δ ótimo generaliza a fórmula de Ledoit and Wolf (2004a), trocando a correlação constante $\bar{r}$ pela correlação-alvo r^T_{ij} de cada par:

$$\begin{aligned}
\hat{\pi} &= \sum_{i,j} \widehat{\operatorname{AsyVar}}\big(\sqrt{N} s_{ij}\big), \qquad \hat{\gamma} = \|T - S\|_F^2, \\
\hat{\rho} &= \sum_i \hat{\pi}_{ii} + \sum_{i \neq j} \frac{r^T_{ij}}{2} \left(\sqrt{\frac{s_{jj}}{s_{ii}}}\, \hat{\vartheta}_{ii,ij} + \sqrt{\frac{s_{ii}}{s_{jj}}}\, \hat{\vartheta}_{jj,ij} \right), \\
\delta^* &= \max\left\{0,\ \min\left\{ \frac{\hat{\pi} - \hat{\rho}}{N\hat{\gamma}},\ 1 \right\}\right\},
\end{aligned} \tag{3.7}$$

em que $\hat{\pi}_{ij} = \frac{1}{N}\sum_t [(r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j) - s_{ij}]^2$ estima a variância assintótica de $\sqrt{N} s_{ij}$ e $\hat{\vartheta}_{ii,ij} = \frac{1}{N}\sum_t [(r_{it} - \bar{r}_i)^2 - s_{ii}][(r_{it} - \bar{r}_i)(r_{jt} - \bar{r}_j) - s_{ij}]$ estima a covariância assintótica entre $\sqrt{N} s_{ii}$ e $\sqrt{N} s_{ij}$. Como em Ledoit and Wolf (2004a), o alvo usa as variâncias amostrais, as covariâncias entre as variâncias e os elementos fora da diagonal entram em $\hat{\rho}$, e S é calculada com divisor N nessas fórmulas.

3.6.2 Fator de mercado e correlação residual

O segundo modo aplica as notícias à parte da covariância que o mercado não explica, como na Equação (2.3) com um fator. Com o modelo (3.4) estimado na janela,

$$\hat{\Sigma} = \hat{\sigma}^2_m \, b\, b^\top + \hat{\Sigma}_e, \tag{3.8}$$

em que $\hat{\sigma}^2_m$ é a variância do mercado, b é o vetor de betas e $\hat{\Sigma}_e$ é a covariância dos resíduos E, encolhida para uma correlação residual *a priori* R_{prior} pela fórmula (3.7). O que muda entre os estimadores é R_{prior}:

- identidade: o modelo de fator único puro;
- correlação constante $\bar{r}_e$: a referência estatística;
- $\tanh(\bar{z}_e + \beta^\top \text{setor})$: a **referência a bater**;

- $\tanh(\bar{z}_e + \beta^\top[\text{setor,notícias}])$: o **modelo principal**;
- o anterior com os atributos de notícia permutados entre as ações: o placebo.

Aqui, β é estimado com y igual à correlação residual realizada no mês. É o desenho de Lu et al. (2023), com a rede de notícias no lugar da rede de co-negociação. Como o fator de mercado fica fora do *prior*, as notícias não precisam descrever o modo comum a todas as ações, apenas o que os pares têm em comum além dele, que é onde H1 mostra que elas informam.

3.6.3 Black-Litterman na covariância

Nos dois modos anteriores, um único δ vale para todos os pares: um par com centenas de eventos e um par ligado só por exposição comum recebem o mesmo peso da notícia. O terceiro modo dá a cada par a confiança que a sua evidência justifica, na estrutura de Black and Litterman (1992) aplicada à covariância (Qian and Gorman, 2001). Apenas a covariância residual Σ_e da Equação (3.8) é atualizada.

- **Prior.** Σ_0 é a covariância residual do modelo com setor, a referência a bater, com variâncias $s_i = (\Sigma_0)_{ii}$. A incerteza do prior sobre os elementos fora da diagonal é a covariância de Wishart da covariância amostral (Anderson, 2003), avaliada em Σ_0 com $N = 252$ pregões:

$$V_{(ij),(kl)} = \frac{\sigma_{0,ik}\,\sigma_{0,jl} + \sigma_{0,il}\,\sigma_{0,jk}}{N}, \tag{3.9}$$

  o análogo, na covariância, da convenção de He and Litterman (1999) de tomar a incerteza do *prior* como o inverso do tamanho da amostra. Uma visão sobre o par (i,j) move também os pares (i,l) e (j,l), na proporção das covariâncias do prior.

- **Visões.** Há uma visão para cada par com algum atributo de notícia não nulo. Seu valor é a correlação prevista pelo modelo com setor e notícias, na escala da covariância: $q_{ij} = \tanh(\hat{z}_{ij})\sqrt{s_i s_j}$. A matriz P seleciona o elemento (i,j) de $\operatorname{vec}\Sigma_e$, de modo que a visão é linear em Σ_e.

- **Confiança.** Cada par com visão cai numa classe de evidência c: só exposição comum ou co-menção ($c = 0$), ou um dos quatro quartis de coocorrência ($c = 1,\ldots,4$). Para cada classe, o erro da visão em escala z é estimado no painel dos meses de treino, descontado o ruído amostral de uma correlação de d_m pregões,

$$\omega_c = \overline{\hat{e}^2}\big|_c - \overline{1/(d_m - 3)}, \qquad \omega_c \geq \frac{1}{N-3}, \tag{3.10}$$

  e levado à escala da covariância pelo método delta, $\Omega_{ij} = (1 - \tanh^2 \hat{z}_{ij})^2\, s_i s_j\, \omega_{c(ij)}$.

- **Posterior.** É a média do Black-Litterman na forma de filtro de Kalman,

$$\operatorname{vec}\Sigma_e^{BL} = \operatorname{vec}\Sigma_0 + VP^\top\big(PVP^\top + \Omega\big)^{-1}\big(q - P\operatorname{vec}\Sigma_0\big), \tag{3.11}$$

  resolvida por gradiente conjugado sem formar V, e projetada para a correlação positiva semidefinida mais próxima, com as variâncias de volta.

3.7 Estimadores de referência e placebo

Cada estimador com notícias tem uma referência sem notícias que só difere dele pela informação do grafo: o alvo de setor, no primeiro modo, e o fator de mercado com resíduo encolhido para o setor, nos outros dois. Essa referência encarna o resultado de Elton and Gruber (1973) e é a hipótese nula natural para um grafo que, como se verá, liga sobretudo empresas do mesmo setor. Para situar os resultados na literatura, as tabelas trazem também as referências estatísticas usuais: a carteira $1/N$ (DeMiguel et al., 2009), a covariância amostral, o *shrinkage* linear de Ledoit e Wolf com os três alvos clássicos (identidade, correlação constante e fator único) e o *shrinkage* não linear (Ledoit and Wolf, 2020).

Superar a referência não basta: o ganho poderia vir apenas de regularizar a matriz com qualquer estrutura esparsa. O placebo testa se o *conteúdo* das relações importa. Em cada mês, as ações são permutadas ao acaso nas matrizes de atributos de notícia, com a mesma permutação em todos os atributos, enquanto o setor e os retornos ficam no lugar; os coeficientes β são os treinados com os dados reais. O placebo tem, portanto, a mesma distribuição de vínculos, a mesma esparsidade e a mesma intensidade de *shrinkage* que as notícias verdadeiras, mas liga as empresas erradas. Se as notícias fossem só regularização genérica, o placebo empataria com elas.

3.8 Carteiras

Os estimadores foram avaliados nas seguintes carteiras, todas com soma dos pesos igual a um:

- **GMV sem restrição**, Equação (2.2): a carteira em que o erro de $\hat{\Sigma}$ passa inteiro para os pesos; é a carteira principal;
- **variância mínima restrita**: sem venda a descoberto e com teto de 10% por ativo, resolvida por gradiente projetado (FISTA);
- **Markowitz**, Equação (2.1) com $\gamma = 5$, e **máximo Sharpe**, com retornos esperados de Bayes-Stein (Jorion, 1986) calculados na janela;
- **máxima diversificação** (Choueifaty and Coignard, 2008);
- **HRP** (López de Prado, 2016), com a distância de correlação $\sqrt{(1-\rho_{ij})/2}$, a mesma da Seção 2.3 a menos de uma constante;
- **mínimo *tracking error*** contra o SPY, com a covariância entre ativos e índice estimada na janela.

Os problemas de razão (máximo Sharpe e máxima diversificação) com restrições foram resolvidos pela reformulação convexa homogênea (Cornuéjols and Tütüncü, 2007) por pontos interiores.

3.9 Desenho experimental

3.9.1 Configuração comum

Todas as avaliações de carteira seguem a mesma configuração:

- universo das n ações mais citadas nas notícias (Capítulo 4), com $n = 100$ no teste principal e $n = 50$ e $n = 200$ como confirmação; com a janela de 252 pregões, há sempre mais observações que ações;
- rebalanceamento no primeiro pregão de cada mês, com a carteira mantida até o rebalanceamento seguinte;
- janela de estimação de 252 pregões anteriores ao rebalanceamento;
- período avaliado de janeiro de 2013 a dezembro de 2023; os anos de 2011 e 2012 servem apenas para treinar os coeficientes que transformam notícias em correlação, que exigem ao menos 24 meses de histórico;
- coeficientes treinados só com meses cujo período de carteira terminou antes de t;
- custo de transação de 10 pontos-base sobre o giro, medido contra os pesos que a carteira teria depois de variar com os preços desde o último rebalanceamento;
- SPY como índice de referência.

3.9.2 Os desenhos testados para H2

A Tabela 3.3 lista os desenhos na ordem em que foram testados, com o critério de sucesso de cada um. Cada desenho surgiu do resultado do anterior, e o nível de significância caiu a cada nova tentativa (Seção 3.2). O D1 foi exploratório; o D2 é o teste principal de H2, com três critérios fixados antes da execução; os demais perguntam se o resultado do D2 muda com restrições de peso, com outro otimizador ou com outro modo de combinar as notícias.

A melhora é medida pela razão de variâncias dos retornos líquidos (variância mínima, máxima diversificação, HRP), pela diferença de Sharpe líquido (Markowitz, máximo Sharpe) ou pela razão de variâncias do retorno ativo (mínimo *tracking error*).

3.10 Métricas e testes estatísticos

Razão de variâncias. A estatística principal das carteiras é a razão entre as variâncias dos retornos diários líquidos de duas carteiras nos pregões em comum, com a carteira com notícias no numerador: valores abaixo de 1 favorecem as notícias. O p-valor bicaudal e o intervalo de confiança vêm de um *bootstrap* circular em blocos de 10 dias, com 2.000 reamostragens dos pares de retornos (Ledoit and Wolf, 2011), o que preserva a dependência temporal e a correlação entre as duas carteiras. A diferença de índices de Sharpe é testada da mesma forma (Ledoit and Wolf, 2008).

Tabela 3.3: Desenhos testados para H2, na ordem de execução.

	desenho	critério de sucesso
D1	alvo de notícias, GMV	exploratório, sem critério fixado
D2	fator + resíduo, GMV sem restrição	(i) as notícias preveem a correlação residual além do setor, com $t > 2$; (ii) razão de variâncias contra o setor < 1 com $p < 0{,}05$ e abaixo do placebo em $n = 100$; (iii) razão < 1 em $n = 50$ e 200 e com a amostra ampliada de notícias
D3	fator + resíduo, variância mínima sem venda a descoberto e teto de 10%	razão < 1 com $p < 0{,}025$ e abaixo do placebo em $n = 100$; razão < 1 em $n = 50$ e 200
D4–D8	fator + resíduo em Markowitz, máximo Sharpe, máxima diversificação, HRP e mínimo *tracking error*	melhora com $p < 0{,}01$ por otimizador e melhor que o placebo; mesma direção em $n = 50$ e 200
D9	Black-Litterman na covariância, GMV sem restrição	razão < 1 com $p < 0{,}0125$ e abaixo do placebo em $n = 100$; razão < 1 em $n = 50$ e 200

Erro de correlação. A qualidade de $\hat{\Sigma}$ como previsão é medida pelo erro quadrático médio entre as correlações estimadas e as realizadas no mês seguinte. A diferença entre dois estimadores é testada na série mensal, com erro-padrão de Newey-West, como no teste de Diebold and Mariano (1995).

Critérios e tentativas repetidas. H1a tem dois critérios: ganho fora da amostra positivo com $t > 2$ na escada E0–E4 e coeficiente positivo e significativo a 5% nos testes de pares. H1b é avaliada pelo teste de Wald, e os coeficientes individuais dos grupos são corrigidos pelo método de Benjamini and Hochberg (1995). Para H2, o nível de significância cai a cada novo desenho pela correção de Bonferroni (Seção 3.2).

Diagnóstico de estabilidade. O número de condição $\lambda_{\max}/\lambda_{\min}$ da correlação estimada é registrado mês a mês para cada estimador (López de Prado, 2016). Ele não é critério de sucesso, mas mede quanto a inversão da matriz amplifica o erro e ajuda a explicar por que um estimador que prevê melhor as correlações pode produzir uma carteira pior.

Capítulo 4

Dados

O trabalho usa três fontes de dados: o corpus de notícias e o painel de preços do conjunto FNSPID (Dong et al., 2024) e a classificação setorial das empresas, obtida dos registros da SEC, a comissão de valores mobiliários dos Estados Unidos. Este capítulo descreve cada fonte, os problemas encontrados nela e como foram tratados, e os universos de ações usados nos testes. Os números foram medidos sobre os arquivos usados, e não tomados da documentação do conjunto.

4.1 O corpus de notícias FNSPID

4.1.1 Descrição do conjunto

O FNSPID (*Financial News and Stock Price Integration Dataset*) reúne notícias financeiras e séries de preços de ações dos Estados Unidos e está disponível publicamente no repositório Hugging Face (Dong et al., 2024). A parte de notícias é um único arquivo CSV de 21,6 GiB (23.232.979.597 bytes) com doze colunas: índice, data, título, *ticker*, URL, editor, autor, texto do artigo e quatro resumos extrativos gerados por algoritmos (LSA, Luhn, TextRank e LexRank).

O arquivo tem uma linha por par (artigo, *ticker*): um artigo que cita cinco empresas aparece cinco vezes. Ele mistura formatos de fontes diferentes e, das suas 15.549.299 linhas, 63,1% não têm *ticker* e 75,9% não têm texto, só título. Na parte final estão 799.037 artigos do portal russo lenta.ru, de notícias gerais e sem nenhum *ticker*.

4.1.2 Ingestão e curadoria

O arquivo foi lido diretamente do repositório remoto, em fragmentos independentes, com o banco de dados analítico DuckDB. Como o texto dos artigos contém quebras de linha dentro de campos entre aspas, as fronteiras dos fragmentos são localizadas por um padrão estrutural (uma quebra de linha seguida de um número e de uma data) que não ocorre dentro do texto; validado em amostras de várias regiões do arquivo, o procedimento não produziu nenhum registro quebrado.

A camada curada separa os artigos (uma linha por artigo) das suas marcações de *ticker* (uma linha por par artigo–*ticker*), o que elimina a duplicação do formato original. O identificador do artigo é a URL ou, quando ela não existe, um *hash* do texto normalizado. As

15.549.299 linhas do arquivo se reduzem a 12.746.534 artigos distintos. Desses, 2.953.850 têm ao menos um *ticker* marcado, somando 5.730.655 marcações de 8.552 *tickers* distintos. O número de artigos marcados cresce de 6 mil em 2009 para 123 mil em 2011 e fica entre 120 mil e 340 mil por ano até 2023. Antes de 2010 quase não há artigos marcados, o que, somado à escassez de relações extraídas nesses anos (Capítulo 5), restringe o período útil do trabalho a 2011–2023.

A data de publicação do corpus não tem hora: todo registro está à meia-noite. Uma notícia datada do dia d pode, portanto, ter saído depois do fechamento do mercado em d. Por isso, como já dito na Seção 3.1, todas as decisões tomadas em t usam apenas notícias com data anterior a t.

4.1.3 Unidades de extração e amostra

As unidades enviadas ao LLM são os artigos com texto, depois de três reduções: cada artigo aparece uma só vez, qualquer que seja o número de *tickers* marcados; artigos republicados com o mesmo texto sob URLs diferentes são reunidos por um *hash* do texto normalizado; e os 10.322.619 artigos sem texto ou com menos de 200 caracteres são excluídos. Os artigos do lenta.ru também foram excluídos, por estarem fora do escopo do trabalho, o que reduziu as unidades de 2.321.501 para **1.607.982**.

Por restrição de orçamento de processamento, a extração foi feita numa amostra. A seleção é determinística e aninhada: cada unidade recebe um número pseudoaleatório derivado do *hash* do seu identificador, e a amostra de fração f contém as unidades com número menor que f. Assim, uma amostra maior sempre contém a menor, e ampliá-la exige processar apenas as unidades novas. A extração foi feita primeiro com 25% das unidades e depois ampliada até 572.762 unidades, 35,6% do total, quando o orçamento acabou. Como as unidades foram processadas em ordem do próprio *hash*, a parte extraída é uma subamostra uniforme do corpus.

4.2 O painel de preços

Os preços vêm do próprio FNSPID: um arquivo compactado de 590 MB com um CSV por *ticker*, 7.693 *tickers* e histórico de 1962 a 2023, conferido pelo *hash* SHA-256 publicado. O trabalho usa os pregões de janeiro de 2005 a dezembro de 2023, que somam 21,5 milhões de observações. O retorno diário é calculado pelo preço de fechamento ajustado por proventos e desdobramentos.

O arquivo tem problemas que, se ignorados, produziriam retornos absurdos e afetariam diretamente as covariâncias. A Tabela 4.1 resume o que foi encontrado e o tratamento dado.

O problema mais grave é a emenda de coletas. Cada lote de dados foi ajustado por proventos e desdobramentos apenas até a data da sua própria coleta, de modo que, na data em que um lote termina e o seguinte começa, o preço ajustado salta. Em 2020-07-06, por exemplo, aparecem quedas de 74,9% na Apple (desdobramento de 4 para 1), 94,9% na Alphabet e 92,4% na Tesla, e quedas menores em empresas que pagaram dividendos depois de 2020, como Coca-Cola, ExxonMobil e Pfizer. As datas de emenda foram identificadas pelo fator de ajuste $f = \text{fechamento ajustado}/\text{fechamento}$, que numa série consistente só muda em datas ex-dividendo: nas quatro datas da tabela, entre 100 e 1.918 *tickers* têm salto de f acima

Tabela 4.1: Problemas do painel de preços do FNSPID e tratamento.

problema	tamanho	tratamento
coletas emendadas em 2015-01-02, 2020-04-02, 2020-07-02 e 2020-07-06	22.678 retornos	retorno do dia marcado como inválido
lote antigo encerrado em 2020-07	3.137 *tickers*	marcados como truncados; saem dos universos quando a série acaba
pico de cotação que se reverte no dia seguinte	7.760 dias	os dois retornos marcados como inválidos; ação excluída do universo se houver pico na janela
preço parado com volume zero	436.540 dias	marcados; afetam sobretudo ações pequenas
pregão faltando na série	81.050 casos	retorno de vários dias marcado como inválido
duas ordens de coluna nos arquivos	—	leitura pelo cabeçalho

de 5% no mesmo dia, contra no máximo 60 em qualquer outra data. Dentro de cada lote, os retornos estão corretos, e quedas reais grandes são mantidas.

Depois da limpeza, restam 20.958.624 retornos válidos de 7.619 *tickers*. O truncamento em 2020-07 tem uma consequência que precisa ser declarada: ações muito citadas, como Bank of America, Facebook, Netflix, Mastercard, Cisco e McDonald's, ficam sem preço depois dessa data e saem dos universos. Além disso, o painel não inclui algumas grandes empresas, como UnitedHealth, Verizon, Moderna e Berkshire Hathaway, e não tem retornos de deslistagem: um retorno ausente conta como zero nas carteiras. Na estimação, um retorno inválido é tratado como ausente: fica fora das correlações de pares e, nas covariâncias da janela, entra como zero depois de centrado, o que vale igualmente para todos os estimadores comparados.

4.3 Universos de ações

Os testes usam dois universos, ambos definidos em cada data de rebalanceamento t (o primeiro pregão de cada mês, de janeiro de 2011 a dezembro de 2023, 156 datas) apenas com informação anterior a t.

Ações mais citadas. Nas regressões fora da amostra e em todas as carteiras (desenhos D1 a D9), o universo reúne as n ações com mais eventos no grafo nos 365 dias anteriores a t, entre as que, nos 252 pregões anteriores, têm ao menos 95% de retornos válidos, nenhum pico, preço de pelo menos US$ 5 e volume financeiro mediano de pelo menos US$ 5 milhões. Fundos e índices são excluídos. Foram usados $n = 50$, 100 e 200, com 166, 315 e 651 *tickers* distintos ao longo do período, respectivamente, e troca de 4% a 5% das ações por mês. Há uma exceção declarada à regra de usar só o passado: uma ação cuja série termina por truncamento do arquivo antes do fim do mês de carteira é excluída, porque isso é uma propriedade do arquivo, e não do mercado. Deslistagens reais não são filtradas.

Esse universo maximiza a cobertura das notícias e mantém o número de ações abaixo do número de observações da janela, o que deixa a covariância amostral bem definida. Ele tem, porém, um problema: é escolhido pela própria variável que se quer testar, e as ações mais citadas tendem a ser grandes e ligadas entre si. Por isso os testes de pares usam um segundo universo.

S&P 500 em cada data. Nos testes de pares de H1a e H1b (Seção 3.5.3), o universo é o conjunto de membros do índice S&P 500 no último registro anterior a t, segundo um histórico público da composição do índice, com retorno válido em ao menos 95% dos 252 pregões anteriores. São entre 344 e 474 ações por mês, com mediana de 390 até junho de 2020 e de 355 depois, por causa dos *tickers* truncados; não é, portanto, o índice completo. O universo não depende das notícias, o que torna os testes mais limpos. Esse universo é usado apenas nas regressões de pares, e não em carteiras.

4.4 Classificação setorial e índice de referência

Setores. O setor é o controle mais importante do trabalho, porque é a forma mais simples de estrutura que o grafo de notícias poderia estar apenas reproduzindo. Para cada *ticker* dos universos, obteve-se o identificador da empresa na SEC (CIK) pela lista atual de *tickers* da SEC ou, para empresas que mudaram de *ticker* ou deixaram de ser negociadas, por busca de nome no sistema EDGAR, conferida contra os nomes anteriores registrados. Do CIK vem o código SIC da empresa, que é mapeado para as classificações de Fama e French de 12 e 49 indústrias e para o SIC de dois dígitos. Dos 902 *tickers* dos universos, 869 receberam setor (96%), o que cobre 99,8% das combinações ação–mês do universo de 100 ações mais citadas. Pares sem setor recebem zero nos indicadores de mesmo setor. Como a classificação é a atual, uma empresa que mudou de ramo carrega o setor de hoje para todo o período; essa limitação é declarada.

Índice de referência. As carteiras usam como referência o SPY, fundo que replica o S&P 500, do próprio painel de preços.

Capítulo 5

Extração de Relações e Construção do Grafo

Este capítulo descreve a parte azul da Figura 3.1: como cada artigo foi transformado em relações estruturadas por um LLM, como essas relações foram filtradas e ligadas aos *tickers* das empresas, e como formam o grafo dinâmico usado nos testes. O capítulo termina com a validação da extração e com uma descrição do grafo resultante.

5.1 Formulação da tarefa

Para cada artigo, o modelo recebe o título, a data, os *tickers* marcados no corpus e o texto, truncado em 8.000 caracteres, e devolve uma lista de tuplas

$$(\text{agent_a}, \text{agent_b}, \text{relation_type}, \text{direction}, \text{strength}), \tag{5.1}$$

às quais se acrescenta a data de publicação do artigo. Cada tupla descreve uma ação de um agente econômico sobre outro: `agent_a` é quem age, `agent_b` é quem recebe o efeito, `relation_type` é a ação, numa expressão verbal curta e livre (“investe em”, “fornece para”, “concorre com”, “eleva juros sobre”), `direction` é o efeito sobre `agent_b`, positivo ou negativo, e `strength` é a força e a certeza do efeito, entre 0 e 1.

O prompt (Apêndice A) define o que é um agente econômico: empresas, índices, bancos centrais, governos e reguladores, moedas e criptoativos, *commodities*, setores, instituições e fundos, e pessoas economicamente relevantes. Define também o que não é: métricas contábeis, como receita, lucro ou dividendos; grupos genéricos, como “investidores” ou “analistas”; e o próprio veículo que publica a notícia. As regras principais são:

- os dois agentes precisam estar nomeados no artigo, e nenhuma relação pode ser inferida de conhecimento externo;
- a direção é o efeito sobre `agent_b`; um efeito mútuo gera duas tuplas;
- a força segue faixas: 0,8 a 1,0 para efeitos explícitos e materiais, 0,4 a 0,7 para efeitos declarados mas modestos ou indiretos, 0,1 a 0,3 para efeitos especulativos;
- no máximo oito tuplas por artigo, e uma lista vazia é uma resposta válida.

O formato da resposta é imposto por decodificação restrita: o servidor de inferência recebe um esquema JSON que fixa os cinco campos, os valores possíveis da direção, o intervalo da força e o máximo de oito itens, e só permite ao modelo gerar sequências que obedeçam a ele. Toda resposta é, assim, um JSON válido. A força ainda é limitada a $[0{,}1]$ na gravação, porque o esquema garante o tipo numérico, mas nem sempre a faixa.

O limite de 8.000 caracteres preserva 83,9% de todo o texto e trunca apenas 5,1% das unidades, medidos nas 401.609 unidades da amostra de 25%, cuja mediana tem 2.999 caracteres. O tamanho do contexto do modelo é calculado pelo pior caso de caracteres por *token*, para que nenhum artigo seja cortado em silêncio.

5.2 Modelo e execução

A extração usa um modelo de pesos abertos executado localmente, o que dá custo previsível, versão fixa e reprodutibilidade. Dois modelos de 14 bilhões de parâmetros foram comparados nos mesmos 200 artigos, com o mesmo prompt: o Qwen2.5-14B-Instruct (Qwen Team, 2024), um modelo de instrução, e o DeepSeek-R1-14B, um modelo destilado de raciocínio. Numa conferência manual de 40 tuplas de cada um, cerca de dois terços das tuplas do Qwen2.5 eram relações válidas entre agentes, contra cerca de um quarto das do DeepSeek-R1, que preenchia a lista até o limite de oito tuplas em 30% dos artigos (5% no Qwen2.5) e usava métricas contábeis e grupos genéricos como agentes com o dobro da frequência. O Qwen2.5 deixa vazios cerca de 40% dos artigos, na maioria avisos de ex-dividendo, listas de cotações e textos padronizados, e foi 39% mais rápido. Uma versão de 7 bilhões de parâmetros foi descartada num teste anterior por inventar relações.

A extração rodou em GPUs alugadas por hora, com o servidor de inferência Ollama, a cerca de um artigo por segundo. Cada resposta é gravada imediatamente em disco, e cada tupla carrega uma versão calculada como *hash* do prompt, do esquema, do limite de caracteres e do nome do modelo, de modo que resultados de configurações diferentes nunca se misturam. Foram processadas 572.762 unidades, sem nenhuma falha, que produziram 1.270.582 tuplas; 327.406 unidades (57%) tiveram ao menos uma relação, com média de 3,9 tuplas cada.

5.3 Filtro de ruído

Apesar das instruções, parte das tuplas não descreve uma relação entre dois agentes econômicos. Um filtro baseado em regras e listas *marca* cada tupla com o motivo de ruído, sem apagá-la: um dos lados é um grupo genérico, como "investidores" (7,3% das tuplas); a relação é uma comparação de desempenho (2,2%) ou o pertencimento a um índice (1,5%); o agente é o veículo ou a casa de análise que publica (1,1%); os dois lados são o mesmo agente (0,8%); um dos lados é uma métrica contábil (0,8%); ou a relação é de organograma, como a nomeação de um dirigente (0,2%). Restam 1.093.431 tuplas limpas, 86,1% do total. Indicadores macroeconômicos e setores não são tratados como ruído ("Fed $\rightarrow$ bancos"), porque são exatamente as entidades não negociadas que o trabalho quer capturar. A qualidade das tuplas limpas é medida na Seção 5.6.3.

5.4 Ligação de entidades a tickers

Para cruzar o grafo com os preços, cada nome de agente precisa ser associado, quando for o caso, ao *ticker* da empresa. A ligação é feita em quatro passos:

1. **Candidatos.** Para cada nome distinto, um procedimento determinístico monta uma lista fechada de *tickers* candidatos, em ordem de força da evidência: o *ticker* escrito no próprio nome ("NASDAQ: AAPL"); o nome igual ao da listagem oficial da Nasdaq; o nome que já é um *ticker* ("AMD"); os *tickers* marcados nos artigos em que o nome aparece; e nomes parecidos na listagem. O universo de *tickers* é a união dos que têm preço no FNSPID e dos marcados no corpus.

2. **Escolha pelo LLM.** Um modelo menor, o Qwen2.5-7B-Instruct, recebe o nome, o contexto e os candidatos e só pode *escolher* um deles ou "nenhum", porque os candidatos entram no esquema como uma enumeração fechada. O modelo também classifica o tipo do agente (empresa, fundo, banco central, país, *commodity* etc.).

3. **Regras.** Só empresas e fundos recebem *ticker*, e o *ticker* escolhido precisa ter nome compatível com o agente ou evidência forte no texto. Um *ticker* entre parênteses no nome é tratado só como evidência: "petróleo (WTI)" não é a empresa W&T Offshore, cujo *ticker* é WTI.

4. **Verificação.** Um segundo passo, com uma pergunta de sim ou não ao modelo, derruba colisões com *tickers* de empresas estrangeiras ou homônimas, exceto controladoras e fundos de índice.

Foram ligados 304.430 nomes distintos. Entre as tuplas limpas, 52,3% têm *ticker* em ao menos um dos lados e 13,2% nos dois. Por falta de orçamento, a verificação do passo 4 não foi aplicada a 434 *tickers* que surgiram na ampliação da amostra (875 menções), dos quais se estima que cerca de um quarto esteja errado.

5.5 O grafo dinâmico

5.5.1 Nós

Cada nó do grafo é um agente. Para empresas com *ticker*, o nó é o *ticker*; para os demais, um identificador canônico do nome. A construção dos nós segue regras que corrigem os erros mais comuns da unificação de nomes:

- o nome canônico sugerido pelo LLM só é aceito se for compatível com o nome original (mesmo *token*, prefixo ou sigla), o que evita fusões erradas, como um banco central estrangeiro unido ao Federal Reserve;

- prefixos de país são removidos quando a versão sem prefixo existe com o mesmo tipo ("US Federal Reserve" e "Federal Reserve"), exceto para empresas;

- classes de ação da mesma empresa são unidas (GOOG e GOOGL);

- nomes que coincidem com *tickers* de outras coisas recebem o tipo no identificador (o milho, *corn*, não é o fundo de *ticker* CORN);

- uma lista manual resolve os casos restantes, como FOMC e Federal Reserve, ou WTI, Brent e petróleo.

O resultado tem 255.384 nós, dos quais 5.979 têm *ticker*. O nó do Federal Reserve, por exemplo, reúne 200 grafias diferentes. A Tabela 5.1 mostra os nós com mais eventos, que já indicam o papel das entidades não negociadas no grafo.

Tabela 5.1: Nós com mais eventos no grafo.

nó	tipo	eventos	nó	tipo	eventos
Federal Reserve	banco central	30.769	Google	empresa	7.945
petróleo	*commodity*	19.285	JPMorgan Chase	empresa	7.144
China	país	15.726	Goldman Sachs	empresa	7.109
Apple	empresa	12.779	Microsoft	empresa	6.844
S&P 500	índice	12.584	economia dos EUA	macro	6.005
Amazon	empresa	9.231	governo dos EUA	governo	5.975
Banco Central Europeu	banco central	8.543	ouro	*commodity*	5.931
dólar	moeda	8.052			

5.5.2 Eventos e classes de relação

Cada tupla limpa vira um evento datado entre dois nós, com peso $w = \pm$ força, conforme a direção. O campo `relation_type` é livre, e o modelo produziu 184.035 expressões distintas. Elas foram agrupadas em 16 classes por expressões regulares, e a expressão original é mantida no evento. A Tabela 5.2 mostra as classes, sua frequência e o sinal médio. As tuplas em que a unificação dos nomes produziu um laço (uma empresa e as próprias ações, por exemplo) não viram arestas.

Tabela 5.2: Classes de relação: participação nos eventos e sinal médio ($+1$ positivo, -1 negativo).

classe	eventos	sinal	classe	eventos	sinal
impacto	32,1%	$+0{,}01$	analista	3,1%	$+0{,}25$
outras	14,0%	$+0{,}08$	negócios	2,9%	$+0{,}71$
concorrência	9,2%	$-0{,}87$	financiamento	2,3%	$+0{,}26$
participação	7,3%	$+0{,}43$	monetária	2,0%	$-0{,}23$
fusões e aquisições	7,0%	$+0{,}41$	governança	0,9%	$+0{,}63$
cadeia de suprimentos	6,1%	$+0{,}22$	política comercial	0,9%	$-0{,}02$
parceria	4,4%	$+0{,}79$	retorno de capital	0,3%	$-0{,}26$
legal e regulatória	4,1%	$-0{,}48$	posicionamento	3,3%	$-0{,}19$

O sinal médio mostra que as classes têm leituras econômicas coerentes: parcerias e negócios são quase sempre positivos, processos e regulação tendem a ser negativos, e a concorrência é quase sempre negativa ($-0{,}87$), porque o ganho de uma empresa é descrito como perda da rival. Essa última característica será importante na interpretação dos resultados (Capítulo 6).

5.5.3 O grafo numa data

O grafo final tem 1.064.801 eventos limpos, entre 673.261 pares de nós distintos. Ele não é materializado para cada data: o grafo em t é obtido agregando os eventos da janela anterior a t com o peso da Equação (3.1), o que leva cerca de 40 milissegundos por data. Como os eventos com data igual ou posterior a t nunca entram, o grafo pode ser consultado em qualquer data sem informação futura.

A Figura 5.1 mostra um recorte real do grafo. Os três grandes bancos aparecem ligados ao Federal Reserve, as petroleiras ao petróleo, e Apple e Boeing à China, com efeito negativo no ano da disputa comercial. As arestas diretas entre os bancos são negativas, de concorrência. É dessa estrutura que saem os atributos de par da Seção 3.4: JPMorgan e Bank of America têm exposição comum positiva (0,18 nessa data), porque se ligam à mesma entidade com o mesmo sinal, e a exposição comum entre um banco e uma petroleira é praticamente nula.

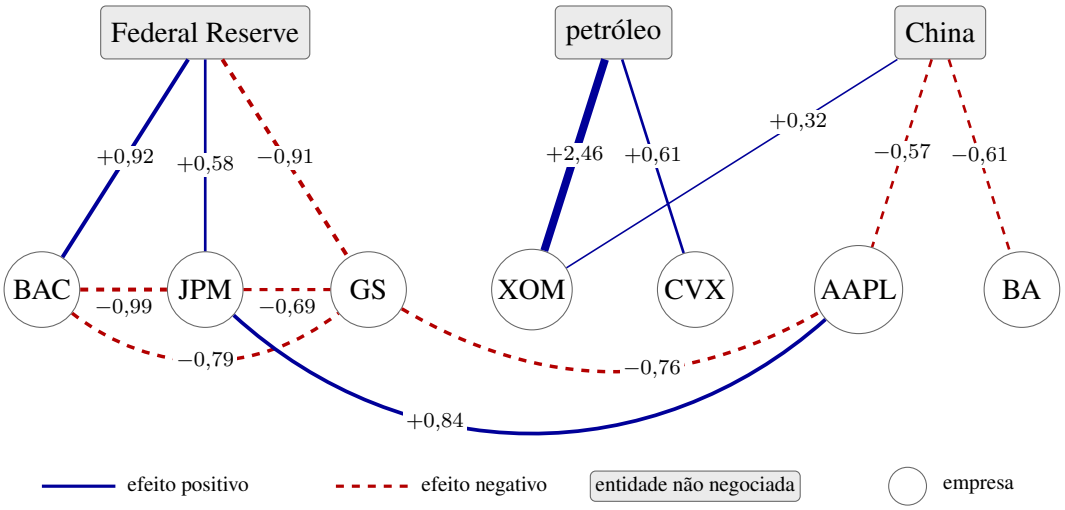


Figura 5.1: Recorte do grafo em 2 de janeiro de 2019: sete empresas e três entidades não negociadas, com os eventos dos 365 dias anteriores. Os números são a soma dos eventos com sinal e decaimento (Equação 3.1), e a espessura da linha acompanha o módulo. Só as ligações mais fortes são mostradas.

5.6 Validação da extração

5.6.1 Presença dos agentes no texto

Uma primeira verificação automática pergunta se os dois agentes de cada tupla limpa aparecem de fato no texto do artigo. O texto estava disponível para 740.467 tuplas (70% do total), as da amostra de 25%. Os dois agentes aparecem literalmente no texto em 72,8% das tuplas e, comparando por palavras distintivas, em 98,2%. A diferença vem da normalização de nomes feita pelo modelo, que escreve “Apple Inc.” quando o texto diz “Apple”. A taxa por palavras varia pouco entre as classes, de 92,1% em retorno de capital a 99,4% em parceria. O modelo, portanto, quase nunca inventa agentes que não estão no texto.

5.6.2 Vazamento de memória do modelo

O Qwen2.5 foi lançado em 2024, e seus dados de treino podem incluir textos posteriores a 2023, o último ano do corpus. O modelo pode, em princípio, saber o que aconteceu depois de cada notícia e deixar esse conhecimento influenciar a extração. Para medir esse vazamento, 218 unidades foram anonimizadas, com os nomes de empresas, os *tickers* e as datas trocados por marcadores, e reextraídas com a mesma versão do prompt e do modelo. Nos 294 pares de agentes que reaparecem nas duas extrações, o modelo atribui a mesma direção em 91% dos casos e praticamente a mesma força (0,730 contra 0,728), sem saber quais são as empresas nem quando a notícia saiu. As divergências entre as duas extrações não se correlacionam com o retorno do agente afetado nos 21 pregões seguintes (correlação de postos de $-0{,}13$, $p = 0{,}26$). Não há, portanto, evidência de que o conhecimento posterior do modelo influencie os sinais e as forças, embora o teste, com poucas unidades, tenha pouco poder estatístico.

5.6.3 Anotação automática da qualidade

A qualidade das tuplas foi avaliada numa amostra estratificada de 800 eventos limpos: 25 por classe de relação nas 16 classes e em duas metades do período (2011–2018 e 2019–2023). A anotação foi **automática**, e não humana: um segundo LLM, o Claude Opus 5.5, de outra família e de maior porte que o modelo extrator, leu cada artigo e julgou a tupla correspondente. Só 567 das 800 tuplas tinham o texto do artigo disponível, as da amostra de 25%; as demais ficaram sem anotação. Em artigos com mais de 3.000 caracteres, o anotador leu o início do texto e trechos em torno das menções aos agentes.

Para cada tupla, o anotador registrou se os dois agentes estão corretos e são agentes econômicos, se a relação existe no texto, qual é a classe correta, se o sinal está certo e a força do efeito numa escala de 0 (inexistente) a 3 (forte). Classe e sinal só foram julgados quando a relação existe no texto. Como a amostra tem o mesmo número de tuplas por classe, e as classes têm frequências muito diferentes no grafo (Tabela 5.2), a Tabela 5.3 traz a média simples e a média ponderada pela participação de cada classe nos eventos, que estima a qualidade do grafo como um todo.

Tabela 5.3: Qualidade da extração segundo a anotação automática (567 tuplas).

medida	média simples	média ponderada	tuplas
agentes corretos	84,1%	81,3%	567
relação existe no texto	85,2%	78,8%	567
classe correta	64,8%	61,9%	483
sinal correto	91,3%	93,5%	483
força: Spearman com a nota do anotador	$\rho = 0{,}35$ ($p < 10^{-17}$)		567

Ponderada pela frequência das classes, a relação existe no texto em 79% das tuplas: cerca de um quinto das arestas do grafo é ruído. Quando a relação existe, o sinal está certo em mais de 90% dos casos. As medidas são estáveis entre os períodos: a relação existe em 84,6% das tuplas de 2011–2018 e em 85,7% das de 2019–2023. A relação é mais confiável em classes de fatos objetivos, como analista (97%), fusões e aquisições (97%) e governança (95%), e menos em concorrência (64%), política comercial (64%) e impacto (67%), em que

o modelo tende a afirmar efeitos que o texto só sugere. A precisão da classe é a medida mais baixa, mas ela avalia sobretudo o mapeamento por expressões regulares da Seção 5.5, e não o LLM: a classe "outras", residual por construção, quase nunca é a classe certa, e as confusões mais comuns são entre classes vizinhas, como governança e negócios ou fusões e aquisições e participação. A força extraída tem correlação positiva, mas moderada, com a nota do anotador. Duas consequências valem para os testes. O ruído nas arestas atenua os coeficientes estimados, de modo que os efeitos medidos no Capítulo 6 são limites inferiores. E a classe menos confiável, a concorrência, é justamente a de maior efeito em H1b, ponto retomado na Seção 6.3.2.

Essa avaliação tem limites que precisam ser declarados. O anotador é um modelo de linguagem, e não um especialista humano: ele pode compartilhar vieses com o modelo avaliado e não substitui uma rotulagem humana. Houve um só anotador, de modo que a concordância entre anotadores (o κ de Cohen) não foi medida. E a avaliação mede apenas a precisão: o *recall*, isto é, a fração das relações afirmadas nos artigos que o modelo captura, não foi estimado.

5.7 Estatísticas descritivas do grafo

O grafo tem entre 31 mil e 150 mil eventos por ano de 2011 a 2023, com mais eventos entre 2011 e 2013 e entre 2021 e 2023, conforme a composição do corpus; antes de 2010 há poucas centenas de eventos por ano. Entre 41% e 53% dos eventos de cada ano são negativos.

Três propriedades do grafo orientam o desenho dos testes:

- **Arestas diretas entre ações são raras.** Em 2018, entre as 100 ações com mais eventos, só 12,5% dos pares tinham aresta direta no ano, mas 79,6% compartilhavam ao menos uma entidade sem *ticker*, como o Fed, o petróleo ou a China. No universo do S&P 500, mais amplo e com empresas menos citadas, 1,0% dos pares tem aresta direta em cada mês e 18,9% têm exposição comum não nula. A exposição comum é, portanto, o atributo com cobertura suficiente para informar a covariância.

- **O grafo é parecido com o setor, mas não é o setor.** Cerca de metade das arestas entre ações liga empresas do mesmo setor Fama-French 12 (de 35% a 54%, conforme o ano), contra cerca de 10% dos pares em geral. Ainda assim, a regressão da exposição comum g_{ij} nos indicadores de setor tem R^2 médio de apenas 0,017 nos 156 meses, muito abaixo de 0,5, limite fixado antes dos testes para considerar a exposição comum redundante com o setor.

- **A cobertura cresce com o tamanho.** No quintil das menores empresas do universo, 73% a 86% têm algum evento no ano; no das maiores, cerca de 97%.

Capítulo 6

Resultados I: as Notícias e a Correlação Futura

Este capítulo responde à primeira parte da pergunta de pesquisa: o grafo de notícias contém informação sobre a correlação futura entre ações que não está na correlação histórica nem no setor (H1)? A Seção 6.1 apresenta a regressão preditiva da correlação total, e a Seção 6.2, a da correlação residual ao fator de mercado. A Seção 6.3 testa os dois canais pelos quais o grafo carregaria essa informação: a exposição comum (H1a) e o tipo de relação (H1b). A Seção 6.4 resume o que o grafo sabe sobre o co-movimento das ações.

6.1 Previsão da correlação total

A regressão da Equação (3.3) foi estimada no universo das 100 ações mais citadas, em 156 datas mensais de janeiro de 2011 a dezembro de 2023, num total de 772.200 pares-data. A variável dependente é a correlação dos retornos no mês de carteira seguinte, em escala z; a correlação histórica usa os 252 pregões anteriores; as notícias usam os 365 dias anteriores a cada data, com meia-vida de 90 dias, valores fixados antes dos testes e não calibrados. A avaliação fora da amostra cobre as 132 datas de 2013 a 2023, com os coeficientes de cada data estimados só com as datas anteriores.

A exposição comum é o atributo mais frequente: 74,7% dos pares-data têm ao menos uma entidade não negociada em comum. A co-menção no corpus aparece em 34,8% e a co-ocorrência nos artigos extraídos, em 28,4%. As arestas diretas são raras: de 1,0% (controle) a 4,4% (concorrência e outras) dos pares-data, conforme o grupo de relação. Só 5,9% dos pares são do mesmo setor Fama-French 49.

A Tabela 6.1 mostra o ganho de cada especificação. O ganho é medido como a redução do erro quadrático fora da amostra, em fração da variância total da correlação, e testado com erro-padrão de Newey-West na série mensal das diferenças.

Quatro resultados se destacam.

1. **As notícias preveem a correlação além da persistência.** Todas as especificações com notícias reduzem o erro fora da amostra em relação à correlação histórica, de forma significativa. O ganho é pequeno em nível, cerca de meio ponto de R^2 sobre uma base de 18,5%, mas a variável prevista é uma correlação de 21 pregões, dominada por ruído amostral, e o ganho aparece em três de cada quatro meses.

Tabela 6.1: Previsão da correlação total fora da amostra (132 meses, 2013–2023, 100 ações).

especificação	R^2_{oos}	ganho	t	meses com ganho
referência: E0, persistência				
E0 persistência	0,1854	—	—	—
E1 + co-menção	0,1869	+0,0015	2,7	69%
E2 + coocorrência	0,1900	+0,0046	5,8	75%
E3 + vínculos e exposição	0,1890	+0,0037	5,5	75%
E4 todas as notícias	0,1910	+0,0056	5,0	76%
E0 + setor	0,1885	+0,0031	4,4	70%
referência: E0 + setor				
E1 + setor	0,1892	+0,0008	2,0	64%
E4 + setor	**0,1917**	**+0,0033**	**4,3**	**73%**

2. **O grafo do LLM supera a co-menção do corpus.** A coocorrência nos artigos extraídos rende três vezes o ganho da co-menção marcada no corpus (+0,0046 contra +0,0015). E todas as notícias juntas ainda acrescentam +0,0041 sobre a co-menção ($t = 5{,}6$). A informação do grafo vai além da variável usada por Tang et al. (2019).

3. **As notícias acrescentam ao setor, e valem mais que ele.** O setor sozinho rende +0,0031 sobre a persistência, o resultado esperado por Elton and Gruber (1973); as notícias sozinhas rendem +0,0056. Depois do setor, a co-menção quase desaparece ($t = 2{,}0$), mas as notícias do grafo continuam significativas ($+0{,}0033$, $t = 4{,}3$).

4. **O canal é a exposição comum, não a relação direta.** Na regressão de Fama-MacBeth com todos os atributos e o setor, a coocorrência ($t = 9{,}7$) e a exposição comum a entidades não negociadas ($t = 6{,}1$) continuam fortes, e os coeficientes de setor caem a menos da metade (o do mesmo setor FF49 vai de 0,0109 para 0,0044): parte do que o setor explica, as notícias também explicam. Já os vínculos diretos por grupo de relação quase não acrescentam e, com os demais controles, a cadeia de suprimentos chega a ter coeficiente negativo ($t = -3{,}0$). Com cobertura de 1% a 4% dos pares e um alvo mensal ruidoso, não é possível separar o tipo da relação do fato de as duas empresas aparecerem juntas nas notícias.

6.2 Correlação residual

A correlação total entre ações é dominada pelo fator de mercado, que o grafo não precisa prever. A mesma análise foi feita com a correlação residual ao mercado (Equação 3.4), que é a parte da covariância em que as notícias entram nos estimadores do Capítulo 7. A persistência tem R^2_{oos} de 0,1610, e o setor acrescenta $+0{,}0030$ ($t = 5{,}0$). Sobre a persistência e o setor, todas as notícias acrescentam $+0{,}0027$, com $t = 8{,}8$, e melhoram a previsão em 84% dos meses. O ganho é um pouco menor em nível que na correlação total, mas muito mais estável: o t sobe de 4,3 para 8,8. Tirar o mercado remove uma fonte comum de variação que as notícias não explicam, e o sinal específico de cada par fica mais nítido.

O resultado também resiste à ampliação da amostra de artigos. Com a amostra de 25%, o ganho das notícias sobre a persistência e o setor era de $+0{,}0031$ ($t = 4{,}0$) na correlação

total e de $+0{,}0026$ ($t = 9{,}7$) na residual; com a amostra final, que tem 44% mais eventos, os valores são $+0{,}0033$ ($t = 4{,}3$) e $+0{,}0027$ ($t = 8{,}8$).

6.3 Os canais da informação: H1a e H1b

Os testes desta seção usam o universo do S&P 500 em cada data, que não depende das notícias: 155 meses entre 2011 e 2023, de 344 a 474 ações por mês e 12,2 milhões de pares-mês. A variável dependente é a correlação residual dos 21 pregões seguintes, em escala z, e a regressão é a da Equação (3.5). Nesse universo, mais amplo que o das ações mais citadas, as notícias são mais esparsas: 18,9% dos pares-mês têm exposição comum não nula e 1,0% tem aresta direta. A Tabela 6.2 mostra a regressão com a aresta direta com sinal.

Tabela 6.2: Regressão de Fama-MacBeth da correlação residual futura (S&P 500, 155 meses). Coeficientes por desvio-padrão do regressor.

regressor	coeficiente	t
exposição comum, g	$\mathbf{+0{,}0038}$	$\mathbf{+11{,}1}$
aresta direta com sinal, $\mathrm{sgnlog}(w)$	$-0{,}0016$	$-9{,}1$
correlação residual histórica, z_{hist}	$+0{,}105$	$+16{,}7$
mesmo setor FF49	$+0{,}013$	$+14{,}4$
mesmo SIC de 2 dígitos	$+0{,}011$	$+15{,}3$
distância de tamanho	$-0{,}0018$	$-4{,}2$
atenção (soma)	$0{,}0000$	$+0{,}1$
atenção (diferença)	$-0{,}0002$	$-0{,}6$

6.3.1 H1a: exposição comum a entidades não negociadas

A exposição comum tem o coeficiente positivo mais forte entre os atributos de notícia: $+0{,}0038$ por desvio-padrão, com $t = 11{,}1$, depois de controlar a correlação residual histórica, os dois indicadores de setor, a distância de tamanho e a atenção da mídia. O coeficiente é positivo em 96% dos meses. No teste de permutação, o maior coeficiente médio obtido com as ações permutadas é 0,0002, cerca de um dezesseis avos do observado ($p = 0{,}001$, o menor possível). **H1a é confirmada.**

A própria regressão afasta as duas explicações mais simples para o resultado. Os dois termos de atenção têm coeficiente nulo: g não mede apenas quanto as duas empresas aparecem nas notícias. E os indicadores de setor estão na regressão; além disso, a regressão de g_{ij} nesses indicadores tem R^2 médio de 0,017 (Seção 5.7), de modo que a exposição comum não é o setor disfarçado.

O resultado repete, num universo que não foi escolhido pelas notícias, o que as Seções 6.1 e 6.2 mostraram no universo das ações mais citadas: o canal que sobrevive aos controles é a exposição comum. É a evidência mais direta de que o grafo descreve uma estrutura de fatores: empresas que as notícias ligam às mesmas entidades se movem juntas, além do que o setor e o passado já indicam. A magnitude, porém, é pequena. Um desvio-padrão a mais de exposição comum corresponde a cerca de 0,004 a mais de correlação, contra 0,105 para

um desvio-padrão da correlação histórica: a exposição comum acrescenta informação ao histórico, mas não o substitui.

6.3.2 H1b: tipo de relação

A Tabela 6.3 traz o coeficiente de cada grupo de relação direta, com as arestas medidas sem sinal. As arestas diretas são raras: 0,49% dos pares-mês têm alguma relação de concorrência, 0,16% de parceria, 0,16% de impacto, 0,09% de cadeia de suprimentos, 0,09% de controle e 0,02% legal ou regulatória. Ainda assim, o teste de Wald rejeita a igualdade dos seis coeficientes: a estatística é 77,9, e a maior obtida nas 1.000 permutações é 30,3 ($p = 0{,}001$; $p = 0{,}003$ com a correção de Bonferroni para as três hipóteses do trabalho). **H1b é confirmada**: o tipo de relação importa. O padrão segue a literatura de vínculos econômicos. A concorrência tem o maior efeito, como esperado para empresas que disputam o mesmo mercado de produtos (Hoberg and Phillips, 2016); a cadeia de suprimentos e as relações de controle (participações e aquisições) vêm em seguida, coerentes com o fluxo de demanda e de caixa compartilhado (Cohen and Frazzini, 2008; Menzly and Ozbas, 2010); e as relações legais e regulatórias, que não criam exposição econômica duradoura, não têm efeito.

Tabela 6.3: H1b: efeito de cada grupo de relação sobre a correlação residual futura.

grupo	coeficiente	t	p (Benjamini-Hochberg)
concorrência	+0,0022	+9,9	$< 10^{-21}$
parceria	+0,0004	+4,7	$< 10^{-4}$
controle (participação, fusões e aquisições)	+0,0007	+4,1	0,0001
cadeia de suprimentos	+0,0006	+3,1	0,003
impacto	+0,0003	+1,9	0,065
legal e regulatória	0,0000	−0,2	0,81
outras (grupo residual)	+0,0004	+2,9	—

Há uma ressalva de medida. A concorrência, o grupo de maior efeito, é também a classe em que a extração é menos confiável: na anotação da Seção 5.6.3, a relação afirmada existe no texto em 64% das tuplas dessa classe, contra 79% no conjunto. O erro de medida num regressor atenua o seu coeficiente, de modo que ele não explica um efeito grande; mas parte do que a classe concorrência captura pode ser apenas a menção conjunta de duas empresas do mesmo ramo. Na regressão, a exposição comum e os indicadores de setor controlam esse efeito, e o coeficiente da concorrência continua o maior. A conclusão que os dados sustentam é a de H1b, que os grupos diferem; a ordenação fina entre eles deve ser lida com cautela.

O sinal da relação. A segunda parte de H1b pergunta se o sinal que o LLM atribui a cada relação indica a direção do co-movimento. Não indica. Na Tabela 6.2, a aresta direta com sinal tem coeficiente *negativo* ($-0{,}0016$, $t = -9{,}1$): quanto mais positivas as relações entre duas empresas, menor a correlação residual futura. Com as arestas positivas e negativas em regressores separados, as duas *aumentam* a correlação, as negativas mais que as positivas ($+0{,}0025$ contra $+0{,}0010$; diferença $-0{,}0015$, $t = -7{,}3$). Os dois critérios fixados para o sinal não são atendidos.

O mecanismo é o mesmo que torna a concorrência o grupo mais forte. As arestas negativas são, em sua maioria, de concorrência, classe cujo sinal médio é $-0{,}87$ (Tabela 5.2): o

ganho de uma empresa é descrito como perda da rival. Mas rivais do mesmo ramo estão expostos aos mesmos choques, e suas ações andam juntas. Somar arestas positivas e negativas com sinal faz as duas se cancelarem e, como as negativas preveem mais correlação, o coeficiente sai negativo. A existência e a intensidade do vínculo, sem sinal, preveem a correlação ($|w|$: $t = +12{,}2$). Esse diagnóstico foi feito depois do teste e é, por isso, exploratório, mas a anotação da Seção 5.6.3 o apoia: o sinal extraído está certo em mais de 90% das relações existentes, de modo que o problema não é erro de extração. Esse é um dos achados centrais do trabalho: **o sinal que o LLM atribui a uma relação descreve o efeito econômico de uma empresa sobre a outra, e não a direção do co-movimento entre elas**.

6.4 Síntese

H1 é confirmada, pelos dois canais. A exposição comum a entidades não negociadas prevê a correlação futura além do histórico e do setor, fora da amostra no universo das ações mais citadas ($t = 8{,}8$ na correlação residual) e nos testes de pares do S&P 500 ($t = 11{,}1$; $p = 0{,}001$ por permutação). O tipo de relação direta importa, com a concorrência à frente (Wald de 77,9; $p = 0{,}001$). Duas qualificações limitam o alcance desse conteúdo. A informação está na *existência* e na *intensidade* dos vínculos, e não no sinal que o LLM atribui a eles. E o ganho é pequeno em magnitude: cerca de três décimos de ponto de R^2 sobre a persistência e o setor, e quatro milésimos de correlação por desvio-padrão de exposição comum. O Capítulo 7 investiga se esse ganho, pequeno mas estatisticamente sólido, sobrevive à passagem da previsão de correlações para a construção de carteiras.

Capítulo 7

Resultados II: as Notícias e as Carteiras

O Capítulo 6 mostrou que o grafo de notícias prevê a correlação futura entre ações além do histórico e do setor. Este capítulo responde à segunda parte da pergunta: essa informação, levada à estimação da matriz de covariância, produz carteiras melhores (H2)? Os desenhos são apresentados na ordem em que foram testados (Tabela 3.3); do D2 em diante, cada um teve o critério de sucesso fixado antes da execução. Salvo indicação, os resultados usam a amostra final de artigos, o universo das 100 ações mais citadas, o período de 2013 a 2023 e custos de 10 pontos-base; as volatilidades são anualizadas e as razões de variâncias dividem a variância do modelo pela da referência, de modo que valores abaixo de 1 indicam que o modelo com notícias reduz o risco. Em todos os desenhos, a pergunta é a mesma: a matriz com setor e notícias produz uma carteira melhor que a matriz só com setor, e melhor que o placebo?

7.1 Alvo de shrinkage com notícias

O primeiro caminho tentado usava como alvo a previsão completa da regressão do Capítulo 6, inclusive a correlação histórica. Ele foi descartado por construção, e não pelo resultado: o alvo dependia da própria amostra, o que viola a hipótese de alvo fixo da fórmula de δ, e a intensidade ficava próxima de 1, de modo que $\hat{\Sigma}$ se reduzia à previsão da regressão. O desenho D1 usa, em vez disso, os alvos da Equação (3.6), sem a correlação histórica. A intensidade média de *shrinkage* ficou em torno de 0,2. A Tabela 7.1 compara a variância da GMV com a do *shrinkage* para a correlação constante de Ledoit and Wolf (2004a), que corresponde ao alvo com $\beta = 0$.

O alvo com notícias não reduz a variância da GMV: fica 3,7% pior que a correlação constante, empatado com o placebo. Na versão sem venda a descoberto, todos os estimadores ficam a menos de 3% uns dos outros. O resultado contrasta com a qualidade da previsão: o alvo com setor e notícias tem o *menor* erro quadrático de correlação de todos os estimadores, 0,09% abaixo da correlação constante, enquanto o placebo fica 0,33% acima ($t = -3{,}9$) e o fator único, 1,05% acima ($t = -3{,}9$). O fator único é o pior em erro de correlação e o melhor em variância da carteira. A GMV premia a estrutura de fatores da matriz, e não a precisão das correlações par a par; um alvo construído sobre a correlação constante parte da base errada. Essa constatação motivou o desenho seguinte, registrado como revisão motivada pelo resultado.

Tabela 7.1: D1: razão de variâncias da GMV contra o *shrinkage* para a correlação constante.

	GMV sem restrição		GMV sem venda a descoberto	
estimador	razão	p	razão	p
Ledoit-Wolf fator único	**0,903**	$< 0{,}001$	0,997	0,77
Ledoit-Wolf não linear	0,931	0,005	1,005	0,76
Ledoit-Wolf identidade	0,939	0,005	1,014	0,43
alvo setor	1,003	0,79	1,006	0,006
alvo notícias	1,046	$< 0{,}001$	1,007	0,10
alvo setor + notícias	1,037	0,002	1,007	0,09
placebo (notícias permutadas)	1,038	0,001	1,001	0,80
covariância amostral	1,233	$< 0{,}001$	1,026	0,12

7.2 Fator de mercado e correlação residual

O desenho D2 aplica as notícias à correlação residual ao fator de mercado (Equação (3.8)). Seu primeiro critério, que as notícias previssem a correlação residual além da persistência e do setor, foi atendido ($t = 8{,}8$; Seção 6.2). A Tabela 7.2 mostra o critério de carteira.

Tabela 7.2: D2: GMV sem restrição com fator de mercado e resíduo encolhido para setor e notícias.

	$n = 50$	$n = 100$	$n = 200$
volatilidade, fator + resíduo setor	13,81%	12,83%	11,72%
volatilidade, + notícias	13,83%	12,84%	11,87%
razão notícias / setor (p)	**1,003** (0,77)	**1,001** (0,89)	**1,024** (0,045)
razão placebo / setor (p)	1,011 (0,30)	1,022 (0,006)	1,021 (0,27)
número de condição, setor $\rightarrow$ + notícias	104 $\rightarrow$ 110	183 $\rightarrow$ 217	374 $\rightarrow$ 544
volatilidade, Ledoit-Wolf fator único	13,78%	12,85%	11,79%
volatilidade, Ledoit-Wolf não linear	13,98%	13,05%	12,16%
volatilidade, $1/N$	21,42%	19,95%	19,85%

O segundo critério, razão abaixo de 1 com $p < 0{,}05$ e abaixo do placebo em $n = 100$, **não foi atendido**: as notícias empatam com o setor (1,001). A confirmação em $n = 50$ e $n = 200$ também falha, e em $n = 200$ as notícias chegam a piorar a carteira, no limite da significância ($p = 0{,}045$). Com a amostra de 25%, o resultado era o mesmo em $n = 100$ (1,001), com o placebo claramente pior.

A última linha da tabela mostra o mecanismo. As notícias aumentam o número de condição da correlação estimada em todos os universos, de 6% em $n = 50$ a 45% em $n = 200$. A estrutura que elas acrescentam é esparsa e pequena, e abre o leque dos autovalores; como a GMV inverte a matriz, o ganho de previsão se perde na inversão. É o mecanismo de instabilidade de Markowitz descrito por López de Prado (2016).

Há um achado lateral: o próprio modelo de fator de mercado com resíduo encolhido para o setor empata com o fator único de Ledoit e Wolf e supera o *shrinkage* não linear em todos os universos.

7.3 Variância mínima com restrições

Na prática, a variância mínima é usada sem venda a descoberto e com teto de peso por ação, e as restrições funcionam elas próprias como *shrinkage* (Jagannathan and Ma, 2003). O desenho D3 pergunta se as notícias melhoram a carteira que um gestor de fato montaria, com teto de 10% por ação. Por ser o segundo desenho para H2, o nível exigido caiu para $p < 0{,}025$.

Tabela 7.3: D3: variância mínima sem venda a descoberto e com teto de 10% ($n = 100$).

estimador	volatilidade	Sharpe	razão contra setor	p
fator + resíduo setor	13,43%	0,778	—	—
setor + notícias	13,42%	0,789	0,998	0,46
placebo	13,39%	0,783	0,994	0,12
Ledoit-Wolf fator único	13,39%	0,788	0,993	0,15
$1/N$	19,94%	0,663	2,205	$< 0{,}001$
confirmação: razão notícias / setor (p); placebo / setor				
$n = 50$	0,996 (0,06)		0,999	
$n = 200$	0,996 (0,09)		1,001	

O critério principal **não foi atendido**: a razão é 0,998, com $p = 0{,}46$, e o placebo fica até um pouco melhor que as notícias. A razão fica abaixo de 1 em $n = 50$ e $n = 200$, mas as diferenças são de 0,2% a 0,5% da variância, menores que o ruído, e com teto o placebo empata com as notícias verdadeiras. Um teste exploratório anterior, com o grafo da amostra de 25%, havia dado 0,994 com $p = 0{,}017$; com a amostra final, o resultado **não se replicou**. Com restrições, todos os estimadores baseados em fator ficam a menos de 0,05 ponto de volatilidade uns dos outros: as restrições já regularizam a matriz tanto que não sobra espaço para a informação das notícias.

7.4 Outros otimizadores

Os desenhos anteriores usaram apenas a variância mínima. Os desenhos D4 a D8 testam a mesma matriz em otimizadores que usam retorno esperado (Markowitz e máximo Sharpe), que buscam diversificação (máxima diversificação), que não invertem a matriz (HRP), onde as notícias perdiam o ganho no D2, e que perseguem um índice (mínimo *tracking error*). Todos são sem venda a descoberto e com teto de 10%, e o nível exigido é $p < 0{,}01$ por otimizador.

Nenhum dos cinco otimizadores atende o critério (Tabela 7.4). Em quatro deles, a matriz com notícias empata com a matriz com setor: as diferenças de Sharpe ficam abaixo de 0,02, as de variância abaixo de 1%, a direção muda entre os universos e o placebo fica igual ou melhor.

No mínimo *tracking error*, as notícias *pioram* a carteira de forma significativa e crescente com o universo: o erro de acompanhamento realizado sobe 10% em $n = 50$, 21% em $n = 100$ e 43% em $n = 200$, todos com $p < 0{,}001$, e o giro sobe de 3,3 para 4,0 vezes o patrimônio por ano. O placebo não piora (1,008), de modo que o efeito vem da estrutura real das notícias. Replicar um índice depende de acertar a covariância conjunta de muitos

Tabela 7.4: D4–D8: notícias contra setor em cinco otimizadores ($n = 100$) e direção em $n = 50$ e $n = 200$.

otimizador	estatística	notícias	p	placebo	p	$n = 50$	$n = 200$
Markowitz ($\gamma = 5$)	Δ Sharpe	$-0{,}015$	0,16	$+0{,}004$	0,62	$-0{,}003$	$+0{,}006$
máximo Sharpe	Δ Sharpe	$-0{,}010$	0,43	$+0{,}004$	0,76	$-0{,}008$	$+0{,}015$
máxima diversificação	razão de var.	0,992	0,46	0,921	0,17	1,003	0,964
HRP	razão de var.	1,007	0,14	1,002	0,59	0,992	1,001
mínimo *tracking error*	razão de var. ativa	**1,214**	$<$ **0,001**	1,008	0,63	**1,104**	**1,432**

ativos; as correlações residuais que as notícias acrescentam acertam a média dos pares, mas distorcem a cobertura entre eles. É o mesmo mecanismo da GMV sem restrição.

Entre os otimizadores, a volatilidade anual vai de 13,4% (variância mínima) a 24,6% (Markowitz), mas, para um otimizador fixo, trocar a matriz muda a volatilidade em menos de um ponto: **o otimizador importa muito mais que o estimador**. Nenhum otimizador com retorno esperado superou o SPY em Sharpe líquido (0,82).

7.5 Black-Litterman na covariância

Nos desenhos anteriores, a notícia entra com um único δ para todos os pares. O desenho D9 dá a cada par a confiança que sua evidência justifica (Seção 3.6) e volta à GMV sem restrição, onde o erro de $\hat{\Sigma}$ passa inteiro para os pesos. O nível exigido é $p < 0{,}0125$.

Tabela 7.5: D9: GMV sem restrição com Black-Litterman na covariância residual ($n = 100$).

matriz	volatilidade	Sharpe	razão contra setor	p
fator + resíduo setor (prior)	12,83%	0,632	—	—
setor + Black-Litterman notícias	13,71%	0,609	1,143	0,015
Black-Litterman placebo	14,62%	0,556	1,300	0,012
setor + notícias, δ único (D2)	12,83%	0,641	1,001	0,87
Ledoit-Wolf fator único	12,85%	0,634	1,003	0,52

O critério **não foi atendido**, e na direção contrária: o Black-Litterman *aumenta* a variância da GMV em 14% (Tabela 7.5), resultado que se repete em $n = 50$ (razão 1,10, $p = 0{,}19$) e em $n = 200$ (1,20, $p = 0{,}001$). O diagnóstico mostra que o método funcionou como previsto: a confiança estimada cresce com a evidência, de $\omega = 0{,}013$ nos pares ligados só por exposição comum a $\omega = 0{,}058$ no quartil de maior coocorrência; a projeção para matriz positiva semidefinida não precisou agir em nenhum mês; e o número de condição mediano até *cai*, de 183 para 137. Mesmo assim, a variância realizada sobe. A cada mês, cerca de 2.700 visões de exposição comum e algumas centenas de visões de coocorrência movem milhares de covariâncias residuais, e o erro de cada visão, da ordem de 0,01 a 0,06 em escala z, tem a

mesma magnitude do sinal que ela carrega. O placebo piora ainda mais (1,30): a informação existe, como no Capítulo 6, mas não vira carteira melhor.

7.6 Síntese

A Tabela 7.6 reúne os resultados dos nove desenhos.

Tabela 7.6: Resultados de H2 em todos os desenhos testados.

	desenho	resultado principal
D1	alvo de notícias, GMV	3,7% pior que a correlação constante; empata com o placebo
D2	fator + resíduo, GMV	empata com o setor em $n = 50$ e 100; pior em $n = 200$ ($p = 0{,}045$)
D3	variância mínima com teto	empata (0,998, $p = 0{,}46$); placebo igual
D4	Markowitz	empata (Δ Sharpe $-0{,}015$)
D5	máximo Sharpe	empata (Δ Sharpe $-0{,}010$)
D6	máxima diversificação	empata (0,992); placebo melhor
D7	HRP	empata (1,007)
D8	mínimo *tracking error*	**pior**: +21% de variância ativa ($p < 0{,}001$)
D9	Black-Litterman, GMV	**pior**: +14% de variância ($p = 0{,}015$)

H2 é rejeitada em todos os desenhos. Em nenhum deles a informação das notícias reduziu de forma significativa a variância realizada ou melhorou o índice de Sharpe em relação à referência de setor, e em dois deles, o mínimo *tracking error* e o Black-Litterman, a carteira com notícias foi significativamente pior. O resultado não depende do tamanho do universo, do otimizador, das restrições de peso nem do modo de combinar as notícias com os preços, e não mudou quando a amostra de artigos foi ampliada. A informação preditiva documentada no Capítulo 6 não se converte em ganho de carteira. Dois mecanismos explicam a diferença, conforme o tipo de carteira. Sem restrição de peso, as notícias acrescentam uma estrutura esparsa e pequena que piora o condicionamento da matriz (D2) ou, como no Black-Litterman, move muitas covariâncias com um erro da mesma ordem do sinal (D9); o otimizador inverte a matriz e explora justamente esse erro. Com restrições, a regularização imposta por elas já é tão forte que todos os estimadores baseados em fator empatam, e não sobra espaço para a informação das notícias (D3 a D7). O Capítulo 8 discute essas explicações.

Capítulo 8

Discussão e Conclusões

Este trabalho perguntou se a estrutura de relações que um LLM extrai das notícias contém informação sobre a covariância futura dos retornos que não está na covariância histórica nem nos modelos de setor e de fatores, e se essa informação produz carteiras melhores fora da amostra. A resposta tem duas partes. Sim, o grafo de notícias contém essa informação: ele prevê a correlação futura entre pares de ações além do histórico, do setor e da co-menção. Não, essa informação não produz carteiras melhores: em nove desenhos de carteira, nenhum estimador com notícias reduziu de forma significativa o risco realizado em relação à sua referência sem notícias, e em dois desenhos a carteira com notícias foi significativamente pior.

8.1 Síntese dos resultados

A base de relações. O Qwen2.5-14B-Instruct leu 572.762 artigos do FNSPID, cerca de 36% do corpus elegível, e extraiu 1.270.582 relações, das quais 86,1% passaram pelo filtro de ruído. Depois da ligação aos *tickers*, elas formam um grafo dinâmico com 255.384 nós e 1.064.801 eventos entre 2011 e 2023. Na anotação automática, cerca de quatro em cada cinco tuplas descrevem uma relação que o texto de fato afirma, e o sinal está certo em mais de 90% das relações existentes.

H1: as notícias preveem a correlação. Na correlação residual ao fator de mercado, os atributos do grafo reduzem o erro de previsão fora da amostra em relação à persistência e ao setor em 84% dos meses, com estatística t de 8,8, e a ampliação da amostra de artigos deixou o ganho igual ou um pouco maior. Os dois canais previstos pela teoria aparecem nos dados. A exposição comum a entidades não negociadas é o mais forte e sobrevive aos controles de setor e de atenção da mídia num universo que não foi escolhido pelas notícias (H1a). O tipo de relação direta importa, com a concorrência à frente (H1b). Em magnitude, o efeito é pequeno: cerca de três décimos de ponto de R^2 e quatro milésimos de correlação por desvio-padrão de exposição comum.

H2: as notícias não melhoram as carteiras. A Tabela 7.6 mostra o padrão. Sem restrição de peso, as notícias empatam com a referência setorial ou a pioram (D1, D2 e D9); com restrições, empatam (D3 a D7); no mínimo *tracking error*, pioram de forma crescente com

o número de ações (D8). O resultado se repete em universos de 50, 100 e 200 ações e nas duas amostras de artigos, e, sempre que as notícias pareceram ajudar, o placebo ajudou tanto quanto elas.

Os dois resultados não se contradizem. O grafo sabe algo sobre o co-movimento, mas o que ele sabe é pouco, está na média dos pares e já está, em boa parte, no setor e nos fatores. A carteira de variância mínima, por sua vez, não depende da precisão média das correlações, e sim da estrutura da matriz que o otimizador inverte.

8.2 Por que a informação não vira carteira melhor

O ganho de previsão é pequeno e está no lugar errado. O ganho das notícias melhora a correlação *média* dos pares, enquanto a GMV depende sobretudo dos autovalores e autovetores da matriz. O D1 mostra essa diferença de forma direta: o alvo com setor e notícias teve o menor erro quadrático de correlação entre todos os estimadores e, mesmo assim, uma carteira 3,7% pior que a correlação constante; o fator único de Ledoit and Wolf (2003), ao contrário, teve o maior erro de correlação e a melhor carteira. Melhorar a previsão das correlações par a par não é o mesmo que melhorar a matriz para a otimização.

A inversão amplifica o erro da estrutura acrescentada. As notícias acrescentam uma estrutura esparsa e de pequena magnitude à correlação residual. No D2, essa estrutura aumentou o número de condição da matriz em todos os universos, de 6% com 50 ações a 45% com 200. Como a GMV inverte a matriz, os autovalores pequenos, os mais afetados pelo erro, recebem os maiores pesos, e o otimizador explora justamente o erro da estimativa (López de Prado, 2016). O Black-Litterman do D9 mostra que o problema não é só de condicionamento: nele o número de condição até caiu, mas milhares de covariâncias foram movidas por visões cujo erro tem a mesma ordem de grandeza do sinal que carregam, e a variância realizada subiu 14%.

As restrições já regularizam a matriz. Com venda a descoberto proibida e teto de peso, a carteira de variância mínima equivale a usar uma matriz encolhida (Jagannathan and Ma, 2003). No D3 e nos otimizadores do D4 ao D7, todos os estimadores baseados em fatores ficaram a menos de um ponto de volatilidade uns dos outros, e o placebo empatou com as notícias verdadeiras. Quando as restrições já fazem o trabalho de estabilizar a matriz, não sobra espaço para a informação das notícias se manifestar.

O que o grafo sabe, o setor já sabe em boa parte. Na regressão com todos os atributos, os coeficientes de setor caem a menos da metade quando as notícias entram: as duas fontes explicam, em grande parte, a mesma coisa. Cerca de metade das arestas entre ações liga empresas do mesmo setor, e o modelo de fator de mercado com resíduo encolhido para o setor, sem nenhuma notícia, já empata com o fator único de Ledoit e Wolf.

Em conjunto, os mecanismos explicam por que o resultado negativo de H2 não vem da falta de informação. A informação existe e é medida com precisão (H1), mas é pequena demais e está numa dimensão da matriz, a média das correlações par a par, que a otimização de carteiras não valoriza. A pergunta relevante para a carteira não é se um sinal prevê correlações, mas se ele melhora a matriz nas direções em que o otimizador a usa.

8.3 O sinal extraído pelo LLM e a correlação

O resultado mais inesperado do trabalho está na análise do sinal (Seção 6.3.2): a aresta direta com sinal tem efeito *negativo* sobre a correlação futura, quando o esperado era positivo. O problema não está na qualidade da extração, pois o sinal das relações existentes está certo em mais de 90% dos casos. O problema é o que o sinal significa. Para o LLM, e para o texto que ele lê, uma relação negativa descreve o efeito econômico de uma empresa sobre a outra: o lançamento de um produto por um concorrente é ruim para a rival. Mas concorrentes do mesmo ramo estão expostos aos mesmos choques de demanda, de custo e de regulação, e suas ações andam juntas.

O achado tem uma consequência para quem usa o sentimento extraído por LLMs como indicador de co-movimento: **a direção de um efeito econômico não é a direção da correlação entre os retornos**. Para estimar a covariância, a existência e a intensidade do vínculo são a informação útil; o sinal só seria útil numa janela de evento, e não numa correlação mensal. Nas carteiras, a questão do sinal não interfere: os atributos que alimentam os estimadores usam o módulo dos vínculos.

8.4 Comparação com a literatura

Os três antecedentes mais próximos relatam ganhos de carteira com informação textual (Seção 2.5). A primeira parte desses resultados se confirma aqui: as notícias preveem a correlação, e o grafo extraído pelo LLM prevê mais que a simples co-menção de Tang et al. (2019). A segunda não se confirma, e duas diferenças de desenho ajudam a entender por quê.

A primeira é a referência. Aqui, toda matriz com notícias foi comparada a uma referência que já usa o setor e, em quase todos os desenhos, um fator de mercado, além de um placebo com a mesma esparsidade. Contra referências mais fracas, as notícias também ganhariam: no D1, o alvo com notícias tem 15% menos variância que a covariância amostral, mas o placebo tem a mesma vantagem. Um ganho medido contra a covariância amostral mistura o efeito do conteúdo do texto com o efeito genérico de impor alguma estrutura à matriz.

A segunda é a janela. Becquin and Esmeir (2023) estimam a covariância com três meses de dados, um regime em que a amostra é muito pouco informativa e qualquer *prior* razoável tende a ajudar. Aqui, a janela foi de 252 pregões, e universos maiores, com menos observações por parâmetro, desfavoreceram as notícias em vez de favorecê-las.

O resultado converge com a literatura que mostra a dificuldade de superar estimadores simples fora da amostra (DeMiguel et al., 2009): as estruturas que funcionam bem na carteira são as que reduzem o número de parâmetros efetivos da matriz, e não as que acrescentam informação par a par.

8.5 Limitações

- **Amostra de artigos.** Por limite de orçamento, o LLM leu cerca de 36% dos artigos elegíveis. A ampliação de 25% para 36% não mudou nenhuma conclusão, o que sugere, sem garantir, que o corpus completo também não mudaria.
- **Qualidade da extração.** A qualidade das tuplas foi medida por outro LLM, e não por anotadores humanos, em 567 tuplas, e o *recall* não foi medido. A classe da relação é a

medida mais fraca (62% de acerto), e a concorrência, o grupo de maior efeito em H1b, é a classe menos confiável.

- **Preços e universos.** O painel de preços é formado por coletas emendadas, não cobre todo o S&P 500 e perde 3.137 *tickers* em 2020. Essas falhas afetam igualmente os estimadores com e sem notícias. O universo das carteiras é escolhido pelo número de citações, a própria variável em teste, e a classificação setorial é a atual, aplicada a todo o período.

- **Tempo e memória do modelo.** As notícias não têm hora de publicação, e o grafo descarta a informação do próprio dia. O período avaliado não é posterior aos dados de treino do modelo de linguagem; o teste de anonimização não encontrou vazamento, mas tem pouco poder estatístico.

- **Alcance.** Os resultados valem para ações americanas de grande capitalização, entre 2013 e 2023, com rebalanceamento mensal e as carteiras estudadas.

8.6 Trabalhos futuros

1. **Usos que valorizam a correlação par a par.** A informação do grafo melhora a previsão da correlação de cada par, e não a estrutura de autovalores. Aplicações em que o par importa por si, como a seleção de pares para *hedge* e a previsão de contágio entre empresas ligadas, podem aproveitar melhor esse sinal.

2. **A exposição comum como fator.** H1a sugere que a exposição a entidades como o Federal Reserve ou o petróleo descreve cargas em fatores de risco. Usar o grafo para escolher fatores observáveis e orientar a estimação das cargas, em vez de alterar correlações residuais par a par, não aumenta o número de parâmetros efetivos da matriz.

3. **Eventos e horizontes curtos.** Um estudo com notícias datadas por hora e janelas de evento poderia testar se o sinal do LLM prevê o co-movimento nos dias seguintes à notícia, onde a direção do efeito econômico deveria importar.

4. **Extração mais completa e auditável.** Processar o corpus inteiro, guardar o trecho que justifica cada tupla e medir precisão e *recall* com anotação humana permitiriam separar o que é limite da informação das notícias do que é limite da extração.

Mostrar que um sinal extraído do texto prevê alguma grandeza financeira é o primeiro passo, e não o último. Entre a previsão e a carteira há um otimizador que amplifica erros, restrições que já regularizam a matriz e referências simples difíceis de superar. Um protocolo com pré-registro, placebo e confirmação em amostras e universos diferentes é o que permite distinguir, nesse caminho, a informação real do efeito genérico de regularizar.

Referências Bibliográficas

T. W. Anderson. *An Introduction to Multivariate Statistical Analysis*. Wiley, 3 edition, 2003.

Jushan Bai and Serena Ng. Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 2002.

Guillaume Becquin and Saher Esmeir. Semantic similarity covariance matrix shrinkage. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 9977–9992, 2023. URL https://aclanthology.org/2023.findings-emnlp.668/.

Yoav Benjamini and Yosef Hochberg. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 1995.

Fischer Black and Robert Litterman. Global portfolio optimization. *Financial Analysts Journal*, 48 (5):28–43, 1992.

Joël Bun, Jean-Philippe Bouchaud, and Marc Potters. Cleaning large correlation matrices: tools from random matrix theory. *Physics Reports*, 666, 2017.

John Y. Campbell and Samuel B. Thompson. Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 2008.

Louis K. C. Chan, Jason Karceski, and Josef Lakonishok. On portfolio optimization: forecasting covariances and choosing the risk model. *Review of Financial Studies*, 12:937–974, 1999.

Yves Choueifaty and Yves Coignard. Toward maximum diversification. *Journal of Portfolio Management*, 35(1), 2008.

Lauren Cohen and Andrea Frazzini. Economic links and predictable returns. *Journal of Finance*, 63 (4), 2008.

Gérard Cornuéjols and Reha Tütüncü. *Optimization Methods in Finance*. Cambridge University Press, 2007.

Victor DeMiguel, Lorenzo Garlappi, and Raman Uppal. Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy? *Review of Financial Studies*, 22(5), 2009.

Francis X. Diebold and Roberto S. Mariano. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 1995.

Zihan Dong, Xinyu Fan, and Zhiyuan Peng. FNSPID: A comprehensive financial news dataset in time series. *arXiv preprint arXiv:2402.06698*, 2024. Conjunto de dados em https://huggingface.co/datasets/Zihan1004/FNSPID; conferir autoria e versão publicada.

Edwin J. Elton and Martin J. Gruber. Estimating the dependence structure of share prices: implications for portfolio selection. *Journal of Finance*, 28, 1973.

Robert Engle and Riccardo Colacito. Testing and valuing dynamic correlations for asset allocation. *Journal of Business & Economic Statistics*, 24(2), 2006.

Eugene F. Fama and James D. MacBeth. Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3), 1973.

Jianqing Fan, Yuan Liao, and Martina Mincheva. Large covariance estimation by thresholding principal orthogonal complements. *Journal of the Royal Statistical Society: Series B*, 75(4), 2013.

Jerome Friedman, Trevor Hastie, and Robert Tibshirani. Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3), 2008.

Li Guo, Lin Peng, Yubo Tao, and Jun Tu. Joint news, attention spillover, and stock returns. arXiv:1703.02715, 2017.

Guangliang He and Robert Litterman. The intuition behind Black-Litterman model portfolios. Technical report, Goldman Sachs Investment Management Research, 1999.

Nicholas J. Higham. Computing the nearest correlation matrix: a problem from finance. *IMA Journal of Numerical Analysis*, 22, 2002.

Gerard Hoberg and Gordon Phillips. Text-based network industries and endogenous product differentiation. *Journal of Political Economy*, 124(5), 2016.

Ravi Jagannathan and Tongshu Ma. Risk reduction in large portfolios: why imposing the wrong constraints helps. *Journal of Finance*, 58(4), 2003.

Albert Q. Jiang et al. Mistral 7B. arXiv:2310.06825, 2023.

Philippe Jorion. Bayes-Stein estimation for portfolio analysis. *Journal of Financial and Quantitative Analysis*, 21(3), 1986.

Raymond Kan and Guofu Zhou. Optimal portfolio choice with parameter uncertainty. *Journal of Financial and Quantitative Analysis*, 42(3), 2007.

David Krackhardt. Predicting with networks: nonparametric multiple regression analysis of dyadic data. *Social Networks*, 10(4), 1988.

Laurent Laloux, Pierre Cizeau, Jean-Philippe Bouchaud, and Marc Potters. Noise dressing of financial correlation matrices. *Physical Review Letters*, 83, 1999.

Olivier Ledoit and Michael Wolf. Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10, 2003.

Olivier Ledoit and Michael Wolf. Honey, I shrunk the sample covariance matrix. *Journal of Portfolio Management*, 30(4), 2004a.

Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88, 2004b.

Olivier Ledoit and Michael Wolf. Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15, 2008.

Olivier Ledoit and Michael Wolf. Robust performance hypothesis testing with the variance. *Wilmott*, pages 86–89, September 2011.

Olivier Ledoit and Michael Wolf. Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *Review of Financial Studies*, 30(12), 2017.

Olivier Ledoit and Michael Wolf. Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 2020.

Charles M. C. Lee, Stephen Teng Sun, Rongfei Wang, and Ran Zhang. Technological links and predictable returns. *Journal of Financial Economics*, 132(3), 2019.

Xiaohui Victor Li and Francesco Sanna Passino. FinDKG: Dynamic knowledge graphs with large language models for detecting global trends in financial markets. In *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF '24)*, pages 573–581, 2024. doi: 10.1145/3677052.3698603. arXiv:2407.10909.

Marcos López de Prado. Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 2016.

Marcos López de Prado. *Machine Learning for Asset Managers*. Cambridge University Press, 2020.

Cheng Lu, Papa Momar Ndiaye, and Majeed Simaan. Improved estimation of the correlation matrix using reinforcement learning and text-based networks. *International Review of Financial Analysis*, 96:103572, 2024.

Yutong Lu, Gesine Reinert, and Mihai Cucuringu. Co-trading networks for modeling dynamic interdependency structures and estimating high-dimensional covariances in US equity markets. arXiv:2302.09382, 2023.

Rosario N. Mantegna. Hierarchical structure in financial markets. *European Physical Journal B*, 11, 1999.

Harry Markowitz. Portfolio selection. *Journal of Finance*, 7(1), 1952.

Lior Menzly and Oguzhan Ozbas. Market segmentation and cross-predictability of returns. *Journal of Finance*, 65(4), 2010.

Whitney K. Newey and Kenneth D. West. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 1987.

Andrew J. Patton. Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 2011.

Edward Qian and Stephen Gorman. Conditional distribution in portfolio theory. *Financial Analysts Journal*, 57(2):44–51, 2001.

Qwen Team. Qwen2.5 technical report. arXiv:2412.15115, 2024.

Stephen A. Ross. The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3): 341–360, 1976.

Anna Scherbina and Bernd Schlusche. Follow the leader: using the stock market to uncover information flows between firms. *Review of Finance*, 24(1), 2020. Versão anterior: Economic linkages inferred from news stories and the predictability of stock returns, AEI Working Paper (2016).

Yan Tang, Yifan Zhou, and Mingyi Hong. News co-occurrences, stock return correlations, and portfolio construction implications. *Journal of Risk and Financial Management*, 12(1):45, 2019. Conferir prenomes dos autores.

Apêndice A

Prompt e Esquema de Extração

Este apêndice reproduz o prompt e o esquema JSON usados na extração (Capítulo 5), na versão `a05d0c0dc189`. Os marcadores entre chaves duplas são substituídos pelo título, pela data, pelos *tickers* marcados e pelo texto de cada artigo. As cópias em `Apendices/` vêm de `prompts/extraction.txt` e `prompts/schema.json` no repositório do projeto.

A.1 Prompt

```
You are an information extraction system for financial news. You do not
↪  chat, explain, or reason out loud. You read one article and return
↪  structured data.

TASK
Identify the ECONOMIC AGENTS in the article and the ACTIONS that connect
↪  them.
Return one tuple for every relationship where one agent affects another.

WHAT COUNTS AS AN ECONOMIC AGENT
Any entity that can act on, or be acted on by, economic forces:
- companies and their tickers ....... NVDA, Apple Inc., Petrobras
- market indices ................... S&P 500, Nasdaq 100, Ibovespa
- central banks ..................... the Fed, ECB, Banco Central do
↪  Brasil
- governments and regulators ........ US Treasury, SEC, European
↪  Commission
- currencies and crypto ............. USD, EUR, BTC
- commodities ....................... crude oil, gold, soybeans
- sectors and industries ............ semiconductors, airlines, banking
- institutions and funds ............ BlackRock, IMF, OPEC
- economically significant people ... Jerome Powell, a named CEO

WHAT IS NOT AN ECONOMIC AGENT
- financial metrics and line items: revenue, EBITDA, net income,
↪  earnings,
  dividends, margins, guidance, net interest income, exports, sales
- generic or unnamed groups: "investors", "analysts", "shareholders",
  "the market", "U.S. stocks", "consumers"
- the news outlet or data provider reporting the story
```

```
A company reporting higher revenue, raising its dividend or beating
 ↪  estimates
is NOT a relationship between two agents -- skip it, unless a second
 ↪  named
agent caused the effect (then it is agent_a and the company is agent_b).

Examples:
  WRONG: Intuit --increases--> revenues     (metric)
  WRONG: GNC --contracted--> gross margin   (metric)
  WRONG: investors --buy--> AAPL            (unnamed group)
  RIGHT: Janney --raises price target on--> Hercules Capital

WHAT COUNTS AS AN ACTION
A verb or event in the article that transmits economic effect from one
 ↪  agent to
another: investing, acquiring, supplying, competing, regulating, raising
 ↪  rates,
reporting earnings, issuing guidance, suing, partnering, defaulting,
 ↪  cutting
output. The action is what makes the pair a relationship rather than two
 ↪  names
appearing in the same text.

EACH TUPLE HAS EXACTLY FIVE FIELDS
1. agent_a ......... the agent that acts (the source of the effect)
2. agent_b ......... the agent that is affected (the target of the
 ↪  effect)
3. relation_type ... the action, as a short lowercase verb phrase
                     (e.g. "invests in", "supplies", "competes with",
                      "raises rates on", "acquires", "regulates")
4. direction ....... the effect on agent_b: "positive" or "negative"
5. strength ........ 0.0 to 1.0, how strong and how certain the effect
 ↪  is

RULES
- Both agents must be explicitly named or unambiguously identifiable in
 ↪  the
  article. Never invent an agent, and never infer one from outside
   ↪  knowledge.
- Direction is the effect on agent_b, not on agent_a. If Fed raises
 ↪  rates and
  that hurts tech stocks, direction is "negative".
- Order matters: agent_a acts, agent_b receives. If the article
 ↪  describes a
  mutual effect, emit two tuples, one in each direction.
- strength calibration:
    0.8 - 1.0  article states the link explicitly AND the effect is
     ↪  material
    0.4 - 0.7  link is stated but modest, partial, or indirect
    0.1 - 0.3  link is speculative, hedged, analyst opinion, or
     ↪  incidental
- Use the ticker symbol when the article gives one; otherwise use the
 ↪  most
  specific name the article uses. Be consistent within a single article.
- Extract only relationships the article itself supports.
- agent_a and agent_b must be two DIFFERENT entities.
```

```
- Quality over quantity. Most articles support between 0 and 4
 ↪  relationships.
  Return only the ones the article clearly states; adding weak,
   ↪  speculative or
  repeated tuples to make the list longer is an error. The hard limit is
   ↪  8.
- Use the whole strength scale. Most stated-but-modest links belong in
  0.4 - 0.7; reserve 0.8+ for explicit, material effects.
- If the article contains no relationship between two economic agents,
 ↪  return
  an empty list. An empty list is a valid and correct answer.

ARTICLE
Title: {{TITLE}}
Published: {{DATE}}
Filed under tickers: {{SYMBOLS}}

{{ARTICLE}}

Return only JSON matching the required schema. No commentary.
```

A.2 Esquema JSON

```
{
  "type": "object",
  "properties": {
    "tuples": {
      "type": "array",
      "items": {
        "type": "object",
        "properties": {
          "agent_a": {
            "type": "string"
          },
          "agent_b": {
            "type": "string"
          },
          "relation_type": {
            "type": "string"
          },
          "direction": {
            "type": "string",
            "enum": [
              "positive",
              "negative"
            ]
          },
          "strength": {
            "type": "number",
            "minimum": 0,
            "maximum": 1
          }
        },
```

```
        "required": [
          "agent_a",
          "agent_b",
          "relation_type",
          "direction",
          "strength"
        ]
      },
      "maxItems": 8
    }
  },
  "required": [
    "tuples"
  ]
}
```

Apêndice B

Reprodutibilidade

Todo o trabalho foi feito com código próprio, em Python, reunido no repositório do projeto (`NewsManager`), a partir de dados públicos: o conjunto FNSPID (Dong et al., 2024) e os registros da SEC. Este apêndice lista como cada resultado do texto é obtido.

B.1 Etapas e comandos

A Tabela B.1 lista as etapas na ordem de execução. Cada etapa grava seu produto em disco e pode ser retomada.

B.2 Versões e sementes

- Extração: versão `a05d0c0dc189`, *hash* do prompt, do esquema, do limite de caracteres e do nome do modelo (Qwen2.5-14B-Instruct, servido pelo Ollama).
- Ligação a *tickers*: versão `c49291db2953`, *hash* do prompt, do modelo (Qwen2.5-7B-Instruct), dos tipos de agente e das listagens de referência.
- Parâmetros fixos: janela de notícias de 365 dias, meia-vida de 90 dias, janela de estimação de 252 pregões, custo de 10 pontos-base, rebalanceamento no primeiro pregão do mês.
- Sementes: 7 nos *bootstraps* e nas permutações do placebo; 101 a 104 no QAP (250 permutações por semente).
- Cada desenho de carteira foi registrado no repositório antes da execução; o histórico de versões guarda o texto de cada pré-registro e a data.

Tabela B.1: Etapas do processo e comando de cada uma.

etapa	comando
ingestão e curadoria do corpus	`python -m newsmanager {probe, plan, ingest, curate, validate}`
unidades e extração pelo LLM	`python -m newsmanager.extract {units, run, collect, filter}`
ligação a *tickers*	`python -m newsmanager.extract {link-prep, link-run, link-verify, link-build}`
grafo de eventos	`python -m newsmanager.extract graph-build`
preços, universos e setores	`python -m newsmanager {prices, universe, sectors}`
regressão preditiva (E0–E4)	`python -m newsmanager h1` e `h1 -residual`
desenhos D1 e D2	`python -m newsmanager backtest -n {50, 100, 200}`
desenhos D3 a D9	`python -m newsmanager.backtester run backtests/*.toml` e `compare`
testes de pares (H1a, H1b)	`python -m newsmanager.grafo {diadico-painel, diadico}`
teste de permutação (QAP)	`scripts/revisao_qap.py`
validação da extração e descritivas	`python -m newsmanager.grafo {auditoria, amostra, metricas, anonimizacao, anon-run, anon-comparar, descritivas}`
conferência dos números do texto	`scripts/conferir_numeros.py`